G検定
人工知能とは
とは
起源言葉の初 1956アメリカでダートマス会議ジョン・マッカーシー
概念
推論、認識、判断など、人間と同じ知的な処理
能力を持つ機械（情報処理システム）
知性や知能自体の定義がないため、
ただし、人工知能とはなんかは共有される定義
がない
周囲の状況（入力）によって行動（出力）を変
えるエージェント（プログラム）
エージェントアプローチ人工知能（共立出版）
分類
レベル１：単純な制御プログラムすべての振る舞いが予め決められ
エアコンの温度調整、洗濯機の水量調整、電気
ジェーバーの深剃り調整など、制御工学やシス
テム工学と呼ばれる分野で長年技術
レベル２：古典的な人工知能
探索・推論・知識データを利用することで、状
況に応じ極めて複雑な振る舞いをする
掃除ロボット、診断プログラムなど、特定の分
野で高い有用性を示し、広く実用化される技術
DeepLearingにつながる人工知能の研究はこの
レベルから始めっている
レベル３：機械学習を取り入れた人工知能
非常に多くのサンプルデータをもとに入力と出
力の関係を学習
検索エンジンや交通渋滞予測
パターン認識という古くからの硏究ベースに発
展し、2000年代ピッグデータ時代に迎えて進化
している
どのような特徴が学習結果に大きく影響する
（特徴量）
レベル４：ディープラーニングを取り入れた人
工知能
特徴量と呼ばれる変数を、自動的に学習するサ
ービスや製品。
特徴量を自動的に学習する技術で、画像認識、
音声認識、自動翻訳などで活用している
AI効果
人工知能で何か新しいことが実現され、その原
因がわかってしまうと、「それは単純な自動化
で合って知能とは関係ない」と結論つける人間
の心理的な効果
人工知能とロボットの違い
ロボットの脳に当たる部分が、その限りでもな
い、「考える（知的な処理能力）という「目に
見えないもの」が中心」
歴史
初の汎用コンピュータ
1946年、アメリカのペンシルバニア大学でエニ
アック（ENIAC）
17,468本もの真空管で構成された汎用電子式コ
ンピュータ
第１次AIブーム
1950年代後半〜1960年代
探索・推論の時代
ダートマス会議 1956年、アメリカで開催された
ジョン・マッカーシー初めて人工知能の言葉を使用
ニューウェル、サイモン
世界初の人工知能プログラム：ロジック・オセ
リストをデモンストレーション
コンピュータを用いて数学の定理を自動的に証
明することが実現可能を示し（四則演算などの
数値計算しかできないが。）
特定の問題に対して解を提示できるようになっ
たことのブーム
東西冷戦下、アメリカは英語ーロシア語の機械
翻訳が注目
知的なさまざまなもんだチェスや将棋で優勝
が、非常に限定された状況で設定された問題し
かにすぎない
探索・推論も初めている
迷路や数学の定理を証明するような簡単な問題
（トイ・プロブラム（おもちゃの問題））でき
ても、複雑なものができないことが明らかにな
ったので、
1970年代は人工知能研修の冬の時代入った
機械学習・特徴表現学習も始めているニューラルネットワーク・機械翻訳
第２次AIブーム
1980年代
知識の時代
1990年：世界初のWebページ
専門家の知識を取り込んだ「エキスパートシス
テム」の開発が活性化
日本では、政府によって「第五時代コンピュー
タ」と名付けられた大型プロジェクトが推進
しかし、知識を蓄積・管理は大変のことを明ら
かになって
1995年ごろから冬時代入った
知識表現：オントロジー
第3次AIブーム
2010年〜
機械学習・特徴表現学習の時代
ビッグデータ
人工知能が自ら知識を獲得する機械学習が実用
化され
統計的機械学習統計的な機械翻訳・検索エンジン
ニューラル機械翻訳
自動運転
大規模言語モデル
知識を定義する要素（特徴量と呼ばれる対象w
お認識する際に注目すべき特徴を定量的に表し
たもの）を人工知能が自ら習得するディープラ
ーニング（深層学習）
第4次AIブーム？
一部の専門家は、2022年ChatGPTの登場の機に
AIブームが新たな局面に入る
問題
トイ・プロブレム（おもちゃの問題）
問題の本質を理解したり、現実世界の問題に取
り組んだりする練習
複数の研修者がアルゴリズムの性能を比較する
ために用いることも
フレーム問題
1969年ジョン・マッカーシーとパトリック・ヘ
イズ提出
未だに本質的な解決はされていない、人工知能
研究の最大な難問
今しようとしていることに関係のあることから
だけを選びすることが、実は非常に難しい
哲学者のダニエル・デネット
隣に時限爆弾があるバッテリーを持ち出すロボ
ットを作るの例
１号：爆弾も一緒に持ち出して爆発
２号：持ち出す方法を考えすぎで爆発
３号：持ち出す方法の方法を考えすぎで爆発
チューリングテストイギリスのアラン・チューリング提出
別の場所にいる人間がコンピュータと会話を
し、相手がコンピュータだと見抜けなければコ
ンピュータには知能があるとする
イライザ（ELIZA）
1966年ジョセフ・ワイゼンバウム開発された
精神科セラピストの役割を演じるプログラム
で、本物のセラピストと信じてしまう人が現れ
ローブナーコンテスト
1991年以降毎年開催
チューリングテストに合格する会話ソフトウェ
アを目指すローブなーコンテスト
強いAIと弱い AI
1980年アメリカ哲学者ジョン・サールが発表し
た「Minds, Brains, and Programs（心、脳、プラ
グラム）」論文で提示した
強いAI
適切にプログラムされたコンピュータは人間が
心を持つのと同じ意味で心を持つ。また、プロ
グラムそれが自身が人間の認知の説明である
「中国語の部屋」の思考実験で「強いAI」は実
現不可能を主張している
完璧なマニュアルを持っているの行動か、心を
持つ行動するか判断できない
チューリングテストの拡張とし、心がどこに存
在するのか、あるいは意味はどこにあるのかの
思考。
コンピュータは記号操作を行っているだけで、
心にとって本質的な意味論を欠けていると主張
している
ロジャー・ペンローズ（ブラックホールの研究
で有名なスティーブン・ホーキングと共同研修
の有名な数学者）
「皇帝の新しい心ーコンピュータ・心・物理法
則」（林一訳、みすず書房）
意識は脳の中にある微細な管に生じる量子効果
（非表示スケールの小さい世界で生じる物理現
象）が絡んでいるので、既存のコンピュータで
は「強いAI」は実現できないと主張
弱いAI
コンピュータは人間の心を持つ必要はなく、有
用の道具であれば良い
シンボルグラウンディング問題（記号接地問
題）
1990年認知科学者のスティーブン・ハルナッド
議論
記号（シンボル）とその対象がいかにして結び
つくか
フレーム問題と同様、人工知能の難問
身体性知識が成立するためには身体が不可欠の考え方
人間には身体があるからこそ物事を認識した
り、思考したりできるという考え、「身体性」
二着目したアプローチ
コップ触ったの感覚、落とすと割れるなどの経
験を含めて「コップ」という概念
外界と相互作用できる身体がないと、概念は捉
えきれない
知識獲得のボトルネット機械翻訳
1970年代後半：ルールベース機械翻訳
1990年代以降：統計的機械翻訳実用レベルになれない
例：He saw a woman in the garden with a
telescope
人間：彼は望遠鏡で、庭にいる女性を見た
機械：彼は望遠鏡で、庭で女性を見た
コンピュータが「意味」を理解していないこと
一般常識がなければ訳せないことがある、一般
知識を取り込んむのは膨大すぎで、極めて困難
となっている
2010年頃、ニューラル機械翻訳
（DeepLearing）登場
2016年11月、Goole翻訳では、機械翻訳の品質
を格段に向上した
ニューラル機械翻訳では人間が言葉を理解する
と同じような構造で訳文を出力すると言われ、
TOEIC 900点以上の人間と同等の訳文も生成可
能だとも言われている
2018年以降：LLMで文章の文脈を理解する能力
に優れ、多様な言語の翻訳もできた
ニューラル機械翻訳は翻訳に特化した技術であ
り、特定の言語か言語への翻訳や専門分野の翻
訳において強みを発揮している
めぐる動向
探索・推論
迷路（探索木）：構造表現を木のような構造
（ツリー）をしているもの
幅優先探索
最短距離でゴールに辿り着く解
探索の途中で立ち寄ったノードを全て記憶する
ので、複雑な迷路ではメモリ不足可能
深さ優先探索
行けるところまで行って、行き泊まりなったら
１つ手前のノードに戻って探索
メモリはあんまりいらないが、最短距離である
かは限らない
ハノイの塔（パズル）探索木にも変換できる
ロボットの行動計画プラニング
状態遷移を表す矢印をロボットの行動都みなし
て構成した空間を探索
STRIPS（Stanford Research Institute Problem
Solver）
前提条件→行動→結果
SHRDLU
1968〜1970にデリー・ウィノグラード開発され
システム
英語による指示を受けて、コンピュータ画面に
絵かれる積み木の世界を動かす
自然な会話はできる
デリー・ウィノグラードはHCI（ヒューマン・
コンピュータ・インタフェース）研究分野へ移
り、Googleの創業者の一人のラリー・ペイジを
育っていた
成果をCycプロジェクトに引き継ぎられた
ボードゲーム（オセロ・チェス・将棋・囲碁）
2016年3月、AlphaGoを4勝1敗で李世石を勝っ
た
組み合わせは天文学的な数字で事実上全てを探
索しきれない
効率よく探索するため、コストの概念を導入
ヒューリスティックな知識（経験知、発見知）
あらかじめ知っている知識や経験を利用してコ
ストを計算すれば、探索を短縮
Mini-Max法
自分の番では自分が有利、相手の番では相手が
有利を前提に戦略をたつ
未来の局面から現在の局面に向けて逆算するこ
とで戦略を立つ。できるだけ遠い未来のゲーム
の状態（ゲームを深く先読みして）をは配慮
し、思慮深い戦略を立つ。深さは（先読み）
αb法（アルファベータ法）
Mini-Maxの無駄を省く方法、スコア計算必要な
いノードを探索対象から外す
スコアを最大選択の自分の局面、探索する必要
のない相手の枝を切り落とす行為：αカット
スコアを最小選択の相手の局面、探索する必要
のない自分の枝を切り落とす行為：bカット
モンテカルロ法
プレイアウト
コンピュータが2人の仮想的なプレイヤーを演
じて、完全にランダムにゲームを進行し終局左
せ
ある局面からプレイアウトを複数回実施するこ
とと、どの方法が一番勝率が高いかを計算し
て、スコア評価を行う
人間がスコアのつけ方の考え方が不要、数多く
打って最良のものを選ぶ
ブルートフォース（力任せ）と同様に、組み合
わせが爆発増えるケースがある
ディープラーニング AlphaGo
知識表現
人工無脳
知識なしても知性があるように感じる人間心理
不思議
特定のルール・手順に沿って会話を機械的に処
理するだけで、実際は内容を理解している訳で
はない
イライザ（ELIZA）
1964〜1966年ジョセフ・ワイゼンバウム開発、
パターン照合で応答するチャットボット。相手
の発言を再利用して発言する手法
後ろのコンピュータゲームやスマートフォンの
音声対話システムに影響あ与えて、会話ボット
や人工無脳の研修につながっている
心理療法の分野にも影響を与えて、オンライン
セラピストのシステムも発展していた
知識ベースの構築とエキスパートシステム
エキスパートシステム
ある専門分野の知識を取込み、その分野の専門
家のように振る舞うプログラム
マイシン（MYCIN）
1970年代、スタンフォード大学開発され
血液中のバクテリアの診断支援のルールベース
正確率は69％、専門医の80％より低いが、専門
医ではない医師より良い結果
DENDRAL
1960年代末、スタンフォード大学開発、実用指
向AI真ののエドワード・ファイゲンバウム開発
未知の有機化合物を特定する
1977年実世界の問題に対する技術を重視した
「知識工学」を提唱
1970年代後半〜1980年代、多く開発された
IBMのワトソン（Watson）
2011年アメリカのクイズ番組で優勝…Question-Answering（質問応答）研修分野の成果
ウィキペディアの情報をもとにライトウェイ
ト・オントロジーを生成して、それを解答に使
う
意味の理解より、質問に含まれるキーワードと
関連しそうな答えを高速に検索に近い
実用レベルまでできた、医療診断や「シェフ・
ワトソン」で新しい料理のレシピを考えの応用
など、コールセンター、人材マッチング、広告
などなどで活用している
「ロボットは東大に入れるか（東ロボくん）」
2011年開始、2020年まで続けられ
2016年6月は進研模試で偏差値57.1でほとんどの
私立大学に合格できるレベルまでできたが…そ
の後は改善は見込めなく、2,016年から最後の模
試を中止、各教科での研究を深めるフェーズに
移り
知識獲得のボトルネック（エキスパートシステ
ムの限界）
ドキュメント・事例から自然言語処理や機械学
習より取得できるが
最大の知識源の専門家からの暗黙知（経験的
な）の獲得は困難
インタビューシステム：このよう事情から知識
獲得のため開発された
知識のお互いが矛盾、一貫性ないものも出て、
知識ベースを保守するのが困難
一部の専門家だけ持つ高度な知識を明示的体系
化でき、常識的な知識は暗黙d明文化されてい
ない者は不向き
コンピュータで知識を扱うための方法論
意味ネットワーク
オントロジー
意味ネットワーク（semantic network）
元々認知心理学における長期記憶の構造モデル
として考案され、現在でも、人工知能に重要な
知識表現の方法の一つ
「概念」をラベルのついたノードで表し、概念
間の関係をラベルをついたリンク（矢印）で結
んだネットワーク
is-a
「である」の継承関係
下位概念から上位概念へ矢印推移率成立
part-of
「一部である」の属性関係推移率不成立がある
…他の関係も多く、最低でも同一類は5以上
ある概念に関連する知識がリンクをもとに辿れ
るため知識検索が容易
オントロジー（ontology概念体系を記述するた
めの方法論）
Cycプロジェクト
DENDRALの後継、1984年スタート、全ての一
般常識をこオンピュータに取り込もう
現在も継続中
知識ベースのシステムが柔軟な能力を発揮する
ための膨大な知識を構築
エキスパートシステムのための知識の共有と再
利用に貢献する学問として知識工学が期待され
るようになり
本来は哲学擁護するの存在論（存在に関する体
系的な理論）の意味
人工知識の用語として、ドム・グルーバーによ
る「概念化の明示的な仕様」て定義され
「言葉（語彙）」や「その意味」、または「そ
れらの関係性」を、他の人とも共有できるよう
に、明確な約束事（仕様）として定義する
構築
流派
対象世界の知識をどのように記述すべきかを哲
学的にしっかり考えて行うもの
ヘビーウェイトオントロジー（重量オントロジ
ー）
その構成要素や意味の関係の妥当性について哲
学的な考察、人間が関わることになる傾向が強
く、時間とコストがかかる
一例：Cycプロジェクト
効率を重視し、とにかくコンピュータにデータ
を読み込ませてできる限り自動的に行うもの
ライトウェイトオントロジー（軽量オントロジ
ー）
完全さは求めない、実用的に使えるものが重視
ウェブマイニング
データマイニング
セマンティックWeb
Webサイトが持つ意味をコンピュータに理解さ
せ、コンピュータ同士で処理を行わせるための
技術
LOD（LinkedOpenData）
コンピュータ処理に適したデータを公開・共有
する技術
HTMLに対して、データのWebの構築を目指す
機械学習・深層学習
機械学習
元々文字認識などのパターン認識の分野で長年
蓄積された技術
2000年以降、インターネットの普及によりデー
タが十分に蓄積され、機械学習はビックデータ
（インターネットの成長とともに蓄積された大
容量のデータ）を注目集まれた
レコメンデーションエンジン、スパムフィルタ
など実用化されるまで至った
人工知能のプログラム自身がデータから学習す
る仕組み
サンプルデータの数が多ければ多いほど、望ま
しい学習結果が得られる（汎用は別）
次元の呪い：データの特徴が増えると、適切な
学習を行うために必要なデータ量が著しく増加
する傾向
次元（特徴量）を減らす工夫
多様かつ質の高いデータを大量に用意
統計的な自然言語処理
従来の文法構造や意味構造を分析して短号単位
で訳を割り当てるではなく、複数の単語をひと
まとまりした単位（句までまたは文単位）で用
意された膨大な対訳データをもとに、最も正確
である確率がたかい訳を選択
対訳データ（コーパス）
「bank」という言葉には、「銀行」または「土
手」という言葉が言語候補になるが、対訳デー
タをたくさん持っていれば、近くにいる単語よ
り、どちらが確率が高いを機械学習できる
特徴量設計
「注目すべきデータの特徴」の選び方が性能を
決定つける
特徴表現学習
人間が特徴量を見つけ出すが難しいに対して、
特徴量を機械学習自身に発見させる
ディープラーニング（深層学習）は「特徴表現
学習」を行う機械学習アルゴリズムの一つであ
る
与えられたデータの特徴量を階層化し、それら
を組み合わせることで問題を解決
ニューラルネットワーク自身が複数ステップの
コンピュータプログラムを学習できる
特徴量は入力データと無関係で、与えられた問
題を解くために必要な処理に役たつ情報が特徴
量として抽出の考えができる
ただし、特徴量の意味解読は困難で、「判断理
由が示せないブラックボックス型の人工知能」
と言われるもある
ディープラーニング（機械学習の一種）ニューラルネットワーク
生物の神経回路を真似することで学習を実現
1943年、神経生理学者のウォーレン・マカロッ
クと数学者のウォルター・ピッツが生物の神経
細胞を単純化した最初のニューロンモデルを発
表
1958年、アメリカのフランク・ローゼンブラッ
トが学習可能なニューロンモデルを提出：パー
セプトロン
出力を見ながら「重み」を調整、直線分離可能
な分類問題を解くが可能
1969年、マービン・メンスキーら：パーセプト
ロンは直線で分離できない分類問題に対応でき
ない、「パーセプトロンの限界」が明らかに
ディープラーニング（深層学習）
深く多層化したニューラルネットワークを使っ
て、データに潜む特徴を自動的に学習する手法
ニューラルネットワークを多層化は簡単が、全
体を学習する方法は難しい
1986年デビッド・ラメルハートラ解決：誤差逆
伝播法（バックプロバゲーション）を提唱
（それまでは、最後の層のニューロンだけを学
習させるのは一般的な限界）
1967年甘利俊一提唱した適応的パターン分類器
の確率的な学習理論は基礎研究の一つ
1979年、福島邦彦がネオコグ二トロンが発表
1989年、ヤン・ルカンは、ネオコグと類似アイ
デア（畳み込みニューラルネットワーク）の構
造でLeNetと名付け、そのニューラルネットワ
ークの学習に誤差逆伝播法を利用することを提
案し、現在の画像認識ニューラルネットワーク
の基礎を構築された…（CNN）
ただ、3層より深くしても、精度が上がらな
い、あるいは学習が困難（計算速度の影響もあ
り）
1992〜1995 アメリアのベル研究所のヴァプニク
らが開発した「サポートベクターマシン」で人
気集まった
当時はNNよりもの効果が高い、線型分割できな
い問題も解決、その後はBoostingと主な競争に
なる
2006年多層にしても学習精度が上らない問題
に対して、入力したものと同じものを出力する
ように学習する、オートエンコーダ（自己符号
器）、活性化関数の研究で、4、5層（ディー
プ）までにしても学習可能になった
LSTMを勾配無くなる問題の理論を確立＋ビッ
クデータと計算力の発展　　　　　　　　　　
　　　　
キーイベント
2012年：画像認識の精度を競い合うILSVRC
（ImageNet Large Scale Visual Recognition
Challenge）
トロント大学のジェフリー・ヒントンらの
SuperVisionが圧倒的な勝利（15.3対2位の東大
のISIの26.1）
この前に、機械学習の特徴量を決めるのは人
間。
深層学習（ディープラーニング）登場：
AlexNet
2017年：Attention is all your need
（Transformer）
RNNやLSTMの痛みを解決、単語と単語の関係性
（アテンション（注意力）で広範囲にわたって
学習可能、さまざまな文脈や状況で利用する単
語意味やニュアンスを深く理解できるだけでな
く、文中の任意の単語間の関連性を複数同時に
効率よく計算することが可能になった）
2022年11月：ChatGPTの登場 LLMの訓練
事前学習：大量な文章を与えさせ、一般的な言
語の構造、文法、語彙などの基本を学び
ファインチューニング（微調整）：特定のタス
クや応用分野に焦点を当てた訓練を行うこと
で、分脈を理解して論理的かつ適切な回答を生
成する能力あるを向上、人のフィードバックよ
りも継続的な学習・改善する
2020年、OpenAIはトランスフォーマーをベー
スとしてLLMの性能は、利用可能なデータ量や
計算リソースに制限がなければ、パラメータの
個数を多くすればするほど性能向上が見込める
こと。GPT2（2019）約15億、GPT3（2020）約
1750億、GPT4（2023）約1兆個超え
機械学習の手法
学習の種類
教師あり学習
与えられたデータ（入力）を元に、そのデータ
がどんなパターン（出力）になるのかを識別・
予測する
例
回帰問題連続値を予測する問題過去の売上から、将来の売上を予測
分類問題離散値を予測する問題与えられた動物の画像が、何の動物かを識別
英語の文章を与えられた時に、それを日本語の
文章に翻訳
代表的な手法
線形回帰（Liner regression）
データ（の分布）があったときに、そのデータ
に最も当てはまる直線を考えるというもの
L1 ラッソ回帰（Lasso regression）
L2 リッジ回帰（ridge regression）
単回帰分析 １種類の入力だけを用いた回帰分析
重回帰分析複数の入力を用いた回帰分析
ロジスティック回帰（logistic regression）
名前回帰ですが、実は分類問題に用いる手法
シグモイド関数
値は0〜1：2クラス分類
与えられたでデータが正例（＋1）、負例（0）
になるかの確率を求め、出力値が0.5以上ならば
正例、0.5未満なら負例で、データを二分する。
0.5以外の閾値でも可、例：迷惑メール分類
ソフトマックス関数
各種類の出力値はそれぞれ0〜1の間、出力値の
合計が1になるのような出力関数
出力が確率分布
多種類の分類を行う
ランダムフォレスト（random forest）
複数の決定木を作成し、各決定木で用いる特徴
量をランダムに抽出することで、特徴量の組み
合わせ問題に対応する。
学習に持ちいるデータも全データを使うのでは
なく、それぞれ決定木に対してランダムに一部
のでツーアウトを取り出し学習に用いる（ボー
トストラップサンプリング）
それぞれの結果を用いて多数決を取って、モデ
ルの最終出力にする
複数のモデルで学習させるのはアンサンプル学
習と言いう、全体から一部のデータを用いて複
数のモデルを用いて学習する方法：バギング
（bagging）
サポートベクターマシン（SVM：Support
Vector Machine）
高度な数学理論に支えられた手法、ディープラ
ーニングが考えられる以前は機械学習において
最も人気のあって手法の1つ。
（入力に用いる）異なるクラスの各データ点と
の距離が最大となるような境界線を求めること
で、パターン分類を行う
マージン最大化
扱うデータ高次元
データが線形分類できない（直線で分類できな
い）
カーネル関数を用いて、高次元に写像後の空間
で線形分類できるようにするアプローチ。
高次元計算が複雑にならないようなテクニック
のことをカーネルトリックと言う
自己回帰モデル（autoregressive model, ARモデ
ル）
時系列データに適用される手法
時系列データ分析のとこを単純に時系列分析と
言う
ベクトル自己回帰モデル（vector
autoregressive model, VARモデル）
複数種類の場合はベクトル
教師なし学習
入力データそのものが持つ構造・特徴が学習
ECサイトの売上データから、どういった顧客層
があるのかを認識
入力データの各項目間にある関係性を把握
代表的な手法
階層なしクラスタリング（k-means法）
データをk個のグループに分けることを目的、
もとのデータからグループ構造を見つけ出し、
それぞれをまとまる
1、まずは適当に各データをkこのクラスタに振
り分ける
2、各クラスの重心をも止める
3、求まったk個の重心と各データとの距離を求
め、各データを最も距離が近い重心に対応する
クラスに振り分け直す
4、重心の位置が（ほぼ）変換しなくなるまで
2、3を繰り返す
階層ありクラスタリング
ウォード法
各データの平方和が小さい順にクラスタを作っ
ていくことで階層構造を作る
最短距離法
最も距離が近い２つのデータ（クラスタ）を選
び、それらを一つのクラスタにまとめることで
階層構造を作る
デンドログラム（dendrogram）：樹形図が作
成され
主成分分析（Principal Component Analysis：
PCA）
データの特徴量間の関係性、すなわち相関を分
析することでデータ構造かを掴む手法
特に特徴量の数が多い場合に用いられ、相関を
持つ多数の特徴量から、相関が少ない少数の特
徴量へと次元削減することが主たる目的
特異値分解（Singular Value Decomposition,
SVD）
主に文章データを扱う場合利用され、また、デ
ータの次元を2、3次元まで削減することによっ
て可視化を行う手法もよく利用される
線形、分散を最大限残す
主成分分析以外の次元削減野手法
多次元尺度構成法（Multi-Dimensional Scaling,
MDS）
線形、分散を最大限残す、2次元への次元削
減・可視化する手法
t-SNE（t-distributed Stochastic Neighbor
Embedding）
2次元、3次元へ、局所的な近さ（クラスタ）を
保存、非線形、可視化によく使う
協調フィルタリング（collaborative filtering）
レコメンデーション（recommendation）に用
いられる手法の一つ、「対象ユーザがかってい
ないが、似ているユーザ測っている商品を推薦
する」
事前にある程度の参考できるデータがない限り
に、推薦を行えない：コールドスタート問題
（cold start problem）
コンテンツベースフィルタリング（content-based filtering）
ユーザ側ではなく、商品側に何かしらの特徴量
を付与し、特徴が似ている商品を推薦する。対
象ユーザのデータさえあれば推薦を行うことが
できる
トピックモデル（topic model）
クラスタリングモデルの一種、データを一つの
クラスタに分類するk-meansと異なり、複数の
クラスタにデータを分類する。
代表的な手法
潜在的ディリクレ配分法（latent Dirichlet
allocation, LDA）
強化学習（Reinforcement Learning）
「行動を学習する仕組み」、ある環境下で、目
的とする報酬（スコア）を最大化するためには
どうのような行動を取っていけばいいかを学習
状態、行動、報酬のやり取りを1時刻ごとに進め
て考え、「将来にわたって獲得できる累積報酬
を最大化する＝累積報酬Rtを最大化するような
状態Stと行動atの対応関係を求めること」
1、エージェントは時刻tにおいて環境から状態
Stを受け取る
2、エージェントは観測した状態Stから行動atを
選択して実行する
3、環境が新しい状態St+1に遷移する
4、エージェントは遷移に応じた報酬rt+1を獲得
5、得られた報酬をもとに、選択した行動の良
し悪しを学習する
6、ステップ1、へ
割引率：未来の価値を今の価値へ変換するの割
引率
バンディットアルゴリズム（Multi-Armed
Bandit Problem）
組み合わせが無数のなかに行動の選択を考える
課題
活用（exploitation）
現在知っている情報の中から報酬が最大隣るよ
うな行動を選ぶ
探索（exploration）
現在知っている情報以外の情報を獲得s得るた
めに行動を選ぶ
ε-greedy方策（epsilon-greedy policy）
基本は活用、一定確率εで探索（ランダム行動
を選択）
UCB方策（upper-confidence bound policy）
期待値の高い選択を選ぶのを基本戦略としつ
つ、これまで試行回数が少ない行動は優先的に
選択する
方策：ある状態から取りうる行動の選択肢、お
よびその選択肢をどう決定するかの戦略、各行
動を選択する確率表現とする
マルコフ決定過程モデル（Markov）
マルコフ性（Markov Property）
強化学習ではエージェントの行動atによって
い、状態がStからSt＋1に遷移すると述べたが、
ここに環境に対して暗黙的にある仮定をおいて
いる（現在の状態Stから将来の状態St＋1へ遷移
する確率は、現在の状態Stにのみに依存し、そ
れより過去の状態には一切依存しない）の性質
一般に状態遷移にマルコフ性を仮定したモデル
のことを、マルコフ決定過程と言う
価値関数
状態価値関数（state-value function）
行動価値関数（action-value function）
TD学習（Temporal-Difference）
強化学習における価値関数を推定する手法
モンテカルロ法（MC）：実際の経験（エピソ
ード全体の報酬）を使って価値関数を更新
動的計画法（DP）：既存の価値の推定を利用し
て更新
逐次更新：各ステップで価値関数を更新可能、
エピソード終了を待たない
ブートストラップ：次の状態の価値推定を使っ
て現在の価値を更新
MCとDPの利点を統合：実際の経験から学習で
き、環境モデルがなくてもよい
価値関数もQ値（Q-value：状態-行動価値）と
も呼ぶ、それ以外V値（状態価値）もある
Q学習（Q-learning）：オフポリシー TD
「未来の最良の選択を常に仮定して学習する」
→ 攻めの学習
SARSA（State-Action-Reward-State-Action）：オンポリシー TD
「自分が実際に取った行動をもとに学習する」
→ 実際の行動に忠実な学習
方策勾配（Policy Gradient）
方策勾配法：直接最適な方策を見つけ出そうの
アプローチ
ロボット制御など、特に行動の選択肢が大量に
あるような課題で用いられる。
方策をあるパラメータで表させる関数として、
（累積報酬の期待値が最大となるように）その
パラメータを学習することで、直接方策を学習
していくアプローチ
REINFORCE
QやV値を学習ではなく、直接方策を学習
1. モンテカルロ法：軌跡全体が終了してから
累積報酬を計算
2. モデルフリー：環境の遷移モデルは不要、
サンプルのみで学習
3. 直接方策最適化：Q値を使わず、方策の確
率分布を直接更新
4. 高分散問題：累積報酬のばらつきが大きい
ため、通常 baseline（基準値）を使って分散を
減らす
Actor-Critic
行動器と方策を評価する評価器で構成、完治関
数ベースおよび方策勾配ベースの考え方を組み
合わせる
モデルの選択・評価
データの扱い
未知のデータに対しての予測能力を見る（準備
できないが、かわりに擬似的に未知のデータを
作り出す）
手元の全データを、学習用データ（訓練デー
タ）、評価用のデータ（テストデータ）にラン
ダム分割評価：交差検証も言う
ホールドアウト検証
事前にデータを訓練データとテストデータを分
割、（特に全体データ数が少ない場合）たまた
まテストデータに対する評価が不正に良くなっ
てしまう
k-分割交差検証
訓練データ・テストデータの分割を複数回行
う、それぞれで学習・評価を行うアプローチ
訓練データをさらに、訓練データと検証データ
に分割する場合もある、検証データで評価＆モ
デル調整でモデルを決定＋テストデータで最終
効果評価
評価指標
予測誤差（損失）：主に回帰問題に対しての
分類問題は明確に評価できるが、回帰問題は数
値そのものを予測するので、単純分けるの評価
はできないため導入する
平均二乗誤（mean squared error, MSE）
対象となる各データの予測値と実際の値の誤差
（差分）をそれぞれ2乗し（正負の誤差が打ち
消し合うを防止）、総和を求めたもの
二乗平均平方根誤差（root mean squared error,
RMSE）
平均二乗誤差のルートを取る
平均絶対値誤差（mean absolute error, MAE）二乗の代わりに絶対値を取る
正解率・適合率・再現率・F値：主に分類問題
に対しての
混同行列（confusion matrix）予測値と実際の値それぞれの組み合わせ
真陽性：True Positive：TP
偽陽性：False Positive：FP
真陰性：True Negative：TN
偽陰性：False Negative：FN
正解率（accuracy）：（TP ＋TN）／全データ全データ中、どれだけ予測が当たったかの割合
適合率（precision）：TP／（TP＋FP）
予測が正しいの中で、実際に正であったものの
割合
再現率（recall）：TP／（TP＋FN）
実際に正であるものの中で、正だと予測できた
割合
F値（F measure）：（2 x precision x recall）/
（precision + recall）
適合率と再現率の調和平均
過学習／過剰適合（overfitting、オーバーフィ
ッティング）
訓練データにのみ最適化されすぎ
ROC曲線とAUC
ROC曲線（receiver operating characteristic
curve）
TPR（True Positive Rate = Recall）を縦軸、FPR
（False Positive Rate）を横軸、閾値を0~1に変
換させった際の曲線
モデルの性能によって大きく変化するもの、モ
デルが全く予測ができない（ランダム予測）と
同じなら、ROC曲線は斜めの直線になり
AUC（area under the curve）
ROC曲線より下部の面積、1に近いほどモデル
性能が高いことを表す
モデルの選択と情報量
モデルを複雑にすればするほど複雑な表現がで
きる、逆に、表現しなくても良いノイズ部分ま
で表現してしまう（過学習）可能性もある
モデルが複雑になればなるほど、学習に必要な
計算コストも増えてしまうので、「ある事柄を
説明するためには、必要以上に多くを仮定する
べきでない」と言う指針を表すオッカムの剃刀
（occam’s razor／Ockham’s razor）
モデルとタスクの相性：情報量基準の指標を利
用
赤池情報量基準（Akaike’s Information Criterion,
AIC）
予測性能を重視 → データにうまくフィットす
るなら少し複雑でもOK
回帰モデル、多項式フィッティング、時系列予
測などのモデル選択
ベイズ情報量基準（Bayesian Information
Criterion, BIC）
モデルの正当性・単純さを重視 → サンプルが
多いと複雑モデルに強いペナルティ
統計モデル、因子分析、混合モデル、クラスタ
リングのモデル選択
ディープラーニングの概要
ニューラルネットワーク
ニューロン（神経細胞）をお互い結びつくこと
を神経回路、ニューロンを再現する。
単純パーセプトロン（Perseption）
1958年にフランク・ローゼンブラット（Frank
Rosenblatt）が提案した線形二値分類モデル
で、最も基本的なニューラルネットワー
複数の特徴量（入力）を受け取り、一つの値を
出力するモデル、単純すぎでほぼ実用されない
（線形分類しか解くことができない）
入力層
重み
出力層
ロジスティック回帰と数式上の表現は全く同じ
層の間をどのように伝播させるかを調整する関
数を活性化関数（シグモイド関数関数もその一
つ）
多層化パーセプトロン（MLP：Multi-Layer
Perseption）
入力層→隠れ層（中間層）→出力層
パラメータ：モデルが学習する数値
予測誤差を誤算関数、値最小化するの数学問題
となる
ハイパーパラメータ：モデルの構造や振る舞い
を決めるものの、最適化計算で求めない値のこ
と
ディープラーニング
隠れ層を増やしたニューラルネットワーク
実用性上、ニューラルネットワークモデル自体
をディープニューラルネットワークと呼ぶは大
半
ハードウェアの制約と進歩
モーラ定理
半導体の性能と集積は、18ヶ月ごとに2倍にな
る
CPU（Central Processing Unit）
さまざまな種類のタスクを順番に処理しておく
（ま〜誤解しやすい説明）
GPU（Graphics Processing Unit）
大規模な並列演算処理が得意
GPGPU（General-Purpose computing on
GPU）
元々画像処理に最適化されたものを、画像以外
の計算にも効率良く使えるように改良
TPU（Tensor Processing Unit）
テンソル計算処理に最適化、機械学習受に特化
した演算処理装置
ディープラーニングのデータ量経験則
バーニーおじさんのルール：モデルのパラメー
タ数の１０倍のデータ数が必要
現実性ではないもあるので、いろんなテクニッ
クで対処している
様々なアプローチ
誤差関数（損失関数）
平均二乗誤差関数
訓練データを用いてこの関を最小化する。（微
分＝導数（Derivative）を利用して最初値を導
く）
分類問題は別の関数が用いられるが、回帰問題
は大半誤差関数を利用している
交差エントロピー誤差関数（cross entropy）
２つの確率分布がどれくらい異なる過を定式化
したもの、分類問題で最も用いられる誤差関数
モデルの各クラスの予測値は0〜1の確率で表
現、正確値と予測値をそれぞれ確立分布として
捉えると、２つの分布が一致するときに最小値
を取る関数も
なぜ平均二乗誤算関数より人気のは、微分計算
に交差エントロピーの式がシグモイド関数やソ
フトマックス関数に含まれる指数計算と相性が
良いこと
特に以前自分で微分式を計算する時代は、計算
が簡単にできるかどうかはかなり重要
その他誤差関数
距離学習における誤差
距離学習（metric learning）：ディープラーニ
ング依存も存在、ディープラーニングを応用し
た手法を深層距離学習（deep metric learning）
と呼ぶ
データの類似度を推定、顔認識や類似データの
検索など様々な分野で利用している
深層距離学習
Siamese Network ２つデータを用いる、誤差はContrastive Loss
Triplet Network 3つデータを用いる、誤差はTriplet Loss
生成モデルにおける誤差
生成問題：画像や文章を生成する
（分類問題、回帰問題など問題…）
与えられたデータをうまく分けることができる
境界線を見つけるではなく、与えられたデータ
がどのような確率分布に基づいているかを見つ
けること。
「今観測できているデータは何らかの確率分布
に基づいて生成されているはずだ」の考え
データ分布とモデル分布の「ズレ」を誤算関数
として定義される
カルバック・ライブラー情報量（Kullback-Leibler divergence：KLダイバージェンス）
イェンゼン・シャノン情報量（Jensen-Shannon
divergence：JSダイバージェンス）
生成モデルをディープラーニングを活用したも
のは深層生成モデルと呼ぶ
例：変分オートエンコーダ（variational
autoencoder, VAE）では、KLダイバージェンス
をベースとして誤差関数（厳密は目的関数）が
最適化計算に用いられる
正則化（regularization）
過学習に対しての色々考えられる対策のこと
訓練データへの過剰な当てはまりを抑制しつ
つ、より単純なモデルが当てはまるようにする
ことを求め
誤差関数にペナルティ項を課すが一般的
誤差関数に制約条件を課すことによって、モデ
ルのパラメータが取り得る範囲を制限するアプ
ローチ
L0正則化
0ではないパラメータの数で正則化、計算コス
トが多くて一般用されない
L1正則化
L1ノルムは重みなどモデルパラメータの各成分
の絶対値の和
一部のパラメータの値をゼロにすることで、不
要なパラメータを削減することができる
L2正則化
L2ノルムは重みなどモデルパラメータの各成分
の二乗和の平方根なので距離に相当
パラメータの大きさに応じてゼロにちかずける
ことで、汎化された滑らかなモデルを得ること
ができる
ラッソ回帰線形回帰に対してL1正規化を適用する手法
リッジ回帰線形回帰に対してL2正規化を適用する手法
ElasticNet
ラッソ回帰とリッジ回帰を組み合わせ手法を利
用した
ドロップアウト（dropout）ランダムにニューロンを「除外する」
ドロップアウトより、違うネットワークで学習
させ、事実上内部的にアンサンプル学習となる
最適化手法
勾配降下法（gradient descent）
実際のモデルの学習では、解析的に解を求めに
行くのではなく、アルゴリズムを用いて最適解
を探索する、というアプローチである。勾配
（微分値＝導数）に沿って降りていくことで解
を探索する手法。
接線の傾き
微分値が勾配をあらわっしているの直感的な理
解
イテレーション k値を繰り返して計算した回数
学習率勾配に沿って一度にどれだけ降りていく
バッチ勾配降下法
全データの予測誤差の総和を用いて更新式の計
算を行うこと、単なる勾配降下法を書く場合バ
ッチ勾配を指すが一般
バッチ（batch）
データの固まりを表し、一回の更新にすべての
データ用いるためのような名前付け
データ全量で回すので、最急降下法とも呼ぶ
ただし、全データ扱うので、各層にメモリが消
費足りない可能
確率的勾配降下法（Stochastic Gradient
Descent， SGD）／オンライン学習
訓練データをシャッフルし、データを一つラン
ダムに抽出、そのデータの予測誤差だけを用い
て更新式を計算する
ニューラルネットワークの学習では、基本的に
全データをシャッフルした後、一つ一つのデー
タを結局すべて更新計算に用いることが大半
エポック：全データを用いる回数
イテレーション：誤差より更新計算の回数（オ
ンライン学習の場合、1エポック＝データ数分の
イテレーション）
ミニバッチ勾配降下法
すべてのデータをいくつかのデータセットに分
割する、各データセット内のデータ数のことを
バッチサイズと言う
一番多く使われる手法
データセット分のメモリのみ確保必要で、メモ
リ負担が相対的に低い
確率的勾配降下法のようにデータによって探索
方向がばらつくにも起こりにくい
1エポック＝ミニバッチ数分のイテレーション
勾配降下法の問題と改善
学習停滞：局所最適解になって、本当の最適解
のことの大域最適解をうまく取れない可能
学習率を大きくして、鞍点を超える手法があり
が、適切なタイミングで学習率を小さくしてい
くが必要。
鞍点
ある次元から見れば極小であるものの、別次元
から見ると極大になる点
プラトー（plateau）
一度鞍点付近に陥ちると、そこから抜け出すこ
とが困難になる、その停留状態であること
ディープラーニングではパラメータの次元が大
きい、鞍点が発生確率が高くなる。鞍点（そし
て局所最適解）に陥ちってしまう問題を回避す
るには、どの方向に沿って購買を進んでいると
きに学習率を大きく（あるいは小さく）すべき
かを考える必要
モーメンタム（momentum）
ディープラーニングより前、1990年代提唱され
たモーメンタム（momentum）：物理の慣性の
考え方を適用したもの、最適化の進行方向に学
習を加速させ、学習の停滞を防ぐものもある
Adagrad（Adaptive Gradient Algorithm）
過去の勾配の二乗和に基づきパラメータごとの
学習率を調整。よく更新されるパラメータほど
学習率を小さくする。
疎な特徴に強いが学習率がどんどん小さくなる
Adadelta（Adaptive Delta）
Adagrad の学習率減衰問題を解決。過去の勾配
二乗の累積ではなく、指数移動平均 (EMA) を使
う。
Adagradの減衰問題を改善、学習率不要
RMSprop（Root Mean Square Propagation）
Adadeltaと似て、勾配の二乗の指数移動平均で
スケーリングする。Hintonによる提案。
非定常目的関数で安定（RNNでよく使われる）
Adam（Adaptive Moment Estimation）
RMSpropのスケーリングに加え、**一次モーメ
ント（勾配の移動平均）と二次モーメント（勾
配二乗の移動平均）**を組み合わせ、バイアス
補正も行う。
デフォルト強力、収束速いが汎化性能に課題あ
り
AMSGrad（Adaptive Moment Estimation with
Long-Term Memory (AMSGrad)）
Adamの二次モーメント推定を「過去最大値」
に置き換え、単調性を保証し、非凸問題でも理
論的収束性を強化。Adamの不安定性を改善。
Adamで学習が不安定/収束しない場合利用
AdaBound（Adaptive Bound Optimizer
（Adam with dynamic bounds））
Adamの変種。学習率に上下限（動的境界）を
設け、学習の初期はAdamのように自動調整、
後半はSGDに近づく
Adamの速さ + SGDの汎化性能
AMSBound（AMSGrad with dynamic bounds）
AdaBoundの拡張で、Adamの代わりに
AMSGrad（Adamの安定化版）をベースに
し、学習率に動的境界を適用。
より安定なAdaBound
早期終了（early stopping）
学習が進むにつれてテストデータに対する誤差
関数の値が右肩上がりにっる時点で止める
ジェフリー・ヒントンも Beautiful FREE
LUNCH と表現している
ノーフリーランチ定理
あらゆる問題で性能の良い汎用最適化戦略は理
論上不可能
二重降下現象
一度テストデータに対する誤差が増えた後、再
び誤差が減っていくの現象、それで、どのタイ
ミングで学習をとめば良いかについては難しく
なる
ハイパーパラメータの探索
例
ニューラルネットワークの層数
各層のニューロン数
ドロップアウトの比率
L1、L2正則化はどれぐらい有効か
ハイパーパラメータチューニング
グリッドサーチ
調整したい（複数の）ハイパーパラメータの値
の候補を明示的にいくつかを指定し、その候補
のすべての組み合わせに対して学習・評価を行
う
ランダムサーチ
ハイパーパラメータの値の候補を指定するでは
なく、代わりに取り得る範囲を指定。その範囲
の中で何かしらの確率分布に基づいて乱数発生
して実験を行う
ベイズ最適化（Bayesian Optimization）
評価が非常に高コスト（例：ディープラーニン
グの学習、物理シミュレーション）
低次元向き（10〜50次元程度まで）
遺伝的アルゴリズム（Genetic Algorithm）
離散的なパラメータ・制約が多い・大域探索が
必要
高次元でも適用可能だが計算量増加
誤差逆伝播法（backpropagation）
複数のパラメータに対して微分を効率よく求め
るために考えられた、ネットワークの各層は、
その層に伝播してきた値は自分より前の層（入
力層に近い層）のパラメータの値が含まれてい
る（計算に使われている）ことに着目し、微分
計算を再利用することを考えている
合成関数の微分、あるいは連鎖率と呼ばれる微
分の公式を用いる、一つずつ計算より効率化さ
れた
勾配降下法を用いてニューラルネットワークの
学習をする際に、微分計算を誤差伝播法を用い
て効率よく行く
信用割当問題（credit assignment problem）を
解決できる
信用割当問題：モデルのどの部分がその予測結
果をもたらしているのかが変わらない問題
新しい挑戦
勾配消失問題誤差の逆伝播する過程で勾配が小さくなりすぎ
勾配爆発問題誤算の逆伝播する過程で勾配が大きくなりすぎ
バッチ正規化（Batch Normalization, BN）
各ミニバッチ内で層の入力xを標準化すること
で、各層の入力分布を安定させ、活性が飽和領
域（シグモイド・tanh関数の飽和領域）に行き
にくくすることで、勾配が0に近づくのを防
ぎ、勾配消失を緩和する
活性化関数
任意の実数を（非線形に）変換することができ
る関数でさえあれば、どんな関数であろうと活
性化関数として用いるのに特に問題ない
ステップ関数
閾値より0か1を出力する関数。微分は0のでデ
ィープラーニングはほぼ利用しない
シグモイド関数と勾配消失問題
シグモイドの微分した関数（導関数）は0〜0.25
（シグモイドの値区間は0〜1）、隠れそうを遡
るごとに、伝播していく誤差はどんどん小さく
なっていく
tanh関数（hyperbolic tangent）
値範囲は-1〜1、微分した関数（導関数）は0~1
それでシグモイド関数はほぼすべてtanh関数に
置き換えの方が良いになり
ReLU関数（Rectified Linear Unit）
値範囲は0~1、0以外の場合は0、0以上の場合は
0~1。微分は0以下0、0以上1。
ReLUを活性化関数に用いることによって、ディ
ープニューラルネットワーク全体をそのまま効
果的に学習できる場合が多くなり
tanh関数よりも、誤差逆伝播の際に勾配が小さ
くなりにくい、但し0以下の場合、微分は0にあ
るので、学習がうまくいかない場合もある
Leaky ReLU
値は0以下の場合、0ではなく、僅かな傾きを持
っている
ただし、実際には精度が出る時もあれば、ReLU
の方が良い場合もある
Parametric ReLU
Leaky ReLUの値が0以下の直線の傾きを学習に
よってい最適化
Randomized ReLU 複数の傾きをランダムに試す
ディープラーニングの要素技術
ネットワーク構成要素
畳み込み層（Convolution Layer）
フィルタ（カーネル）を用いて、特徴を特徴マ
ップとして抽出する畳み込み処理
フィルタと同じ位置のかけ合わせで総和処理で
特徴マップ抽出
パディング処理入力の上下左右に要素を追加、0の値で埋め
入力と同じサイズの特徴マップを抽出したい、
辺の特徴も抽出したいなどで利用する
ストライド（stride）フィルタを重ねる位置をずらす幅
Atrous Convolution／dilated convolution（膨張
畳み込み）
カーネルの各要素の間に「dilation rate（膨張
率）」だけ間隔をあけて適用、パラメータ数や
計算コストを増やさずに受容野（receptive
field）を広げることができる。
Depthwise Separable Convolution
空間方向とチャネル方向に対して独立に畳み込
み処理を行う
空間方向はDepthwise Convolution、特徴マップ
のチャネル毎に畳み込みを行う
チャネル方向はPointwise Convolution、１x１
（チャネル数の分を）の畳み込みを行う
普通の畳み込みは空間✖️ チャネル全体の中の
ブロックフィルタで畳み込み
プーリング層（Pooling Layer）
特徴マップをルールに従って小さくする処理、
ダウンサンプリングあるいはサブサンプリング
とも呼ばれる
最大値プーリング（max pooling）ある局所領域ごとの最大値を抽出する
平均値プーリング（average pooling）平均値を抽出する
特徴を集約して、特徴次元を削減する。プーリ
ング処理も畳み込み処理と同様、画像のズレに
対する頑健性を持ち、不変性を獲得
プーリング = 局所的特徴の要約 → 特徴マップ
の次元圧縮
局所平行移動へのロバスト性 → 不変性の獲得
（translation invariance）
全結合層（Fully Connected Layer / Dense
Layer）
層に入力された特徴に対して重みをかけて、総
和した値をユニットの値とする、通常のニュー
ラルネットワークと同じ線形関数です。
CNN（LeNet）
畳み込み層・プーリング層を繰り返した後、全
結合層を積層する。
従来型CNN（VGG, AlexNetなど）の分類層でよ
く使用
Global AveragePooling
特徴マップの平均値を１つのユニット（ニュー
ロン）の値にする
出力ベクトルの長さはチャンネル数と同じ
学習パラメータなし。モデルが軽量で過学習リ
スクが低い。
空間方向の情報を平均化するため、位置依存性
は失われる。
ResNetやMobileNetなど近年のモデルで広く採
用され、軽量化・汎化性能向上に貢献
正規化層
正規化処理
特徴の分布のばらつきを抑制するために、各層
の特徴の平均値が0、分散が１になるような処
理
バッチ正規化（Batch Normalization（BN））
各層で活性化関数をかける前の特徴的を正規化
（データを変形する）する、どのように変形す
れば良いかは学習によってい決める
チャネル数分正規化を行う
学習時、ミニバッチで複数の入力データ用い
て、各層において、データ間での特徴のバラツ
キをチャネル毎に正規化するように学習
バッチサイズはハイパーパラメータとして事前
に設定
レイヤー正規化データ毎に全チャネルをまとめて正規化バッチサイズ分正規化を行う
インスタンス正規化データ毎に書くチャネルを正規化チャネル数✖️ バッチサイズ分の正規化を行
う
グループ正規化データ毎に複数のチャネルをまとめて正規化複数インスタンスをグールプして正規化を行う
メリット学習がうまくいきやすく、過学習し難くなる
スキップ結合
「超」深層にすると、学習時に誤差を入力層近
くまで逆伝播しにくくなるため、層を飛び越え
た結合をする
ResNetで導入され
層が深くなっても、層を飛び越える部分は伝播
しやすくなる
様々な形なネットワークのアンサンプル学習に
なっている
出力層
リカレンとニューラルネットワーク
（Recurrent Neural Network, RNN）
時系列を扱うため、ネットワークの中間状態を
次の入力の処理に利用する回帰結合層を含むネ
ットワーク
入力層＋（過去の）回帰結合層→回帰結合→出
力層
エルマンネットワーク（Elman Network）
回帰結合層の情報を伝播して、次の時刻の入力
とともに利用するモデル
自然言語処理などで利用
ジョルダンネットワーク（Jordan Network）
出力層の情報を伝播して、次の時刻の入力とと
もに利用するモデル
ロボットの運動制御などで利用
代表例言語モデル（Language Model, LM）
音声処理でも自然言語処理でも利用できる、後
継のPretrained Modelsの基礎ともなっている
LSTM（LongShort-Term Memory）
RNNの課題
勾配消失問題
RNNは時間軸を展開すると深いニューラルネッ
トワークになるので、誤差を逆伝播する際に、
過去に遡るにつれて勾配が消えていってしまう
入力重み衝突
通常のニューラルネトワーク：関係ある情報を
入力された際は重みが大きくあるべきですし、
関係のない情報が入力された際は、重みは小さ
くあるべき
時系列では、「今の時点では関係ないけれど、
将来の時点では関係ある」という入力が与えら
れた際に、重みはは大きくすべきであり、同時
に小さくすべきであるの矛盾を抱える
出力重み衝突
通常のニューラルネットワークの活性化関数を
工夫するなどに対して、LSTMは回帰結合層の
構造を変えることで、勾配消失、重み衝突を解
決
LSTMブロック
通常のニューラルネットワークにおけるユニッ
トの一つがこのLSTMブロック
誤差を内部に留め、勾配消失を防ぐためのセル
セルはCEC（Constant Error Carousel）とも言
われ、
必要な情報を必要なタイミングで保持・消却さ
せるためのゲート
入力ゲート入力重み衝突防ぐのため
出力ゲート出力重み衝突防ぐのため
忘却ゲート
誤差が過剰にセルに停留するのを防ぐのため、
リセットの役割を果たす
LSTMは時系列データを扱う上ではデファクト
スタンダード（暗黙的な標準）になっているモ
デルとも言える
LSTMはセルやゲートそれぞれを最適化が必要
で、計算量が多く必要になる
GRU（Gated Recurrent Unit）
リセットゲート、更新ゲートが「入力ゲート、
出力ゲート、忘却ゲート」の代わりを果たし
Bidirectional RNN
課題例：時間情報の途中が欠けていてそれが何
かを予測したい場合は、過去の情報だけでな
く、過去と未来両方の情報を使って予測した方
が効果的と言える
自然言語においては例えば単語の品詞を推定し
たい場合などは、過去の単語だけではなく未来
の単語情報も用いる方が高精度に行える
通常のRNNは過去から未来への一方向でしか学
習することができないに対して、RNNをふたつ
組み合わせ流ことで、未来から過去方向も含め
て学習できるようなモデル
２つのRNNを組み合わせと言っても、それぞれ
は過去用と未来用とで独立しているので、取り
立てで複雑などところもない
エンコーダ・デコーダ
入力が時系列、出力が一つではなく、入力が時
系列なら、出力も時系列で予測したいものを、
Seq2Seq（sequence-to-sequence）
RNN エンコーダ-デコーダ
類似に２つのRNNをくみあわせて、入出力どち
らもRNNで対応する
エンコーダ入力データを処理して符号化
デコーダ
符号化された入力情報を使ってデコーダが復号
化
出力も時系列のため、全出力を一気に行うこと
は不可能、デコーダは自身の出力が次のステッ
プで入力として受け取って処理すること
RNNの学習
通常のニューラルネットワークと同様に、入力
層から回帰結合層に情報が伝播する経路がある
RNNは過去の回帰結合層から（現在の）回帰結
合層にも情報を伝播する経路を持つ
すなわく、これまでに与えられた過去の情報を
どの程度現在の情報に反映することが学習する
内容。誤差を過去に遡って逆伝播
BPTT（BackPropagation Through-TIme）時間軸に沿って誤差を反映していく
出力層をSoftmax函数で確率に変換し、正解と
の誤差を計算して誤差逆伝播によってパラメー
タの調整を行う
教師強制（Teacher Forcing）
正解データを次の入力データとして利用するこ
と
機会翻訳でもデコーダへの入力として正解の翻
訳文を利用するので、教師学習を利用している
RNNだけではなく、入力系列と出力系列が同じ
場合には利用できるので、トランスフォーマー
学習などでも利用している
露出バイアス（Exposure Bias）
テスト時は教師強制利用できないので、訓練時
とテスト時で入力データの傾向に違いが出る、
テスト時では訓練時ほどのパフォーマンスがで
ない問題
こちらは、言語生成AIにおける繰り返し
（repetition）、矛盾（incoherence）、ハルシ
ネーション（hallucination）などのエラーの原
因の一つ
Attention
誕生背景：RNNは（LSTMにしろ、GRUにしろ）
１つ前の状態と新たな入力から次の状態を計算
するだけであり、過去の（BiRNNでは過去と未
来）どの時刻の状態がどれだけ次の状態に影響
するまでは直接まとめていない
「時間の重み」をネットワークに組み込んだの
がAttentionと呼ばれる機構です
過去の各時刻での回帰結合層の状態を保持して
おき、それぞれの重みを求め、出力を計算する
際に回帰結合層の状態を重み付き和を利用する
ことで、時間の重いを考慮したモデルを実現
入力と出力の対応関係「時間の重み」を可視化
も可能
Seq2Seqは長くなればなるほど全体の情報を適
切に保持することができなくなり、Attention機
構の導入で過去の情報を適切に重み付けして用
いることが可能となり、長文であっても正確な
翻訳が出力できるようになった
トランスフォーマー（2017：Google）
RNNの課題
機械翻訳モデルでは、それぞれRNNで構成され
たエンコーダとデコーダをAttention機構により
橋渡ししたような構造を持っている。
Source-Target Attention／Encoder-Decoder
Attention
入力文（source）と出力文（target）の橋渡し
に使われるAttention機構
欠点
入力データを時間軸に沿って必ず１つずつ順番
位読み込む逐次処理が必要→並列計算できず、
処理速度が遅くなり
時系列の最初の時刻に入力した情報の影響が時
間の経過とともに次第に薄れてしまう
エンコーダとデコーダからRNNを排除し、代わ
りにSelf-Attention（自己注意機構）と呼ばれる
ネットワーク構造を採用
ネットワーク全体をSelf-AttentionとSource-Target Attentionの２つ機構のみから構成され、
並列計算がしやすく、RNNと比べる高速にモデ
ルの学習が行える
Self-Attentionでは遠い位置にある単語同士の関
係もうまく捉えることができる
Self-Attention（自己注意機構）
Source-Target Attentionが入力文と出力文の単
語間の関連度を計算したものに対し、Self-Attentionは入力文内の単語間または出力文内の
単語間の関連度を計算したもの
RNNで入力文内の単語間の関係計算にはその間
にある単語数分のステップが必要に対し、Self-Attentionでは入力文内のすべての単語間の関係
を１ステップで直接計算することが可能
ある単語と他の単語との間の関係計算は、別の
ある単語とその他の単語との間位の関係計算と
は独立するので、すべての計算が並列に行え、
高速に処理できる
単語間の関係を直接計算できるが、語順の情報
が失われる。それに対してトランスフォーマー
は、位置エンコーディング（positional
encoding）と呼ばれる単語の出現位置に固有の
情報を入力に付加することで、ニューラルネッ
トワークは間接的に単語の位置情報や単語間の
位置情報を考慮することができる
デコーダはSource-Target Attentionにより入力
文の情報も利用
エンコーダでは入力入力文のすべての単語を見
ながら計算を行う、デコーダでは先頭から順に
出力ので、未来の情報は使えいない。
そのため、デコーダで翻訳文を生成するプロセ
スは並列化できない
ただし、訓練時には正解の翻訳を与えられるの
で並列計算はできる
QKV（クエリ、キー、バリュー）
２種類のAttentionとも、Q ,K,Vより計算してい
る。QKVそれぞれの値はベクトりもしくはベク
トリをまとめた行列
構造図
エンコーダの一層分
入力＋位置エンコーディングでのQKVをMulti-Head Attention（Self-Attention）に入力して、
デコーダのKVを生成する
デコーダの一層分
過去の出力＋位置エンコーディングでのQKVを
Multi-Head Attention（Self-Attention）に入力
して、デコーダのQを生成する
上記ふたつより生成されたKVQより、Multi-Head Attention（Source-Target Attention入力
して、デコーダの一層分の出力を算出する
詳細は論文：Attention Is All You Need
Multi-Head Attention
Attentionの計算を複数並列行う、各Attentionの
計算をHeadと呼ぶ、目的は多視点で異なるパタ
ーンでクエリとキーとの関係を見る
クエリ、キー、バリューの値が同じなら計算は
無駄になるため、そこでこれらの３つの値をそ
れぞれ異なる全結合層に通じて変形する、さら
にHeadの数だけ異なる全結合層を用意する
オートエンコーダ
基本的なオートエンコーダ
可視層（入力層＝出力層）と隠れ層の二層から
なるネットワーク
入力層の次元よりも、隠れ層の次元を小さくし
ておくことで、入力情報が圧縮されたもの
エンコーダ入力層→隠れ層
デコーダ隠れ層→出力層
教師なしの学習として、画像ノイズ削減など利
用している
積層オートエンコーダ（stacked autoencoder）
ディープラーニングの黎明期考えられた手法、
DPの祖であるジェフリー・ヒントン考えたもの
で、文字通りエンコーダを「積み重ねる」
A→B訓練後、続いてB→Cへ訓練のような順番
的に学習していく。それぞれで隠れそうの重み
が調整されるので、全体で見ても重みが調整さ
れたネットワークができる、このオートエンコ
ーダを順番に学習していく手順のことを事前学
習（pre-training）と呼ばれる
ただし、現在はこの「事前学習」は移転学習の
文脈で用いられることが大半
変分オートエンコーダ（Variational Auto-Encoder, VAE）
従来のオートエンコーダは、入力と出力が同じ
ようにするような学習を行う、隠れ層は入力デ
ータ（の特徴）をうまく圧縮表現したもの
変分オートエンコーダは入力データを圧縮する
ではなく、統計分布（平均と分散）に変換す
る。
入力データ（画像）に何かしらの分布に基づい
て生成されているものだとしたら、その分布を
表現するように学習すれば良いの考えです。
エンコーダは統計分布のある一つの点なる潜在
変数に変換、デコーダは統計分布からランダム
にサンプリングした１点を復元すること
VQ-VAE 潜在変数を連続値ではなく離散値にする
infoVAE
潜在変数とデータの相関を高めることで生成の
精度をあげる
ß-VAE
VAEの目的関数において正則化を工夫すること
で画像の特徴を潜在空間上でうまく分離し、画
像生成を行いやすくする
ディープラーニングの応用例
画像認識
畳み込みニューラルネットワーク
（Convolutional Neural Network, CNN）
RGB画像は縦と横だけではなく、奥行き（チャ
ネル：色情報など）を持つ三次元ものに敵した
構造として考えられたネットワーク
ネオコグにトロン（Neocognitron） 1980年福島邦浩
人間が持つ視覚野の神経細胞の２つの働きを模
してみようという発想から生まれた
単純型細胞（S細胞）：画像の濃淡パターン
（特徴）を検出する
複雑型細胞（C細胞）：特徴の位置が変動して
も同一の特徴であるとみなす。
入力層→コントラスト抽出→エッジ抽出→…→
高次特徴抽出→…→認識細胞層
LeNet 1998年ヤン・ルカン
畳み込み層とプーリング層（またサブサンプリ
ング層）の２種類の層を複数組み合わせた構造
S細胞⇄畳み込み層
C細胞⇄プーリング層
微分（勾配計算）を用いないadd-if slientと呼ば
れ学習法⇄誤差逆伝播法
データ拡張（data agumentation）
手元にあるデータから擬似的に別のデータを生
成するアプローチ
上下左右にずらす
上下左右を反転する
拡大・縮小をする
回転をする
斜めに歪める
一部を切り取る
ノイズを加える
・・・
一方、闇雲にすべての処理を処理を施さないよ
うに注意が必要（例：親指をあげていいねのや
つを上下回転すると。。。）
二つデータを合成する Mixup
データの一部の値を０にする Cutout
データの一部の値をランダムにする Random Erasing
RandAugment
どのようなデータ拡張の処理をどのぐらいの強
さで行えば良いか自体により決める
CutMix
物体認識タスク
入力画像に対してその画像に映せる代表的な物
体クラスの名称を出力するタスク。
識別対象としている物体クラス全てに対して確
信度を出力する、その確信度が最も高い物体ク
ラスを識別結果として出力する
ILSVRC：画像認識の精度を競うコンペティショ
ン
AlexNet 2012年優勝
畳み込み層→プーリング層→畳み込み層→プー
リング層→畳み込み層x３→プーリング層→全
結合層x３
AlexNet以降、畳み込み層とプーリング層の繰
り返しをさらに増やした、より深いネットワー
クのモデルが続々登場
ZFNet 2013年優勝
VGG（Visual Geometry Group, Oxford） 2014年準優勝
畳み込み層→畳み込み層→プーリング層の塊を
繰り返し、16層まで積層している。
各畳み込み層のフィルタサイズを３x３へ統一
し、プーリングを行った次の畳み込み層からフ
ィルタ数を２倍に増やすというシンプルな基本
設計を採用していた
深くなっても学習できるよう、一旦少ない層数
で学習した後、途中に畳み込み層を追加して深
くする学習手法
GoogLeNet 2014年優勝
層を深くするだけではなく、同時に異なるフィ
ルタサイズの畳み込み処理を行うInceptionモジ
ュール
着目する範囲が異なる特徴を合わせて捉える
ネットワークの途中に認識結果を出力する層を
追加し、学習時に誤差を逆伝播する補助的な機
構を導入している
2015年優勝
ResNet
152層の「超」深層でtop-5 error 約3.6%、人間
の識別精度（エラー率大凡5％）を超えてい
る。（但し、ILSVRCテストの1000クラス以外で
は人間のように識別できない）
残差接続（skip connection）：y=F(x)+x このアイデアだけで、深いネットでも誤差がス
ムーズに逆伝播でき、学習が安定
フィルタ数を増やす WideResNet
スキップ結合を工夫 DenseNet
SENet（Squeeze-and-Excitation） 2017年優勝
畳み込み層を出力した特徴マップに重みつける
Attention機構を導入（汎用的なアイデア）
10〜20までの深さで、さらに「超」深層になる
と識別制度が落ちる
MobileNet
畳み込み層に深層分離畳み込み（Depthwise
Separable Convolution）をしている
各チャネルごとに空間方向の特徴抽出 Depthwise Convolution
チャネル方向に情報を融合（線形結合） Pointwise Convolution
Neural Architecture Search（NAS）
リカレンとニューラルネットワークと深層強化
学習を用いてネットワーク構造を探索する。
RNN出力した各層のフィルタサイズやフィルタ
数などを元にネットワークを作成し、学習およ
び評価する。それで、認識精度が高くなるよう
に深層強化学習によりネットワークを生成する
部分を学習する
NASNet（2017）
生成する単位をResNetのResidual Blockのよう
な塊にする工夫を導入
MnasNet（2018）
認識制度だけでなくモバイル端末での計算量を
考慮する工夫を導入
EfficientNet（2019）
ネットワークの「深さ」「幅」「解像度」をバ
ランスよくスケーリングする方法
物体検出タスク
入力画像に映せる物体クラスの識別とその物体
の位置を特定するタスク
位置特定とクラス識別２段階で処理
R-CNN（2014, Region-based CNN）
画像から物体候補領域Selective Search（セグメ
ンテーションの方法）で抽出，大凡2000区域抽
出
物体候補領域を一体のサイズにリサイズして、
CNNに入れて、判定は最上位層の一つ前の層
（FC層）を特徴ベクトルとし、サポートベクタ
ーマシン（SVM（one-vs-all））によりクラス
識別を行う
物体候補領域ごとにこのような識別処理を行う
ため、処理時間がかかる
Fast R-CNN（2015）
画像全体を入力して特徴マップを獲得すること
で高速化する、特徴マップ上で物体候補領域に
相当する部分を切り出し、識別処理を行う
Faster R-CNN（2015）
Fast R-CNNまで利用していたSelective Search
をRegion Proposal Network（RPN）というCNN
モデルに置き換えてさらに高速化するモデル
RPNで並行できるようにGPUより一気に加速さ
れた、Fast R-CNNの2秒/図より、0.2秒/図まで
改善
Mask R-CNN（2017）
インスタンス分割のマスク枝を追加、FPN によ
りマルチスケール検出が向上
位置特定とクラス識別を１段階で処理
FPN（2017）（Feature Pyramid Network、特徴
ピラミッドネットワーク）
R-CNN 系列の性能を強化するモジュール、
Mask R-CNNと同じ年の2017FaceBookから提
出、よく一緒に利用してインスタンス分類を利
用している
異なる層の特徴を上下に融合して、小さい物体
には高解像度、大きい物体には意味情報豊富な
特徴を提供する
YOLO（You Only Look Once）
出力層を工夫して入力画像の各位置における物
体領域らしさと矩形領域を直接出力する仕組
み、各位置は入力画像の画像単位ではなく、グ
リッドに分割した領域単位にとって、らしさを
判別する
SSD（Single Shot MultiBox Detector）
CNNの途中の特徴マップからYOLOのように領
域単位で物体らしさと矩形領域を出力する
なぜ、特徴マップは段々小さくなるので、途中
のも利用することで、小さいな物体も検出しや
くすなり、かつデフォルトボックスのパターン
を複数用意しておくことで、縦長や横長の物体
を検出しやすくなる
画像の画素ごとに識別を行うタスクセグメンテーションタスク
セマンティックセグメンテーション（semantic
segmentation）
集団の歩行者などを一人一人分離できない同一クラスの物体を一まとめする画像全体を対象とする識別
インスタンスセグメンテーション（instance
segmentation）
物体検出した領域を対象とする識別
物体検出した領域に対してセグメンテーション
を行う
一人一人分離できる
パノプティックセグメンテーション（panoptic
segmentation）
個々の物体をそれぞれ分離しつつ、道路や建物
などはひとまとめにする
FCN（Fully Convolutional Network）
全結合層を用いず、畳み込み層だけで構成する
モデルを採用、最後の特徴マップの１つの画素
は入力画面の広い範囲の情報集約しているの
で、１画素ごとにクラス識別ができるようにな
り
SegNet（Segmentation Network）
畳み込み層とプーリング層を繰り返し積層する
ことで小さく（エンコーダ）なった特徴を徐々
に拡大する（デコーダ）構造を採用する方法
エンコーダ側の最大値プーリングした位置を記
憶して、デコーダ側の拡大時に記録していた位
置に特徴マップの値を配置して、それ以外は０
にする。境界付近のセグメンテーション結果を
ぼやけさせない工夫している
VGGスタイルの畳み込み＋プーリング
U-Net
データ側で特徴マップを拡大して畳み込み処理
する際にエンコーダ側の特徴マップを同じサイ
ズになるように切り出して利用
X線画像（CT、MRIなど）の医療画像診断に用
いられている。SegNetに比べると精度が高い
通常は３x３畳み込み＋ReLU（Rectified Linear
Unit）＋プーリング
PSPNet（Pyramid Scene Parsing Network）
エンコーダとデコーダの間にPyramid Pooling
Moduleという複数の解像度で特徴を捉えるモジ
ュールを追加
特徴を異なるサイズでプーリングし、それぞれ
の大きさで畳み込み処理を行い
DeepLab（2014-2015）
広い範囲の情報を集約するため、畳み込み層に
は、Atrous convolution（Dilated Convolution）
を利用導入したモデルをDeepLab
DeepLab V3+（2018）
SegNetやU-Netのようなエンコーダとデコーダ
の構造、PSPNetのような複数解像度の特徴を捉
える機構（ASPP：Atrous Spatial Pyramid
Pooling）を採用したモデル
姿勢推定タスク
人の頭や足、手などの関節位置を推定するタス
ク
Convolutional Pose Machines
CNNを多段に組み合わせて徐々に各骨格のの信
頼度マップを高精度化、多段組み合わせで着目
範囲も広げて行き、人の全体の構造を考慮して
各骨格の位置を推定する
OpenPose
複数の人の骨格を同時に推定できるようにした
手法
骨格間間の位置関係を考慮した処理を導入 Parts Affinity Fields
YOLO、Faster R-CNN、Mast R-CNNなど複数のタスクを一つのモデルで対応できることマルチタスク学習
音声処理
音声データのコンピュータでの扱い
A-D変換（Analog to Digital Conversion）
パルス符号変調（Pulse Code Modulation,
PCM）
連続的な音波を一定時間ごとに観測する標本化
（サンプリング）
量子化
観測された波の強さをあらかじめ決められた値
に近似する量子化
量子化された値をビット列で表現する符号化符号化
高速フーリエ変換（Fast Fourier Transform,
FFT）
非常に短い時間ごとに周波数解析を行う必要で
の変換アルゴリズム、FFTにより音声信号は周
波数スペクトル（spectrum）に変換
メル尺度（mel scale）
人間が感じる音の高低に合わせた尺度、メル尺
度の差が同じであれば、人間が感じる音の差も
同じであるように定義している
人間の聴覚は低周波領域の周波数の違いには敏
感であるのに対して、高周波領域では鈍感であ
ると言われる。
メル尺度は大量な心理学試験で取得された統計
的な尺度
音色
同じHzの音の違いを認識する
楽器の音色は高調波成分（こうちょうはせいぶ
ん）できまる
高さ（Hz）、長さ（横長）、強さ（縦長）
全く同じ音（音色）であっても、異なるところ
を識別するもの
スペクトル包絡（スペクトル上の緩やかな変
動）
音色の違いの周波数スペクトル
デファクトスタンダード
メル周波数ケプストラム係数（Mel-Frequency
Cepstrum Coefficients, MFCC）
入力された音のスペクトル包絡に相当する係数
列を得られる、これは音色の特徴量となるもの
フォルマント周波数
スペクトル崩落を求めるといくつかの周波数で
ピックを迎えることがわかる、そのピックをフ
ォルマントと呼ぶ、
入力された音色の音韻（言語によらず人間が発
声する区別可能な音）が同じであれば、フォル
マント周波数は近い値となる。個人差により多
少ズレが発生する
音声データをテキストに変換して出力する技術 Speech-to-Text（STT）音声認識
一般的な音声認識器は音響モデルと言語モデル
の二つ、および単語と単語を発現した時の音素
（言語ごとに区別される音の最小単位）列をペ
アにした辞書で構成される
音響モデル
ある単語列を発声した時に、それに対応する音
素列がどれぐらいの確率で観測されるかを表す
確立モデル
音素，耳で音を聞き分ける部分
隠れマルコフモデル（Hidden Markov Model ,
HMM）
音素ごとに学習しておく、さまざまな単語の認
識に対応できる
単語を認識する際にはあらかじめ定義された単
語と音素列の対応辞書により音素列に変化し、
音素列に従ってHMMを連結することでモデル化
する
音響モデルとしてはHMMの他にも混合正規分布
モデル（Gaussian Mixture Modle , GMM）や、
CNNやRNNなどのニューラルネットワークも用
いられる
RNNを用いて音声データを時系列音素出力に
は、発音しない間は対応が必要
Connectionist Temporal Classification（CTC）
出力候補として音素に加えて空文字を追加し、
さらに連続して同じ音素を出力した場合は一度
だけ出力したものと縮約する処理を行い、これ
により、出力の長さと正解の長さが違う場合で
も処理できる
言語モデル
ある単語列はどのぐらいの確率で出現するかを
表す確率モデルで、単語列の文章としての自然
さを表している
言葉の流れ，脳で自然な文章に直す部分
n-gram言語モデル
ある単語が出現する確率を、それより前のN-1
個の単語が出現したという条件のもとでの条件
付き確率の積として計算される
最近RNNやトランスフォーマーなどのニューラ
ルネットワークを用いた言語モデルも広く利用
される
End-to-End 音声データから直接単語列を生成する音声認識
モデル
感情分析
機械がより適切な応答を返すために、人間の音
声の感情分析を行う
自動議事録作成では誰の発話かを推定する話者識別
音声認識器に音声データが入力されると、辞書
に格納された情報から考える数多くの音素列お
よび単語列が生成される、それぞれが音響モデ
ルおよび言語モデルによってスコア付けされる
この二つのスコアを統合して最も良いものが最
終的な音声認識結果として出力される
テキストを音声に変換して出力する技術 Text-to-Speech（TTS）音声合成
従来
テキストの形態素解析、読み推定、読みから音
素列への変換、音素列から音声は波形の生成な
どのいくつかのステップを経て実現
音声波形は、ある話者のさまざまな音素の波形
をあらかじめデータベース化しておき、これら
を組み合わせて音声合成を行う波形接続方式
と、音の高さや音色などに関するパラメータを
HMMなどによって推定し、これを元に音声を合
成するパラメトリック方式の２つがある（前者
より合成の質が低い）
2016年：WaveNet By DeepMind
ディープラーニングを用いたパラメトリック方
式の音声合成モデル
周波数スペクトルなどの変換はせず、量子化さ
れた状態のままニューラルネットワークで処理
することで、音声合成の質を劇的に向上させた
自然言語処理
テキストデータの扱い方
テキストデータの表現
単語n-gram
文字列を複数個の単語を並べたものとして表現
できる
n=1：ユニグラム（uni-gram）
n=2：バイグラム（bi-gram）
n=3：トライグラム（tri-gram）
Bag-of-Words（BoW）
単語の集合として表現する、BoWでは単語がバ
ラバラに保存され、出現順序の情報は失われる
Bag-of-n-grams
局所的な出現順序が重要な意味を持つ場合もあ
る
ID化
ニューラルネットワークは数値列（ベクトル）
しか扱えない、各単語に異なる整数値を順に割
り当て
ワンホットベクトル（one-hot vector）
IDに相当するベクトルの次元の値だけが１で他
が全て０となっている
TF -IDF（Term Frequency-Inverse Document
Frequency）
TF：１つの文章内での単語の出現割合（単語の
頻度を文章内の全単語数で割ったもの）であり
IDF：ある単語が出現する文章の割合（ある単語
が出現する文章の数を全文章数で割ったもの）
の逆数をとり、さらに大数をとったもの
TF-IDFはTFとIDFの値を掛け合わせたもの、１
文章内で出力回数が多く、出現する文章の数が
少ない単語lほど大きな値となるため、TF-IDFの
値の大きさがある程度その単語の重要度を表し
ている
局所表現（local representation）単語埋め込み（word embedding）
ワンホットベクトルは値が０か１しかなく離散
的で、１を取る次元が１つしかないため情報が
疎であり、次元数が単語の種類数と等しい、非
常に高次元となっている
局所表現では単語同士の意味の近さを考慮され
なく、局所表現を連続的（実数値全体を取る）
で、情報が密であり（値が０である次元が少な
い）、次元数の低いベクトルに変換することを
かんがえる。このような単語の表現を分散表現
（distributed representation）や単語埋め込み
（word embedding）と呼ぶ
word2vec
単語を分散表現で表すことで、ベクトル間の距
離や位置関係から単語の意味を表現する代表的
な手法
単語の意味は、その周辺の単語によって決まる
という分布仮説と呼ばれる言語学の主張をニュ
ーラルネットわーくとして実現
例の　王様ー男性＋女性＝女王
手法
ある単語を与えて周辺の単語を予測するモデルスキップグラム（skip-gram）
周辺の単語を与えてある単語を予測するモデル CBOW（Continuous Bag-of-Words）
どちらも中間層のニューロン数の次元を持つ実
数ベクトルをその単語の意味を表現とみなす
fastText
単語埋め込みを学習する際に単語を構成する部
分文字列の情報も含めること。部分文字列の情
報を併用することで訓練データには存在しない
単語（Out Of Vocabulary, OOV）出会っても単
語埋め込みを計算したり、活用する単語の語幹
と語尾を分けて考慮したりすること
学習に要する時間が短い特徴を持っている、ウ
ィキペディアとコモンクロールを用いて訓練し
た世界中の１５７言語によるそれぞれの訓練済
みデータを提供している
文脈を考慮した分散表現を得る手法 ELMo（Embeddings from Language Models）
事前学習モデル（Pre-trained Models）
事前学習＋移転学習
画像認識分野では以前から、VGG16などのよう
に大規模なデータで事前学習したモデルを基
に、特定のカテゴリの小規模なデータを使って
移転学習で、小規模でも高精度に行うが可能
GPT（Generative Pre-Training）：2018
OpenAI開発、事前学習として行うのは大規模
なコーパスを用いた言語モデルの学習、トラン
スフォーマーのデコーダと似た構造を持つ
パラメータ数は約１億
BERT（Bidrectional Encoder Representation
from Transformers）：2018
Google社開発した、トランスフォーマーエン
コーダを利用、エンコーダは入力された全体が
見えている状態ので、通常学習の言語モデルに
より学習は行えない
Masked Language Model（MLM）
文内の単語のうちの一部をマスクして見えない
ようにした状態で入力し、このマスクされた単
語を予測させる学習タスク
Next Sentence Prediction（NSP）
2つの文を繋げて入力し、2つの文が連続する文
かどうかを判定する学習タスク
移転学習さまざまな応用タスクを解くことがで
きる。さらに各単語の最終状態を使って品詞タ
グ付けや固有表現解析を行ったり、SQuAD
（Stanford Question Answering Dataset）のよ
うな回答の範囲を予測するタイプの質問応答タ
スクも解ける
パラメータ数は約３億
AlBERT、DistilBERT
タスクの精度を落とさずにパラメータ数を削減
する
大規模言語モデル（LLM）
15億 GPT-2（2019年2月）
GPTでは行えなかった機械翻訳などの言語生成
タスクも行えるようになった
NAVIA 80億 Megatron-LM（2019年9月）
Microsoft 170億 Turing -NLG（2020年2月）
GPT-3（2020年5月）
様々な言語生成タスクが非常に高精度に行える 1750億
別話題
CNNを使わない新たな慈善がクシュモデルであ
るVision Transformer（ViT）も2020年登場
ChatGPT（2022年11月）
これまでのテキストデータからの言語モデルの
学習だけでなく、生成された応答が適切かどう
かを人間が判断し、その判断結果から強化学習
を用いることで、より高精度な応答を生成する
ことができる（RLHF、Reinforcement Learing
from Human Feedback）と呼ぶ
その後
PaLM→PaLM2→Gemini Google
Chinchilla DeepMind
LLaMA メタ
1兆パラメータを超えるPanGu -Σも出ている
自然言語処理のタスク
評判分析（sentiment analysis）
与えられた文をGPTに入力し、入力し終わった
最後の状態を使って、入力された文の極性
（positive, negative, neutral）を判定する
自然言語推論（Natural Language Inference,
NLI）
与えられた２つの文書の内容に矛盾があるか、
一方が他方を含意するかなどを判定するタス
ク。含意関係認識（Recognizing Textual
Entailment, RTE）とも呼ばれる
質問応答（question answering）
文章とこれに関する質問文が与えられ、適切な
回答を選択肢の中から選ぶタスク。しばしば常
識推論（commonsense reasoning）が必要
意味の類似度（semantic similarity）判定
文書分類（document classification）
与えられた文書がどのクラスに属すかを予測す
るタスク。評判分析タスクも文書分類の一種
GLUE（General Language Understanding
Evaluation）
様々な言語理解タスクをまとめたベンチマー
ク、世界中の研究者がこのデータセットでの精
度を競っている
文法が正しいかどうかの判定
感情分析（ポジティブかネガティブか）
2つの文が同じ意味かどうかの判定
含意関係認識
質問応答
さらに複雑なタスクを扱う SuperGLUE
日本語に特化した JGLUE
深層強化学習（deep reinforcement learning）
ディープラーニングと強化学習を組み合わせ手
法
2013 基本手法であるDQN（Deep Q-Network）
がDeepMind社から発表され
DQNは、Atari社が開した家庭用ゲーム機
Attari2600の多種多様なゲームを人間並や超え
る
2020年前半、DeepMind社から発表された
Agent57と呼ばれる手法で、５７ゲーム全てで
人間のスコアを超えるようになった
Q学習（1992年）では、ある特定の状態に対し
て1つの行動価値（Q値）を割り当てて、その行
動価値に対する学習を行う。実世界には非現実
的なところが多く
DQNは、ゲームや実世界の画像をそのままディ
ープニューラルネットワーク（畳み込みニュー
ラルネットワーク）の入力として、行動候補の
価値関数や方策を出力として学習するアプロー
チ
経験再生（experience replay）
環境を探索する過程で得た経験データをリプレ
イバッファと呼ばれる機構に保存し、あるタイ
ミングで、これらの保存データをランダムに複
数抜き出してディープニューラルネットワーク
の学習に使う手法
学習に使うデータの時間的偏りをなくし学習の
安定を図る
ターゲットネットワーク
現在学習しているネットワークと、学習の時間
的差分がある過去のネットワークに教師のよう
な役割をさせる手法
これにより価値推定を安定させる
ダブルDQN（double deep q-network）
経験再生やターゲットネットワークの使い方を
工夫した
「点数をつける人」と「実際にその行動を選ぶ
人」を分けて、冷静に判断できるようにする。
優先度付き経験再生（prioritized experience
replay）
凡ミスより、大失敗や大発見を強く記憶して、
繰り返し復習する
デュエリングネットワーク（dueling network）
ある状態では「どの行動をしても結果がほとん
ど同じ」ことがある。
Q値を 「その状態の価値 (V)」＋「各行動の相
対的な優位性 (A)」 に分解して学習。
カテゴリかるDQN（categorical deep q-network）
Q値を「分布（確率分布）」として学習。例え
ば「この行動で +10点になる確率50%、-5点に
なる確率30%…」みたいに扱う。
ノイジーネットワーク（noisy network）
ε-greedy（ランダムに行動する手法）は単純す
ぎて探索効率が悪い。
ニューラルネットのパラメータ自体に「ノイ
ズ」を注入して、自然に探索を促す。
報酬の伝播を速める N-step Return
すべてを組み合わせた手法：Rainbow（2017：
DeepMind）
すべての優秀な点を取り扱うで飛躍的に性能が
向上した
Rainbow以降も、複数CPUやGPUを使って学習
を行う分散型強化学習により学習の収束速度が
飛躍的に向上
内発的報酬（intrinsic reward）
極めて難易度が高いゲームにおいても人間以上
のパフォーマンスを発揮
深層強化学習とゲームAI
DP登場後、評価関数の部分をディープニュー
ラルネットワークで置き換え、加えて、深層強
化学習と従来のゲーム木の探索、またその他の
ディープラーニングを使った画像認識や系列処
理の手法を取り入れることでゲームAIは飛躍的
な性能向上できた
代表的な手法やゲームAI
ボードゲームにおけるゲームAI
２人完全情報確定ゼロ和ゲーム
行動を選択する時点で、盤面の状態や相手の持
ち駒などのゲームに関する情報が全てプレーヤ
ー側で把握できる、かつ、一方が勝てば他方が
負けるゼロ和性、偶然の要素がないゲーム
モンテカルロキー探索（2000年代前半考案）
複数回のゲーム木の展開によるランダムしミュ
ーレション（プレイアウト）をもとに近似的に
良い打ち手を決定する手法
AlphaGo
2016年、DeepMind開発したゲームAI、技術的に
は、モンテカルロ木探索に深層強化学習の手法
を組み合わせて圧倒的な強さを到達
人間の棋譜のデータを使って教師あり学習や、
複製したAlphaGoとの自己対戦（self-play）で
獲得された経験を使って深層強化学習を行う
AlphaGo Zero
教師なしで最初から自己対戦でAlphaGoよりも
上まった
Alpha Zero
囲碁のみならず、将棋やチェスなどの分野で人
間のトッププレーヤーを超えて圧倒的な性能を
持つ
その他ゲームにおけるゲームAI
リアルタイムにゲームが進行、不完全情報ゲー
ムである
マルチエージェント強化学習（Multi-Agent
Reinforcement Learning, MARL）
今まで単一エージェントによる強化学習と区別
してする概念、エージェントの協調的や競争的
な関係を考慮して強化学習
OpenAI Five（2018年OpenAI）
MOBA（Moltiplayer Online Battle Arena）型の
Dota2で人間トップチームに優勝
LSTM、PPOなどの強化学習アルゴリズムを利用
特長は手法やアルゴリズムではなく、膨大な計
算資源と学習時間です。（５万以上のCPUと
1000個以上のGPUを使用して10ヶ月に及ぶ強化
学習を行った）
AlphaStar（2019年DeepMind）
RTS（Real-Time Strategy）型のスタークラフ
ト２で人間トップに優勝
ResNet、LSTM、ポインターネットワーク、ト
ランスフォーマーなど、画像処理や自然言語処
理の手法も多く取り入れたネットワークを使っ
て学習、ゲームプレイを行い
強化学習時にはゲーム理論や、自己大戦の発展
系の手法を使うなど、様々な人工知能技術が巧
みに組み合わせされて構成、いわば人工知能技
術の集大成的なアルゴリズムである
実システム制御への応用
ロボット制御への応用での実世界の課題
状態や行動を適切に設定する必要
次元の呪い（curse of dimensionality）
強化学習では、最も基本的な設定として、低次
元で離散値の状態や行動を扱う
連続値を離散値にはどの幅でやるか、様々な状
態・行動の高次元から低次元への転換に、状態
や行動の数が指数的に増大するため学習が困難
になる
価値関数や方策を関数近似することで高次元の
連続値のセンサデータや制御信号を状態や行動
として扱う、特に、関数近似器としてディープ
ニューラルネットワークを用いることで、デー
タの特徴表現を表現できるを期待
状態表現学習（state representation learning）
不変な特徴量を学習するCNNでは連続可変状態
で適切でない可能。問題に対して適切な方策を
学習できるように、エージェントは入力となる
センサデータから、「状態」に関する良い特徴
表現を学習する必要。深層強化学習の文脈で
は、しばしば「状態」に関する特徴表現学習を
さす
連続表現学習（continuous control）問題
DQNを利用することで、状態として画像という
高次元なデータを入力に利用することができる
ようになったが、出力である行動には低次元な
離散値が仮定されてしまい、ロボットが行動と
して関節角や台車の速度といった連続値の行動
に直接出力する問題設定
報酬設計が難しい
報酬関数の設計（どのような状態・行動の組に
どのぐらいの大きさの報酬を与えるかの設定）
によって、得られる方策の挙動は大きく異なる
報酬成形（reward shaping）
報酬関数の設計と学習された方策の挙動の確認
を繰り返して、適切に学習が行われるように報
酬関数を作り込む
サンプル効率が低い割にデータ収集コストが高
い
データの時効性、汎用性、本物の収集の難しさ
方策安全性の担保が難しい
実世界には無限試行できない（ロボット故障な
どなど）、実行動の安全性を担保する仕組みを
導入が必要
解決策
人間が環境やロボットに行わせたタスクに関す
る事前知識（ドメイン知識、domain
knowledge）を学習に組み込むための工夫を提
案している
オフラインデータの利用
事前（本物適用より）に何らかの方法で集めた
データから方策を学習する
オフライン強化学習（offline reinforcement
learning）
実際環境ではなく、そのデータセットを学習す
る
模倣学習（imitation learning）
人間が期待する動作をロボットに対して教示す
ること、ロボットが方策設定を学習する。これ
を教示データはデモンストレーションと呼ば
れ、ロボットを直接手で動かしたり、リモコン
やVRインタフェースにより遠隔操作したりする
ことで作成され
sim2real シミュレータの利用
シミュレータで学習した方策を現実世界に移転
して利用する設定
リアリティギャップ（reality gap）
現実世界とシミュレータで再現された世界の間
の差異
ドメインランダマイゼーション（domain
randomization）
シミュレータの各種パラメータをランダムに設
定した複数のシミュレータを用いて生成したデ
ータから学習する。
例：2019年OpenAI、５本指のロボットハンドの
中でルービックキューブを解く
残差強化学習（residual reinforcement
learning）
従来のロボット制御で用いられてきたような基
本的な制御モジュールの出力と、実際にロボッ
トがタスクを行う環境における最適な方策との
差分を強化学習によって学習すること
既存の枠を立てるので、サンプル効率や安全性
の面で有効な手法である
例：2019年プリンストン大学やGoogleなどのチ
ームが、ロボットアームを利用して様々な物体
を把持し、指定された箱に投げ入れる
TossingBotの研究が発表された
環境のモデルの学習
今まではほぼモデルフリー（model-free）：環
境状態がどのように遷移するかに関する知識を
明示的に学習しない
モデルベース（model-base）
環境に関する予測モデルを明示的に活用しなが
ら方策の学習を行う学習アルゴリズム
実際環境→状態・行動・報酬など様々な情報→
環境モデル⇄方策
世界モデル（world model）
エージェントが、得られる情報をもとに自身の
周りの世界に関する予測モデルを学習して、方
策の学習に活用する枠組みは、世界モデルと総
称される
データ生成
生成タスク
画像生成
データセット（訓練データセット）から画像が
持つ潜在空間を学習し、それをベクトルとして
表現。潜在空間より画像を生成する
音声生成
文章生成
変分オートエンコーダ（Variational
AutoEncoder, VAE）：2014年
数学的に堅実、潜在空間の理解が得意、でも画
像がぼんやりしがち
敵対的生成ネットワーク（Generative
Adversarial Network, GAN）：2014年
ジェネレータ（generator）
ランダムなベクトルを入力し、画像を生成して
出力する
ディスクリミネータ（descriminator）
画像を入力とし、その画像が本物か（ジェネレ
ータによって生成された）偽物かを予測して出
力する
DCGAN（Deep Convolutional GAN）：2015年
ディープニューラルネットワークで用いて、畳
み込みニューラルネットワークを採用したも
の、高解像での画像の生成が可能になっていた
Pix2Pix
GANのようなベクトルの代わりに、画像データ
を入力して別の画像に変換する処理
あらかじめペアの画像を学習のために用意必要
です。
Cycle GAN
ある画像を変換して、その変換した画像を元の
画像に再度変換する仕組みで、ペアなデータ準
備が不要になった
Diffusion Model：2015年研究開始、2020年から
実用までできた
データを生成する過程を時間的な連続的な拡散
のプロセス
拡散過程
学習時に、画像データにノイズを加えていき、
ガウス分布にする
逆拡散過程
データ生成時に、ノイズから徐々にノイズを除
去して画像データを生成する
NeRF（Neural Radiance Fields）：2020年
数枚の写真を与えると、そのシーンを 3D 的に
再構築し、見たことのない角度からの画像をレ
ンダリングできる
複数の画像データとそれらの視点や照明条件な
どの情報を用意し、画像データとそれらの情報
を元に、３次元区間の各点での色や透明度を予
測するネットワークを学習する
生成品質が高い、計算リソースが必要、シート
ごとに学習が必要、品質は入力データの質と量
に強く依存され
移転学習・ファインチューニング
学習済みモデル
移転学習
学習する時、出力層だけ初期化して学習。
出力手前に複数の全結合層などを追加する場合
などもある
ImageNetのデータセットで事前学習済みモデル
は1000クラス分類のやつ、最後の出力層は適用
したい問題のクラス数になるように、新たな出
力層に変更して学習する。
ファインチューニング
追加層だけではなく、モデルのすべての重みを
更新するよう学習する
少量データでの学習
Few-shot学習
極端に少ないデータ数、数枚程度で学習する手
法
MAML（Model-Agnostic Meta-Learning）
モデルの重み自体を更新するのではなく、モデ
ルの重みをどのように更新すれば良いかという
う学習方法自体を学習するメタ学習
One-shot学習
Zero-shot（ゼロショット）学習
半教師あり学習
擬似ラベリング（Pseudo-Labeling）
正解のついているデータを利用して学習を行
い、正解のついていないデータを評価する。そ
の結果をもとに擬似的な正解をつけ
一致性正則化（Consistency regularization）
データに対してノイズを加えた変換後のデータ
と変換前のデータをそれぞれモデルに入力した
際に、同じように出力になるすべき、この変化
前後の差を最小化する考え方
FixMatch
擬似的な正解ラベルと一致性正則化を組み合わ
せて高い制度を達成
自己教師あり学習
プレテキストタスクという人があらかじめ設定
した問題を学習
例：画像認識分野で、入力データに異なるデー
タ拡張を施して、モデルに入力、モデルが出力
する特徴が類似するように学習
一致性正規化と同じ原理
継続学習
認識したいクラスを増えていく、認識したい環
境（ドメイン）が変わっていく、適用範囲が広
がるにいく
但し、過去に学習したクラスを正しく認識でき
ない破滅的忘却が起きる可能
マルチモーダル
画像、言語、音声など様々なデータを入力して
も同時に扱う手法
マルチモーダルタスク
例：Image Captioning
画像データを入力すると、その内容を要約した
テキストを出力
テキストから画像を生成する Text-To-Image
基盤モデル
CLIP（Contrastive Language-Image Pretraining,
2021, OpenAI）
画像から抽出する特徴とテキストから抽出する
特徴が同じようになるよう非常に大量のデータ
で学習して、特徴を学習する。
物体認識と物体検出、Visual Question
Answeringなど、様々なタスクで利用され
DALL-E
CLIPとDiffusion Modelを用いて、テキストで指
定した画像を高品質で生成
Flamingo（2022, DeepMind）
その場で例を見せればすぐ学ぶ賢いマルチモー
ダルLLM
Unified-IO（2022, AllenAI）
何でも I/O 形式で統一して処理する万能マルチ
モーダルAI
モデルの解釈性
判断根拠を解釈し、説明にすること説明可能AI（Explainable AI）
LIME（Local Interpretable Model-agnostic
Explanations）
入力データの特徴の一部だけを与え、その、そ
の時の振る舞いを線形モデルに近似する局所的説明（1つの予測に対して理由を説明）
Permutation Importance
入力データの特徴をランダムに入れて、振る舞
いの変化をもとに特徴の寄与度を測り
全体的説明（グローバル） → モデル全体でど
の特徴が重要かがわかる
計算コストがかかる、特徴量同士が強く相関す
ると誤解を生む可能性
SHAP（SHapley Additive exPlanations）
ゲーム理論の Shapley値に基づく、予測を「す
べての特徴が協力して出した成果」と考え、各
特徴の貢献度（限界寄与）を公平に分配
局所（1つの予測の説明）と全体（全体の特徴
重要度）の両方を扱える
計算コストが非常に高い（TreeSHAP など高速
近似が実用化されている）
CAM（Class Activation Mapping）（2016年）
画像認識タスクに用いるモデルの予測判断根拠
をしますために「画像のどこを見ているか」を
可視化する
GAPの最終層の手前に用いたネットワークの構
造
可視化したいクラスに対応する重みをGAP前の
特徴マップに乗算し、すべての特徴マップを足
して１つのヒートマップにする。
Grad-CAM（2017年）
出力クラスに対する勾配情報を用いて、「最後
の畳み込み層の特徴マップにどれだけ貢献した
か」を重み付け、任意の CNN アーキテクチャ
に適用可能
但し、その過程で画像が低解像度になってしま
う
Guided Grad-CAM（2017年）
入力値の勾配情報も用いて、CAM過程の低解像
度問題解消
モデルの軽量化
蒸留
層が深く高精度なネットワークを学習した知識
を、層が浅く軽量なニューラルネットワークへ
伝える方法
層が深く複雑な学習済みのネットワーク教師ネットワーク
生徒ネットワーク
教師の学んだ知識を伝える未学習のネットワー
ク
「答えはA」 通常の学習時に用いるone-shotな正解ラベル hard target
「答えはA（90％）、B（10％）」 教師ネットワークの事後確率 soft target
hard targetとsoft targetそれぞれを用いて、ク
ロスエントロピー誤差関数で計算して、誤差逆
伝播法で生徒ネットワークを更新
枝刈り
ニューラルネットワークの接続の一部を切断す
る、すなわち重みの値を０にする
絶対値の小さいものから順番に削除マグニチュードベース
勾配ベース
モデルにデータを入力して各クラスの確信度を
出力、正解クラスの確信どから誤差を逆伝播し
て、勾配情報から各重みの評価値を算出、この
評価値（感度とも言う）が小さいものから順番
に削除
一般的に、モデル全体の学習と枝狩を繰り返し
て、少し済みモデルサイズを圧縮することが多
い
いきなり多くの重みを削除すると精度に悪影響
可能
宝くじ仮説（Frankle & Carbin, 2019）
モデルを学習する際に、より良い初期値（当た
りくじ）を持つサブネットワークがモデル全体
の中に含まれている
従来のは枝刈り後、モデルの重みは初期化せ
ず、繰り返し更新。対して、宝くじ仮説には重
みを初期値に巻き戻して、元の訓練データより
高い精度のモデルを作成
量子化
重みなどのパラメータを少ないビット数で表現
して、モデルを圧縮する方法。
ネットワークの構造を変えずにメモリ使用量を
減らす
最初精度は誤差や勾配のため一般的に、32ビッ
ト浮動小数点数を使用する。推論時にはそこま
で高精度が必要なく、８や４ビット整数などに
することも性能をほぼ維持しながらメモリと計
算量を減らす
AIのビジネス利活用
経営課題を解決し、利益を創出意義
５分が１分になることではなく、５日が１分に
なることに焦点、要は部分最適してもビジネス
インパクトを生み出すが困難、全体的を最適化
することで連鎖的に改善され、圧倒するバリュ
ーチェーン・サプライチェーンを手に入れる
AIプロジェクトの進め方
そもそもAIを適用する必要があるのか
AIは手段の一つでしなく目的ではない、AIの特
性っを理解した上で判断が必要、かつ短期的、
中期的、長期的で時間軸、および実施内容での
ルールベース、データ蓄積の流れ的な考案が必
要
AIの適用箇所と技術の連携範囲を再検討 BPR（Business Process Re-engineering）
提供方法
クラウド
モデルの更新が楽、装置の故障管理不要、計算
機の保守・運用が不要
通信遅延の影響を受ける、ダウンした時の影響
が大きい、量よりのコストは意外に大きいの場
合もある
エッジ
リアルタイム性が高い、通信量が少ない、故障
の影響範囲が小さい
モデルの更新が難しい、機器を長期間保守運用
する必要がある
開発計画を策定
データを確認する段階、モデルを試作する段階
（PoC）、運用に向けた開発をする段階にフェ
ーズを細かく区切り、収集されたデータの中身
や学習して得られたモデルの精度に応じて、柔
軟に方針を修正できるような体制が望ましい
プロジェクト体制を構築
多岐にわたるスキルを保有する様々なステーク
ホルダーを巻き込んだ体制づくりが必要
システム構築技術者
ビジネス的な観点も踏まえて全体を把握・意思
決定するマネージャ
UX／UXに関するデザイナー
データサイエンティスト
...
プロジェクト計画の各フェーズの進め方
CRISP-DM（CRoss-Industry Standard Process
for Data Mining）：データマイニングのための
産業横断型プロセス：1990年代末に策定
プロセス
ビジネス理解（Business Understanding）
データ理解（Data Understanding） → データの
収集・探索
データ準備（Data Preparation） → 前処理・特
徴量作成
モデル構築（Modeling） → 学習・モデル作成
評価（Evaluation） → モデルがビジネス目標を
満たしているか確認
展開（Deployment） → 実運用や意思決定に活
用
CRISP-ML（Cross-Industry Standard Process
for Machine Learning）
CRISP-DMの上、Business UnderstandingとData
Understandingが統合され、Monitoring and
Maintenance（監視・保守）が追加され６つの
ステップ
MLOps
NIPS2015論文
AIモデル構築部分は全体のAIプロジェクトの中
で極めて小さく、その周辺領域が大きいこと
概念図
Configuration→DataCollection→Feature
Extraction・DataVerification・ML
Code→Machine Resource Management・
Analysis Tools・Process Management
Tools→Serving Infrastructure→Monitoring
サービス化
各フェーズの進め方（実装・運用・評価）
例
産業連携をこなうことで、プロジェクト構成メ
ンバーを分散させる
大学からデータサイエンティストを出し、事業
会社がデータが提供し、ベンチャー企業が環境
を提供など
オープンイノベーション化
外部のアイデアや技術と結合しイノベーション
を生み出すスピードを向上させ、コストやリス
クを低減させる
例：Ciscoは有望なスタートアップへの出資やM
＆A、協業関係を築くなど外部資源を積極的に
活用する
Triple Helix model
欧州では、これまで大学・産業界・政府の産業
連携ネットワークを中心とし、研究開発領域に
留まらず技術の商用化やビジネスモデルの領域
まで及ぶ
プロジェクトの計画に反映する
このAIシステムの恩恵や影響を受けたのは誰か
想定外のユーザはいないか
判断や最適化を行う時の基準はなんか
判断や最適化などを機械で行うことの正当性は
どんな根拠に基づいているか
AIシステムやサービスを、現在の文脈以外に悪
用される危険性はあるか。それを防ぐ対策は取
られているか
データの収集・加工・分析・学習
データの収集方法および利用条件
オープンデータセット
企業や研究者が公開しているデータセット
コンピュータビジョン分野
ImageNet
PascalVOC
MS COCO
自然言語分野
WordNet
SQuAD
DBPedia
LibriSpeech 音声分野
利用する際にライセンス要注意
自身で作成
センサを利用環境の情報計測などのアプローチ計測データ
テキストデータ解析
時系列データ
アンケートやインタビュー
ログデータ
ソーシャルメディアの投稿データ
学習可能なデータを集める
認識すべき対象の情報が十分に含まれているか AIのモデルを訓練できるデータが必要
データの偏るを無くす
データの網羅性を重視
データを加工
収集されたデータに、不要な情報や、データ間
で形式の近いがありなど、前処理必要
教師あり学習の場合は、正解データを作成も必
要：アノテーション
ばらつき要注意
アノテーション定義の曖昧さ
アノテーション実施しゃの感性
作業の専門性
認知容量を超える規模
ケアレスミスなど
対策
要件を決める際に、マニュアル作成、作業者が
要件を理解できるようにする
アノテーションの判断軸とそのサンプルの提
示、作業せいどの明確化（言語のルール＋事
例）
ルール明確の上で、どの程度の誤差を許容する
かも明確
匿名加工個人情報の配慮
個人を特定できないように情報を加工する、プ
ライバシー保護を図り
氏名等の個人識別に繋がる情報の削除やマスキ
ング、データの集約化など
画像や音声データは、元データに復元できない
ような特徴量のデータをしつつ、生データは削
除する対策など
Python 開発・学習環境を準備
バージョン管理で、環境を切り替えられるツー
ル（pyenv, virtualenv, pipenv, poetryなど様々あ
る）
AIモデルを学習
初期段階ではパラメータの設計が甘くモデルの
精度が低いところから始まるため、モデルの調
整によってい大きな精度向上を見込め
ビジネスの目標に基づく、精度とコストの折り
合いをつけて進む
学習済みモデルを用いて移転学習するなどもあ
る
検証には、学習に用いたデータ以外のテストデ
ータを用いて検証を行う
過学習を避けるために、バリデーションデータ
を用意して、最終性能評価を行う
データリーク要注意
モデルが学習時に本来知るべきでない情報にア
クセスしてしまう現象
未来の事象を予測するモデルに未来の情報がモ
デルの学習に漏れ込んでしまうと、評価が過度
に高くなる可能。それで実際の運用時に予期し
ない誤差を生じる可能性がある
推論を行う
運用時にコストやデプロイ環境制限などによっ
て、モデルの最適化や軽量化が必要の場合もあ
る
時間の経過や環境の変換より、当時の学習デー
タとは異なるデータが増えていくことで、モデ
ルの精度が徐々に低下するリスクがある
定期的にデータを再収集し、モデルを再学習あ
るいは微調整をすることが推奨
AIの法律と論理
「AI活用推進法（AI新法）」が2025年6月に成
立・公布され、2025年夏頃にAI戦略本部が設置
され基本計画が策定され
AIの法律
著作権法
思想または感情を創造的に表現したもの著作物
事実自体は著作物ではないです、それに対して
の創造的な考え記事は著作物
アルゴリズムや数学的な手法も対象外
ソースコードのコピーやかなり類似では著作権
侵害ですが、予め自己実現なら問題なし
データに関しても通常、単なる事実でしかない
ため、保護の対象でもない
ただし、情報の選択や体系的な構成に創造性が
認められる場合は特別な規定により著作権が認
められる
複製権、公衆送信権、譲渡権など著作者財産権
著作者人格権
著作者の精神がきつけられないように保護、公
表権、氏名表示権、同一性保持権などがある、
譲渡はできない
職務著作
従業員等が職務上行う著作
法人等の発意に基づいて、法人等が自己の名義
で公開するものなどの要件を満たすれば、会社
等の法人に著作権が原則として帰属する
プログラムについては外部に公表を予定してい
ないことも多いため、法人等が自己の名義で公
表するものであることは不要と定められている
従業員ではなく、業務委託先が行なった著作の
著作権は発注者ではなく業務委託先に帰属する
ことを要注意
独占権利の例外
著作権法３０条の４、コンピュータによる情報
解析に利用するような場合には、複製等を認め
る
著作者の死亡年の翌年1月1日から起算して70年
まで保護されます。
無名・変名・団体の場合は、公表後70年まで
（または死亡後・創作後70年まで）
ベルヌ条約の「短期優先の原則（rule of the
shorter term）」
データと著作権
テーブルデータ
内容は客観的な事実、やアノテーションの内容
も客観的な事実の場合、著作権は発生しない
画像データ
人間がカメラを使って撮影した場合は原則著作
権が発生
ただし、工場における設置カメラによる自動撮
影のような場合は発生しない、また、画像に対
するアノテーションは、通常客観事実の記述し
かないので、アノテーションにより別途著作権
の発生もない
テキストデータ
人間が当該テキストを執筆した時点で著作権が
発生、アノテーションは他のと同じ
プログラムと著作権
プラグラムも著作物として認める
パラメターは計算の結果得られた数字の羅列の
で、著作物とは言えず著作権発生しない
生成AIと著作権
３０条の４により原則的に適法学習用データへの利用
AI生成物の著作権
単なるAI生成するものは創作性を認められず著
作権は成立しない
人間がAIを道具として創作したような場合やAI
生成画像を作ったような人間に創作的寄与が認
められる場合には著作権成立
AI生成物による著作権侵害
既存著作物に類似していることを理由に著作権
侵害が成立するためには、既存著作物に似拠し
ている必要がある
ただし、AIはどう判定するはは大議論になる
特許権特許法
アイデアを保護する法制度、排他的・独占的な
権利、特許権者からライセンスを受けないと第
三者がそのアイデアを使うことができない
他の第三者にも実施権を付与を行う通常実施権
専用実施権
公表登記が必要、独占的排他的な権利を付与し
特許権者自身も実施できない権利
基本
特性
産業上の利用可能性
新規性
進歩性
登録制
特許庁に出願をし、特許庁の審査と登録を受け
て初めて権利として成立
同一の発明を行なった者がいる場合に、日本の
特許法は先願主義ので、先のやつに特許を与え
る
特許は基本20年、医薬品などは最長25年
従業員が職務に関して行なった発明について、
一定の場合には特許権が使用者である企業等に
帰属するためを特許法で定めている
契約や従業規則で使用者があらかじめ特許を取
得するためを定めていれば、ただし、適切な対
価を従業員に支払うが必要
データの保護と不正競争防止法
不正競争行為と呼ばれる情報の窃取などを処罰
する
要件営業秘密
秘密管理性
主観的ではなく、秘密管理の意思が秘密管理措
置として他の一般情報特別必要、マル密などの
表記付与、営業秘密のリスト化、閲覧のための
パスワード設定などで
有用性
非公知性
限定提供データ（2023年改正で導入）
電磁的方法により相当量蓄積された情報であっ
て、特定の者との間で、電磁的方法により有償
で提供されるものをいう。
個人情報保護法
個人情報の定義
生存する個人に関する情報であって、いずれが
に該当するもの
当該情報に含まれる氏名、生年月日その他の記
述等により特定の個人を識別することができる
もの（他の情報と容易に照合することができ、
それにより特定の個人を識別ことができること
となるものを含む。）
氏名や顔写真はもちろん、メールアドレスも該
当する。電話番号や位置情報は単品であれば特
定できないので個人情報ではないです。ただ
し、単品ではなく氏名と一緒になっている場合
は個人情報になり
個人識別番号が含まれるもの
法令で定めた番号や記号などに該当し、指紋や
DNAなどの生体情報や、運転免許証番号やパス
ポート番号などの公的機関より与えられた番号
が含まれる。
顔認識に用いられる特徴ベクトルも前者の生体
情報に該当し個人情報に該当する
個人データベース等
個人情報を含む情報の複合体であって、特定の
個人情報を検索できるようにしたもの。
注意が必要なのは、紙媒体によるデータベース
も含まれるということです。名刺を五十音順に
検索できるように並べたものも個人データベー
スに該当する
個人データベース等を構成する個人情報個人データ
保有個人データ
開示、訂正、削除等の権限を有する個人データ
を指す。
委託により預かっている個人データは保有個人
データではないです
事業者が自ら利用目的を決定して保有している
個人データのこと。ただし、6か月以内に消去
する短期データなどは除く
類型ごとの規制概要
個人情報
利用目的の特定等
原則として、あらかじめ本人の同意を得ること
なくこの利用目的を超えて個人情報を取り扱う
はできない
利用目的はあらかじめ公表するか、速やかに通
知または公表する必要
通常の個人情報は取得する際に同意までは不要
で、利用目的の通知または公表でOKが、要配慮
個人情報は取得でも同意が必要
不適正な利用の禁止等
偽りその他不正の手段により取得は禁止、違法
または不当な行為を助長し、または誘発する恐
れがある方法により個人情報を利用も禁止
個人データ
取得利用に関する規制
個人データを正確・最新の内容を保ち、利用す
る必要がなくなった場合に、遅滞なく消去する
努力ぎむが課かされ
安全管理義務
個人データの漏洩、滅失または毁损の防止その
他の個人データの安全管理のために必要かつ適
切な装置を講じなければならない
従業員もしくは委託を受けた者に対して必要か
つ適切な監督を行うが必要
例外原則本人の同意が必要（オプトイン：opt-in）第三者提供規制
利用目的の達成に必要な範囲内において個人デ
ータの取り扱いを委託することに伴って個人デ
ータが提供される場合は同意不要
AI開発を第三者に委託する場合に、開発会社に
学習用データとして個人情報を提供する。委託
元の利用目的の達成に必要な範囲でのみ個人情
報の利用が可能です
保有個人データに対する規制
開示請求
本人は、自己に関する保有個人データの開示を
請求することはでき、企業は原則として応じな
ければならない
訂正等の請求権
内容の訂正、追加または削除
利用の停止または消去
特別な個人情報や類似情報の規制
要配慮個人情報
本人の人種、信条、社会的身分、病歴、犯罪の
経歴、犯罪により害を被った事実などの特にセ
ンシティブな個人情報を指す
オプトアウト（opt-out）より本人同意せず第
三者へ提供不可
匿名加工情報
第三者に提供するため氏名などを削除するが、
削除前のデータと容易に照合性が認められ、相
変わらず個人情報として取り扱う、自由な利活
用はできないため、匿名加工情報制度を設けた
匿名加工情報は、プライバシーに関する情報の
ため様々な義務があったが、一定の事項を公表
した場合には、同意なく第三者提供が可能にな
る
特定の個人を識別できないように加工が必要
例
氏名を削除するとともに、住所を市区町村レベ
ルまで抽象化、照合用のIDも削除、116歳などの
特異なデータを削除など
対応表の破棄なども必要
個人情報保護委員会が公開してる個人情報の保
護に関する法律についてのガイドラインがあ
り、匿名加工情報・匿名加工情報編
仮名加工情報
第三者提供は原則禁止され、事業者内部での利
活用を想定した制度
氏名との削除、クレジットカード番号などの財
産的損害が生じる恐れのある記述等の削除でた
り、「116歳」など特異なデータの削除等まで必
要ない
個人情報では利用目的を変更する場合には原則
本人同意が必要、仮名加工情報では変更に本人
の同意が不要で、事後的に利用目的を変更して
利用することができるようになり
個人関連情報
生存する個人に関する情報であって、個人情
報、仮名加工情報及び匿名加工情報のいずれに
も該当しないもの
IPアドレス、閲覧履歴などこれらだけでは個人
情報等該当するものではない
第三者へ提供する際に、提供先には当該個人関
連情報を個人データとして取得が予測する場
合、原則は本人同意が必要
例、提供先の第三者が（氏名、住所、 IPアドレ
ス）の個人データを持っており、 IPアドレスを
用いて照合すると個人関連情報を個人データと
することができる場合がある
GDPR（General Data Protection Regulation（一
般データ保護原則））
EU領域内の個人情報を保護する目的の法
EUに事務所を設置している企業だけではなく、
様々なものを保護対象としている
EUの個人に商品・サービスの提供を行っている
データポータビリティ権など日本居ない権限が
定めている
データ保護責任者の配置等の日本の個人情報保
護法にはない義務が定めている
データ移転に関して厳しい制限がある
高額な制裁金がある
独占禁止法
自由競争を阻害する行為を禁止することで公正
かつ自由な競争を促進し、ひいては一般消費者
の利益を保護するための法律
事業者同士が話し合って価格を決定するカルテ
ルなどを阻止する
議論
データの囲い込み
市場支配力のある巨大な事業者が、当該市場に
おける事業活動に不可欠で、代替的な取得が困
難なデータを独占すること　←　ただし、まだ
明確に禁止する法律がない
AIとカルテル
カルテルの合意が守られているかを監視するAI
で、その合意に従って価格をつけるように設定
されたアルゴリズムをカルテルに参加している
事業間で用いていること
デジタルプラットフォーム規制
一定のプラットフォーム事業者を対象に、取引
条件等の開示や運営状況の報告・評価等を義務
つける（特定デジタルプラットフォームの透明
性及び高平成の向上に関する法律）
AI開発契約
請負契約
仕事の完成を約束し、その結果に対して報酬が
支払われる契約
凖委任契約
医師による治療契約は完治の約束がない事務の履行に対して報酬が支払われる履行割合型
成果完成型
事務により得られる成果に対して報酬を支払う
もの
請負と違って、成果の実現を条件に報酬を支払
う、仕事完成業務がない、（努力義務＋成果確
認）がある。
AI開発契約に関するガイドラインと特徴
例
経済産業省が「AI・データの利用に関する契約
ガイドライン」（AI契約書ガイドライン）
特許庁・経済産業省「研究開発型スタートアッ
プと事業会社のオープンイノベーション促進の
ためのモデル契約書」（特許庁モデル契約書）
日本ディープラーニング協会「ディープラーニ
ング開発標準契約書」
特徴
モデルの内容や性能がデータの品質に依存する
性能保証が難しい
ノウホウの重要性が高い
加工方法、ハイパーパラメータ設定、データ分
析などなど、委託者側のドメイン特有のノウホ
ウも重要
開発の流れ
アセスメント
解決すべき課題の特定等を行う、成果物は報告
書であることが多い
AI契約ガイドラインでは秘密保持契約（NDA）
だけを締結するが、想定は簡易なもので、実に
はそれなりの工数が必要ので、一般的に準委任
契約を利用
PoC（Proof of Concept：概念実証）
実運用可能なモデルが作成できるか、モデルを
実運用できるかを調査するが目的
準委任契約を締結、成果物は調査結果をまとめ
た報告書
実装
結果予測できないため、準委任契約で行う事が
多い。
成果物としてはモデル（推論用コードとパラメ
ータ）であり、成果完成型準委任契約を利用す
ることもある
追加学習
保守・運用契約中で実施か、ある程度規模大き
な追加学習もあり、一般的に準委任契約です
一般的にAIモデル以外、ユーザインタフェース
も合わせて開発
アジャイル形式の場合は準委任契約が一般
ウォーターフォール型契約の場合は要件定義フ
ェーズは準委任が、実装フェーズでは主に請負
契約を用いている
AI開発契約で定めておく必要知的財産権の帰属
実用主義で、利用権を重視し、必要に応じて著
作権者側に制限を加える
秘密保持契約（Non-Disclosure Agreement：
NDA）
AI開発契約の締結検討段階や簡易なアセスメン
トを行う段階で締結される契約
第三者へ開示・漏洩以外、目的以外禁止、他社
からの委託や自社営業目的での使用なども禁止
した方が良い
AI利用契約
特定の会社のために専用のAIを開発する場合の
契約
追加学習に関する手当注意点
サービス提供者側の判断で追加され、ユーザ側
は知らないものので
同じデータに対して昨日とは異なる出力になさ
れるや、ユーザ環境における精度低下も可能
あらかじめ契約書で説明しておく、サービス提
供者側が責任を負わないため定めていく
複数のユーザのデータを用いて１つのパラメー
タを更新する場合も、その旨をAI利用契約に明
記すべき
AIの論理
信頼できるAI（Trustworthy AI）、責任あるAI
（Responsible AI）
国内外のルールと取込み
ハード・ロー
法律など公的機関が定める順守義務が生じるル
ール、法的強制力がある一方、成立や変更には
議会などの承認が必要で遅くなる
AI法案が代表的なEUを除けば基本はソフト・ロ
ー
EU：AI法案等
AIを直接規制する法であるAI法案を発表し、制
定を目指している、AIのリスクに応じた規制を
行うリスクベースアプローチが採用され、法案
以外、AIに関する賠償ルールを定めるハード・
ローであるAI責任指令案を公開し、制定を目指
している
ソフト・ロー
公的機関だけではなく業界団体や学会も定める
自主規制、ガイドラインなど、強制力がない
が、裁判時に善管注意義務違反の参考になる
日本政府よりルール
内閣府
「人間中心のAI社会原則」のAIの社会実測を進
めるため関係者が注意すべき基本原則を述べる
ガイドライン
総務省
「AI利活用ガイドライン」、AIをビジネスに利
活用する者が留意すべき原則を述べる
「国際的な議論のためのAI開発ガイドライン
案」、AI開発者が留意すべき原則についての説
明
経済産業省
「AI原則実践のためのガバナンス・ガイドライ
ン」、原則の実践を支援すべく、実施すべき行
動目標を指示し、実践例や事務的な対応例を示
している
AI事業者ガイドライン
AIの開発者・提供者・利用者を含む、あらゆる
事業者に、基本方針や理念（why）や取組指針
（what）が「本編」で示され、具体的な対応
（how）が「別添」に示されている
外国政府によるルール
アメリカ
Blueprint for an AI Bill of Rights
アメリカのホワイトハウスが出したガイドライ
ンであり、AIの開発や利活用等をガイドする原
則を説明する
Executive Order on Safe, Secure, and
Trustworthy Artificial Intelligence
バイデンは、AIの安全性に関して政府機関に対
して研究を行うことなどの指示を大統領令
AI RISK MANEGEMENT FRAMEWORK アメリカ商務省配下のNISTが定めたAIに関する
リスク・前ネジメントのためのフレームワーク
Ethics guidelines for trustworthy AI EU AI法案より前に信頼できるAIのための必要事項
を解説するもの
国際機関によるルールや国際連携
Recommendation of the Council on Artificial
Intelligence OECD（経済協力開発機構）
2019年世界で初めて政府間で合意されたAIに関
する原則。
AIは人権や民主主義の価値に沿うべき
透明性と説明責任
セキュリティとプライバシー保護
公平性と包摂性
G7（広島AIプロセス, 2023）
G7各国が生成AI（特に基盤モデル）に関して、
透明性・リスク管理・国際協調を進める合意
Global Partnership on AI（GPAI, 2020設立）
日本、米国、EU、インドなどが参加
AI倫理、ガバナンス、社会応用について国際協
調
ISO
ISO/IEC 42001（2023年）：AIマネジメントシス
テムの国際標準
バイアス公平性
データバイアス
学習データに偏りがあることでモデルも偏る。
例：顔認識モデルが白人男性には強いが、女性
や有色人種には弱い。
データ収集時に多様性を確保
サンプリング手法の工夫（例：層化抽出）
データオーグメンテーションで不足クラスを補
う
選択バイアス（Selection Bias）
分析対象が偏っている。母集団を正しく反映し
ない。
例：健康調査を「病院に来た人」だけで行うと
偏る。
無作為抽出を徹底
欠損データ処理を適切に実施
重み付けで母集団に近づける
測定バイアス（Measurement Bias）
データの測定方法が偏りを生む。
例：古い機器での計測誤差、質問票の誘導的な
文言。
測定機器・方法を標準化
クロスチェックや複数測定を導入
アルゴリズムバイアス
モデル構造や学習方法自体に偏りが入る。
例：誤差を最小化するだけだとマイノリティの
精度が落ちる。
公平性制約を組み込む（Fair ML）
ロス関数を工夫してマイノリティの重みを上げ
る
人間自体がバイアス
認知バイアス
無意識バイアス
研究者や利用者の主観的な判断が入り込む。
例：結果の解釈に先入観が影響、都合のよいデ
ータだけを選ぶ。
ピアレビューや第三者チェック
透明性・説明責任を確保
バイアスを意識的に開示
安全性
安全性
AIによって利用者や第三者の生命・身体・財産
に危害が及ばないように配慮すること
安全性基準
AIがタスクに対して適切に判断ができること有効性
プライバシー・バイ・デザインプライバシー
AIの開発の仕様設計段階からプライバシー保護
の取組みを行う考え方
経済産業省
カメラ画像を用いる場合に「カメラ画像利活用
ガイドブック」を参考に、推論の内容、利用目
的、データの保存方法、周知方法など
透明性とアカウントビリティ
情報の開示に関する事項を透明性として扱う
どのような理由で、誰に対して、どのような情
報を開示するのか検討するが必要
AIに関して責任を負うことを意味するものをア
カウントビリティ
AIの出力がもたらされた入力やパラメータ等が
追跡できる追跡可能性、出力の原因を探ること
のできる検証可能性、必要なドキュメントの文
書化、AI論理に関する事項を実施する責任者や
担当組織の明確化など
セキュリティ
学習用データを汚染攻撃、敵対的事例
（Adversarial example）を用いた推論結果の操
作、推論結果を集めることでによる学習用デー
タやモデルの推測、細工をしたモデルの配布と
いうモデル汚染攻撃など様々あり
悪用の防止
ディープフェイクなどポルノや偽情報や、生成
AIを利用した詐欺や危険物の製造方法の調査な
どが問題、サイバー攻撃へのAI利用なども懸念
された
仕事の保護
AI自動化により引き起こされる仕事の喪失から
労働者を保護、最小化するや他の仕事に移行な
ど
民主主義とその他の価値
誤情報の拡散、ソーシャルメディアの操作、死
者のデジタル復活などなど
生成AIにおける価値
AIガバナンス
経営層の関与
経営層が組織として行うことを意思決定し、関
与する
AIポリシー
AIの価値や原則などの目的に対して、どのよう
に取り込んでいくのかなどを述べるドキュメン
ト
責任者の特定
AIガバナンスに関する業務を実施する責任者や
実施担当者・担当組織を任命する必要
AIリスク・アセスメント
開発・導入しようとしている、または現在利用
しているAIが自組織や利用者、社会にどのよう
なリスクを生じさせるかの検討
目標や手続きの設定
社内教育
文書化
必要な文書を文書化して保存しておき、必要な
者がいつでもアクセスできるようにしておく
モニタリング
どの指標で、どのような頻度やタイミングでモ
ニタリングを行うのかを検討
内部監査、振り返りと改善
リスク低減のための措置の例
AIの判断は参考とし人間が最終判断を下す人間の関与
フィードバック
ステークホルダー関与
多様性の確保
データの品質確保
改良