

G検定

▼ 人工知能とは

▼ とは

▼ 起源

▼ 言葉の初

▼ 1956アメリカでダートマス会議

- ジョン・マッカーシー

▼ 概念

▼ 推論、認識、判断など、人間と同じ知的な処理能力を持つ機械（情報処理システム）

▼ 知性や知能自体の定義がないため、

- ただし、人工知能とはなんかは共有される定義がない

▼ 周囲の状況（入力）によって行動（出力）を変えるエージェント（プログラム）

- エージェントアプローチ人工知能（共立出版）

▼ 分類

▼ レベル1：単純な制御プログラム

▼ すべての振る舞いが予め決められ

- エアコンの温度調整、洗濯機の水量調整、電気シェーバーの深剃り調整など、制御工学やシステム工学と呼ばれる分野で長年技術

▼ レベル2：古典的な人工知能

▼ 探索・推論・知識データを利用することで、状況に応じ極めて複雑な振る舞いをする

▼ 掃除ロボット、診断プログラムなど、特定の分野で高い有用性を示し、広く実用化される技術

- DeepLearningにつながる人工知能の研究はこのレベルから始めている

▼ レベル3：機械学習を取り入れた人工知能

▼ 非常に多くのサンプルデータをもとに入力と出力の関係を学習

- 検索エンジンや交通渋滞予測

- パターン認識という古くからの研究ベースに発展し、2000年代ビッグデータ時代に迎えて進化している
- どのような特徴が学習結果に大きく影響する（特徴量）
- ▼ レベル4：ディープラーニングを取り入れた人工知能
 - 特徴量と呼ばれる変数を、自動的に学習するサービスや製品。特徴量を自動的に学習する技術で、画像認識、音声認識、自動翻訳などで活用している
- ▼ AI効果
 - 人工知能で何か新しいことが実現され、その原因がわかってしまうと、「それは単純な自動化で合って知能とは関係ない」と結論つける人間の心理的な効果
- ▼ 人工知能とロボットの違い
 - ロボットの脳に当たる部分が、その限りでもない、「考える（知的な処理能力）」という「目に見えないもの」が中心
- ▼ 歴史
 - ▼ 初の汎用コンピュータ
 - ▼ 1946年、アメリカのペンシルバニア大学でエニアック（ENIAC）
 - 17,468本もの真空管で構成された汎用電子式コンピュータ
 - ▼ 第1次AIブーム
 - ▼ 1950年代後半～1960年代
 - 探索・推論の時代
 - ▼ ダートマス会議
 - ▼ 1956年、アメリカで開催された
 - ▼ ジョン・マッカーシー
 - 初めて人工知能の言葉を使用
 - ▼ ニューウェル、サイモン
 - ▼ 世界初の人工知能プログラム：ロジック・オセリストをデモンストレーション
 - コンピュータを用いて数学の定理を自動的に証明することが実現可能を示し（四則演算などの数値計算しかできないが。）
 - ▼ 特定の問題に対して解を提示できるようになったことのブーム
 - 東西冷戦下、アメリカは英語ーロシア語の機械翻訳が注目

- 知的なさまざまなもんだチェスや将棋で優勝が、非常に限定された状況で設定された問題しかにすぎない
- ▼ 探索・推論も初めている
 - ▼ 迷路や数学の定理を証明するような簡単な問題（トイ・プログラム（おもちゃの問題））できても、複雑なものができないことが明らかになったので、
 - 1970年代は人工知能研修の冬の時代入った
- ▼ 機械学習・特徴表現学習も始めている
 - ニューラルネットワーク・機械翻訳
- ▼ 第2次AIブーム
 - 1980年代
 - ▼ 知識の時代
 - 1990年：世界初のWebページ
 - ▼ 専門家の知識を取り込んだ「エキスパートシステム」の開発が活性化
 - 日本では、政府によって「第五時代コンピュータ」と名付けられた大型プロジェクトが推進
 - ▼ しかし、知識を蓄積・管理は大変のことを明らかになって
 - 1995年ごろから冬時代入った
 - 知識表現：オントロジー
- ▼ 第3次AIブーム
 - 2010年～
 - ▼ 機械学習・特徴表現学習の時代
 - ▼ ビッグデータ
 - ▼ 人工知能が自ら知識を獲得する機械学習が実用化され
 - ▼ 統計的機械学習
 - 統計的な機械翻訳・検索エンジン
 - ニューラル機械翻訳
 - 自動運転
 - 大規模言語モデル

- 知識を定義する要素（特徴量と呼ばれる対象wお認識する際に注目すべき特徴を定量的に表したもの）を人工知能が自ら習得するディープラーニング（深層学習）

▼ 第4次AIブーム？

- 一部の専門家は、2022年ChatGPTの登場の機にAIブームが新たな局面に入る

▼ 問題

▼ トイ・プロブレム（おもちゃの問題）

- 問題の本質を理解したり、現実世界の問題に取り組んだりする練習
- 複数の研修者がアルゴリズムの性能を比較するために用いることも

▼ フレーム問題

▼ 1969年ジョン・マッカーシーとパトリック・ヘイズ提出

- 未だに本質的な解決はされていない、人工知能研究の最大な難問

▼ 今しようとしていることに関係のあることからだけを選びることが、実は非常に難しい

▼ 哲学者のダニエル・デネット

▼ 隣に時限爆弾があるバッテリーを持ち出すロボットを作るの例

- 1号：爆弾も一緒に持ち出して爆発
- 2号：持ち出す方法を考えすぎで爆発
- 3号：持ち出す方法の方法を考えすぎで爆発

▼ チューリングテスト

▼ イギリスのアラン・チューリング提出

- 別の場所にいる人間がコンピュータと会話をし、相手がコンピュータだと見抜けなければコンピュータには知能があるとする

▼ イライザ（ELIZA）

- 1966年ジョセフ・ワイゼンバウム開発された
- 精神科セラピストの役割を演じるプログラムで、本物のセラピストと信じてしまう人が現れ

▼ ロープナーコンテスト

- 1991年以降毎年開催
- チューリングテストに合格する会話ソフトウェアを目指すロープナーコンテスト

▼ 強いAIと弱いAI

- ▼ 1980年アメリカ哲学者ジョン・サールが発表した「Minds, Brains, and Programs（心、脳、プログラム）」論文で提示した

▼ 強いAI

- ▼ 適切にプログラムされたコンピュータは人間が心を持つのと同じ意味で心を持つ。また、プログラムそれが自身が人間の認知の説明である
 - ▼ 「中国語の部屋」の思考実験で「強いAI」は実現不可能を主張している
 - 完璧なマニュアルを持っているの行動か、心を持つ行動するか判断できない
 - ▼ チューリングテストの拡張とし、心がどこに存在するのか、あるいは意味はどこにあるのかの思考。
 - コンピュータは記号操作を行っているだけで、心にとって本質的な意味論を欠けていると主張している
 - ▼ ロジャー・ペンローズ（ブラックホールの研究で有名なスティーブン・ホーキングと共同研究の有名な数学者）
 - ▼ 「皇帝の新しい心ーコンピュータ・心・物理法則」（林一訳、みすず書房）
 - 意識は脳の中にある微細な管に生じる量子効果（非表示スケールの小さい世界で生じる物理現象）が絡んでいるので、既存のコンピュータでは「強いAI」は実現できないと主張

▼ 弱いAI

- コンピュータは人間の心を持つ必要はなく、有用の道具であれば良い

▼ シンボルグラウンディング問題（記号接地問題）

- 1990年認知科学者のスティーブン・ハルナッド議論

▼ 記号（シンボル）とその対象がいかにして結びつくか

- フレーム問題と同様、人工知能の難問

▼ 身体性

▼ 知識が成立するためには身体が不可欠の考え方

- ▼ 人間には身体があるからこそ物事を認識したり、思考したりできるという考え、「身体性」二着目したアプローチ

- コップ触ったの感覚、落とすと割れるなどの経験を含めて「コップ」という概念
- 外界と相互作用できる身体がないと、概念は捉えきれない

▼ 知識獲得のボトルネック

▼ 機械翻訳

- 1970年代後半：ルールベース機械翻訳

▼ 1990年代以降：統計的機械翻訳

▼ 実用レベルになれない

▼ 例：He saw a woman in the garden with a telescope

- 人間：彼は望遠鏡で、庭にいる女性を見た
- 機械：彼は望遠鏡で、庭で女性を見た

▼ コンピュータが「意味」を理解していないこと

- 一般常識がなければ訳せないことがある、一般知識を取り込んむのは膨大すぎて、極めて困難となっている

▼ 2010年頃、ニューラル機械翻訳（DeepLearning）登場

▼ 2016年11月、Goole翻訳では、機械翻訳の品質を格段に向上した

- ニューラル機械翻訳では人間が言葉を理解すると同じような構造で訳文を出力すると言われ、TOEIC 900点以上の人間と同等の訳文も生成可能だとも言われている

▼ 2018年以降：LLMで文章の文脈を理解する能力に優れ、多様な言語の翻訳もできた

- ニューラル機械翻訳は翻訳に特化した技術であり、特定の言語が言語への翻訳や専門分野の翻訳において強みを発揮している

▼ めぐる動向

▼ 探索・推論

▼ 迷路（探索木）：構造表現を木のような構造（ツリー）をしているもの

▼ 幅優先探索

- 最短距離でゴールに辿り着く解
- 探索の途中で立ち寄ったノードを全て記憶するので、複雑な迷路ではメモリ不足可能

▼ 深さ優先探索

- 行けるところまで行って、行き泊まりになったら1つ手前のノードに戻って探索
- メモリはあんまりいらないが、最短距離であるかは限らない
- ▼ ハノイの塔（パズル）
 - 探索木にも変換できる
- ▼ ロボットの行動計画
 - ▼ プラニング
 - 状態遷移を表す矢印をロボットの行動都みなして構成した空間を探索
 - ▼ STRIPS（Stanford Research Institute Problem Solver）
 - 前提条件→行動→結果
 - ▼ SHRDLU
 - ▼ 1968～1970にデリー・ウィノグラード開発されシステム
 - 英語による指示を受けて、コンピュータ画面に絵かれる積み木の世界を動かす
 - 自然な会話はできる
 - デリー・ウィノグラードはHCI（ヒューマン・コンピュータ・インタフェース）研究分野へ移り、Googleの創業者の一人のラリー・ページを育てていた
 - 成果をCycプロジェクトに引き継がれた
- ▼ ボードゲーム（オセロ・チェス・将棋・囲碁）
 - 2016年3月、AlphaGoを4勝1敗で李世石を勝った
 - ▼ 組み合わせは天文学的な数字で事実上全てを探索しきれない
 - ▼ 効率よく探索するため、コストの概念を導入
 - ▼ ヒューリスティックな知識（経験知、発見知）
 - あらかじめ知っている知識や経験を利用してコストを計算すれば、探索を短縮
 - ▼ Mini-Max法
 - ▼ 自分の番では自分が有利、相手の番では相手が有利を前提に戦略をたつ
 - 未来の局面から現在の局面に向けて逆算することで戦略を立つ。できるだけ遠い未来のゲームの状態（ゲームを深く先読みして）をは配慮し、思慮深い戦略を立つ。深さは（先読み）

▼ $\alpha\beta$ 法（アルファベータ法）

▼ Mini-Maxの無駄を省く方法、スコア計算必要ないノードを探索対象から外す

- スコアを最大選択の自分の局面、探索する必要のない相手の枝を切り落とす行為： α カット
- スコアを最小選択の相手の局面、探索する必要のない自分の枝を切り落とす行為： β カット

▼ モンテカルロ法

▼ プレイアウト

- コンピュータが2人の仮想的なプレイヤーを演じて、完全にランダムにゲームを進行し終局左せ

▼ ある局面からプレイアウトを複数回実施することと、どの方法が一番勝率が高いかを計算して、スコア評価を行う

- 人間がスコアのつけ方の考え方が不要、数多く打って最良のものを選ぶ
- ブルートフォース（力任せ）と同様に、組み合わせが爆発増えるケースがある

▼ ディープラーニング

- AlphaGo

▼ 知識表現

▼ 人工無脳

- 知識なしでも知性があるように感じる人間心理不思議

▼ 特定のルール・手順に沿って会話を機械的に処理するだけで、実際は内容を理解している訳ではない

▼ イライザ（ELIZA）

- 1964～1966年ジョセフ・ワイゼンバウム開発、パターン照合で応答するチャットボット。相手の発言を再利用して発言する手法
- 後ろのコンピュータゲームやスマートフォンの音声対話システムに影響あを与えて、会話ボットや人工無脳の研修につながっている
- 心理療法の分野にも影響を与えて、オンラインセラピストのシステムも発展していた

▼ 知識ベースの構築とエキスパートシステム

▼ エキスパートシステム

- ある専門分野の知識を取込み、その分野の専門家のように振る舞うプログラム
- ▼ マイシン (MYCIN)
 - 1970年代、スタンフォード大学開発され
 - 血液中のバクテリアの診断支援のルールベース
 - 正確率は69%、専門医の80%より低い、専門医ではない医師より良い結果
- ▼ DENDRAL
 - ▼ 1960年代末、スタンフォード大学開発、実用指向AI真ののエドワード・ファイゲンバウム開発
 - 未知の有機化合物を特定する
 - 1977年実世界の問題に対する技術を重視した「知識工学」を提唱
 - 1970年代後半～1980年代、多く開発された
- ▼ IBMのワトソン (Watson)
 - 2011年アメリカのクイズ番組で優勝...Question-Answering (質問応答) 研修分野の成果
 - ▼ ウィキペディアの情報をもとにライトウェイト・オントロジーを生成して、それを解答に使う
 - 意味の理解より、質問に含まれるキーワードと関連しそうな答えを高速に検索に近い
 - 実用レベルまでできた、医療診断や「シェフ・ワトソン」で新しい料理のレシピを考えの応用など、コールセンター、人材マッチング、広告などなどで活用している
 - ▼ 「ロボットは東大に入れるか (東ロボくん)」
 - 2011年開始、2020年まで続けられ
2016年6月は進研模試で偏差値57.1でほとんどの私立大学に合格できるレベルまでできたが...その後は改善は見込めなく、2016年から最後の模試を中止、各教科での研究を深めるフェーズに移り
- ▼ 知識獲得のボトルネック (エキスパートシステムの限界)
 - ドキュメント・事例から自然言語処理や機械学習より取得できるが
 - ▼ 最大の知識源の専門家からの暗黙知 (経験的な) の獲得は困難
 - インタビューシステム: このよう事情から知識獲得のため開発された

- 知識のお互いが矛盾、一貫性ないものも出て、知識ベースを保守するのが困難
- ▼ 一部の専門家だけ持つ高度な知識を明示的体系化でき、常識的な知識は暗黙d明文化されていない者は不向き
 - ▼ コンピュータで知識を扱うための方法論
 - 意味ネットワーク
 - オントロジー
- ▼ 意味ネットワーク (semantic network)
 - 元々認知心理学における長期記憶の構造モデルとして考案され、現在でも、人工知能に重要な知識表現の方法の一つ
 - ▼ 「概念」をラベルのついたノードで表し、概念間の関係をラベルをついたリンク (矢印) で結んだネットワーク
 - ▼ is-a
 - 「である」の継承関係
 - ▼ 下位概念から上位概念へ矢印
 - 推移率成立
 - ▼ part-of
 - ▼ 「一部である」の属性関係
 - 推移率不成立がある
 - ...他の関係も多く、最低でも同一類は5以上ある概念に関連する知識がリンクをもとに辿れるため知識検索が容易
- ▼ オントロジー (ontology概念体系を記述するための方法論)
 - ▼ Cycプロジェクト
 - ▼ DENDRALの後継、1984年スタート、全ての一般常識をこコンピュータに取り込もう
 - 現在も継続中
 - 知識ベースのシステムが柔軟な能力を発揮するための膨大な知識を構築
 - ▼ エキスパートシステムのための知識の共有と再利用に貢献する学問として知識工学が期待されるようになり
 - 本来は哲学擁護するの存在論 (存在に関する体系的な理論) の意味
 - 人工知識の用語として、ドム・グルーバーによる「概念化の明示的な仕様」で定義され

- 「言葉（語彙）」や「その意味」、または「それらの関係性」を、他の人とも共有できるように、明確な約束事（仕様）として定義する
- ▼ 構築
 - ▼ 流派
 - ▼ 対象世界の知識をどのように記述すべきかを哲学的にしっかり考えて行うもの
 - ▼ ヘビーウェイトオントロジー（重量オントロジー）
 - ▼ その構成要素や意味の関係の妥当性について哲学的な考察、人間が関わることになる傾向が強く、時間とコストがかかる
 - 一例：Cycプロジェクト
 - 効率を重視し、とにかくコンピュータにデータを読み込ませてできる限り自動的に行うもの
 - ▼ ライトウェイトオントロジー（軽量オントロジー）
 - ▼ 完全さは求めない、実用的に使えるものが重視
 - ウェブマイニング
 - データマイニング
 - ▼ セマンティックWeb
 - Webサイトが持つ意味をコンピュータに理解させ、コンピュータ同士で処理を行わせるための技術
 - ▼ LOD（LinkedOpenData）
 - コンピュータ処理に適したデータを公開・共有する技術
 - HTMLに対して、データのWebの構築を目指す
- ▼ 機械学習・深層学習
 - ▼ 機械学習
 - ▼ 元々文字認識などのパターン認識の分野で長年蓄積された技術
 - 2000年以降、インターネットの普及によりデータが十分に蓄積され、機械学習はビックデータ（インターネットの成長とともに蓄積された大量のデータ）を注目集まれた
 - レコメンデーションエンジン、スパムフィルタなど実用化されるまで至った
 - ▼ 人工知能のプログラム自身がデータから学習する仕組み
 - サンプルデータの数が多ければ多いほど、望ましい学習結果が得られる（汎用は別）

- ▼ 次元の呪い: データの特徴が増えると、適切な学習を行うために必要なデータ量が著しく増加する傾向
 - 次元（特徴量）を減らす工夫
 - 多様かつ質の高いデータを大量に用意
- ▼ 統計的な自然言語処理
 - ▼ 従来の文法構造や意味構造を分析して短号単位で訳を割り当てるではなく、複数の単語をひとまとまりした単位（句までまたは文単位）で用意された膨大な対訳データをもとに、最も正確である確率がたかい訳を選択
 - ▼ 対訳データ（コーパス）
 - 「bank」という言葉には、「銀行」または「土手」という言葉が言語候補になるが、対訳データをたくさん持っていれば、近くにいる単語より、どちらが確率が高いを機械学習できる
- ▼ 特徴量設計
 - 「注目すべきデータの特徴」の選び方が性能を決定つける
- ▼ 特徴表現学習
 - ▼ 人間が特徴量を見つけ出すが難しいに対して、特徴量を機械学習自身に発見させる
 - ▼ ディープラーニング（深層学習）は「特徴表現学習」を行う機械学習アルゴリズムの一つである
 - 与えられたデータの特徴量を階層化し、それらを組み合わせることで問題を解決
 - ▼ ニューラルネットワーク自身が複数ステップのコンピュータプログラムを学習できる
 - 特徴量は入力データと無関係で、与えられた問題を解くために必要な処理に役たつ情報が特徴量として抽出の考えができる
 - ただし、特徴量の意味解釈は困難で、「判断理由が示せないブラックボックス型の人工知能」と言われるもある
- ▼ ディープラーニング（機械学習の一種）
 - ▼ ニューラルネットワーク
 - ▼ 生物の神経回路を真似することで学習を実現
 - 1943年、神経生理学者のウォーレン・マカロックと数学者のウォルター・ピッツが生物の神経細胞を単純化した最初のニューロンモデルを発表

- ▼ 1958年、アメリカのフランク・ローゼンブラットが学習可能なニューロンモデルを提出：パーセプトロン
 - 出力を見ながら「重み」を調整、直線分離可能な分類問題を解くが可能
 - 1969年、マービン・メンスキーら：パーセプトロンは直線で分離できない分類問題に対応できない、「パーセプトロンの限界」が明らかに
- ▼ ディープラーニング（深層学習）
 - 深く多層化したニューラルネットワークを使って、データに潜む特徴を自動的に学習する手法
- ▼ ニューラルネットワークを多層化は簡単が、全体を学習する方法は難しい
 - ▼ 1986年デビッド・ラメルハートら解決：誤差逆伝播法（バックプロパゲーション）を提唱
 - （それまでは、最後の層のニューロンだけを学習させるのは一般的な限界）
 - 1967年甘利俊一提唱した適応的パターン分類器の確率的な学習理論は基礎研究の一つ
 - 1979年、福島邦彦がネオコグニトロンが発表
 - ▼ 1989年、ヤン・ルカンは、ネオコグと類似アイデア（畳み込みニューラルネットワーク）の構造でLeNetと名付け、そのニューラルネットワークの学習に誤差逆伝播法を利用することを提案し、現在の画像認識ニューラルネットワークの基礎を構築された... (CNN)
 - ただ、3層より深くしても、精度が上がらない、あるいは学習が困難（計算速度の影響もあり）
 - ▼ 1992～1995 アメリカのベル研究所のヴァプニクらが開発した「サポートベクターマシン」で人気集まった
 - 当時はNNよりもの効果が高い、線型分割できない問題も解決、その後はBoostingと主な競争になる
 - ▼ 2006年 多層にしても学習精度が上がらない問題に対して、入力したものと同じものを出力するように学習する、オートエンコーダ（自己符号器）、活性化関数の研究で、4、5層（ディープ）までにしても学習可能になった
 - LSTMを勾配無くなる問題の理論を確立+ビックデータと計算力の発展

▼ キーイベント

- ▼ 2012年：画像認識の精度を競い合うILSVRC (ImageNet Large Scale Visual Recognition Challenge)
 - ▼ トロント大学のジェフリー・ヒントンらのSuperVisionが圧倒的な勝利 (15.3対2位の東大のISIの26.1)
 - この前に、機械学習の特徴量を決めるのは人間。
深層学習 (ディープラーニング) 登場: AlexNet
- ▼ 2017年：Attention is all your need (Transformer)
 - RNNやLSTMの痛みを解決、単語と単語の関係性 (アテンション (注意力) で広範囲にわたって学習可能、さまざまな文脈や状況で利用する単語意味やニュアンスを深く理解できるだけでなく、文中の任意の単語間の関連性を複数同時に効率よく計算することが可能になった)
- ▼ 2022年11月：ChatGPTの登場
 - ▼ LLMの訓練
 - 事前学習：大量な文章を与えさせ、一般的な言語の構造、文法、語彙などの基本を学び
 - ファインチューニング (微調整)：特定のタスクや応用分野に焦点を当てた訓練を行うことで、分脈を理解して論理的かつ適切な回答を生成する能力あるを向上、人のフィードバックよりも継続的な学習・改善する
 - 2020年、OpenAIはトランスフォーマーをベースとしてLLMの性能は、利用可能なデータ量や計算リソースに制限がなければ、パラメータの個数を多くすればするほど性能向上が見込めること。GPT2 (2019) 約15億、GPT3 (2020) 約1750億、GPT4 (2023) 約1兆個超え

▼ 機械学習の手法

▼ 学習の種類

▼ 教師あり学習

- ▼ 与えられたデータ (入力) を元に、そのデータがどんなパターン (出力) になるのかを識別・予測する

▼ 例

▼ 回帰問題

▼ 連続値を予測する問題

- 過去の売上から、将来の売上を予測

▼ 分類問題

- ▼ 離散値を予測する問題
 - 与えられた動物の画像が、何の動物かを識別
 - 英語の文章を与えられた時に、それを日本語の文章に翻訳
- ▼ 代表的な手法
 - ▼ 線形回帰 (Linear regression)
 - ▼ データ (の分布) があつたときに、そのデータに最も当てはまる直線を考えるというもの
 - L1 ラッソ回帰 (Lasso regression)
 - L2 リッジ回帰 (ridge regression)
 - ▼ 単回帰分析
 - 1 種類の入力だけを用いた回帰分析
 - ▼ 重回帰分析
 - 複数の入力を用いた回帰分析
 - ▼ ロジスティック回帰 (logistic regression)
 - 名前回帰ですが、実は分類問題に用いる手法
 - ▼ シグモイド関数
 - 値は0~1: 2クラス分類
 - ▼ 与えられたでデータが正例 (+1)、負例 (0) になるかの確率を求め、出力値が0.5以上ならば正例、0.5未満なら負例で、データを二分する。
 - 0.5以外の閾値でも可、例: 迷惑メール分類
 - ▼ ソフトマックス関数
 - ▼ 各種類の出力値はそれぞれ0~1の間、出力値の合計が1になるのような出力関数
 - 出力が確率分布
 - 多種類の分類を行う
 - ▼ ランダムフォレスト (random forest)
 - 複数の決定木を作成し、各決定木で用いる特徴量をランダムに抽出することで、特徴量の組み合わせ問題に対応する。
 - ▼ 学習に持ちいるデータも全データを使うのではなく、それぞれ決定木に対してランダムに一部のでツアアウトを取り出し学習に用いる (ブートストラップサンプリング)

- それぞれの結果を用いて多数決を取って、モデルの最終出力にする
- 複数のモデルで学習させるのはアンサンブル学習という、全体から一部のデータを用いて複数のモデルを用いて学習する方法：バギング (bagging)
- ▼ サポートベクターマシン (SVM: Support Vector Machine)
 - 高度な数学理論に支えられた手法、ディープラーニングが考えられる以前は機械学習において最も人気のあった手法の1つ。
 - ▼ (入力に用いる) 異なるクラスの各データ点との距離が最大となるような境界線を求めることで、パターン分類を行う
 - マージン最大化
 - 扱うデータ高次元
 - データが線形分類できない (直線で分類できない)
- ▼ 自己回帰モデル (autoregressive model, ARモデル)
 - ▼ 時系列データに適用される手法
 - 時系列データ分析のところを単純に時系列分析と言う
 - ▼ ベクトル自己回帰モデル (vector autoregressive model, VARモデル)
 - 複数種類の場合はベクトル
- ▼ 教師なし学習
 - ▼ 入力データそのものが持つ構造・特徴が学習
 - ECサイトの売上データから、こういった顧客層があるのかを認識
 - 入力データの各項目間にある関係性を把握
 - ▼ 代表的な手法
 - ▼ 階層なしクラスタリング (k-means法)
 - データをk個のグループに分けることを目的、もとのデータからグループ構造を見つけ出し、それぞれをまとめる
 - 1、まずは適当に各データをkこのクラスに振り分ける
 - 2、各クラスの重心をも止める
 - 3、求まったk個の重心と各データとの距離を求め、各データを最も距離が近い重心に対応するクラスに振り分け直す
 - 4、重心の位置が (ほぼ) 変換しなくなるまで2、3を繰り返す
 - ▼ 階層ありクラスタリング

- ▼ ウォード法
 - 各データの平方和が小さい順にクラスタを作っていくことで階層構造を作る
- ▼ 最短距離法
 - ▼ 最も距離が近い2つのデータ（クラスタ）を選び、それらを一つのクラスタにまとめることで階層構造を作る
 - デンドログラム（dendrogram）：樹形図が作成され
- ▼ 主成分分析（Principal Component Analysis: PCA）
 - ▼ データの特徴量間の関係性、すなわち相関を分析することでデータ構造かを掴む手法
 - 特に特徴量の数が多い場合に用いられ、相関を持つ多数の特徴量から、相関が少ない少数の特徴量へと次元削減することが主たる目的
 - ▼ 特異値分解（Singular Value Decomposition, SVD）
 - 主に文章データを扱う場合利用され、また、データの次元を2、3次元まで削減することによって可視化を行う手法もよく利用される
 - 線形、分散を最大限残す
 - ▼ 主成分分析以外の次元削減手法
 - ▼ 多次元尺度構成法（Multi-Dimensional Scaling, MDS）
 - 線形、分散を最大限残す、2次元への次元削減・可視化する手法
 - ▼ t-SNE（t-distributed Stochastic Neighbor Embedding）
 - 2次元、3次元へ、局所的な近さ（クラスタ）を保存、非線形、可視化によく使う
- ▼ 協調フィルタリング（collaborative filtering）
 - ▼ レコメンデーション（recommendation）に用いられる手法の一つ、「対象ユーザがかっていないが、似ているユーザ測っている商品を推薦する」
 - 事前にある程度の参考できるデータがない限りに、推薦を行えない：コールドスタート問題（cold start problem）
- ▼ コンテンツベースフィルタリング（content-based filtering）

- ユーザ側ではなく、商品側に何かしらの特徴量を付与し、特徴が似ている商品を推薦する。対象ユーザのデータさえあれば推薦を行うことができる
- ▼ トピックモデル (topic model)
 - ▼ クラスタリングモデルの一種、データを一つのクラスタに分類するk-meansと異なり、複数のクラスタにデータを分類する。
 - ▼ 代表的な手法
 - 潜在的ディリクレ配分法 (latent Dirichlet allocation, LDA)
- ▼ 強化学習 (Reinforcement Learning)
 - ▼ 「行動を学習する仕組み」、ある環境下で、目的とする報酬（スコア）を最大化するためにはどのような行動を取っていけばいいかを学習
 - ▼ 状態、行動、報酬のやり取りを1時刻ごとに進めて考え、「将来にわたって獲得できる累積報酬を最大化する＝累積報酬 R_t を最大化するような状態 S_t と行動 a_t の対応関係を求めること」
 - 1、エージェントは時刻 t において環境から状態 S_t を受け取る
 - 2、エージェントは観測した状態 S_t から行動 a_t を選択して実行する
 - 3、環境が新しい状態 S_{t+1} に遷移する
 - 4、エージェントは遷移に応じた報酬 r_{t+1} を獲得
 - 5、得られた報酬をもとに、選択した行動の良し悪しを学習する
 - 6、ステップ1、へ
 - 割引率：未来の価値を今の価値へ変換するの割引率
- ▼ バンディットアルゴリズム (Multi-Armed Bandit Problem)
 - ▼ 組み合わせが無数のなかに行動の選択を考える課題
 - ▼ 活用 (exploitation)
 - 現在知っている情報の中から報酬が最大隣るような行動を選ぶ
 - ▼ 探索 (exploration)
 - 現在知っている情報以外の情報を獲得s得るために行動を選ぶ
 - ▼ ϵ -greedy方策 (epsilon-greedy policy)
 - 基本は活用、一定確率 ϵ で探索（ランダム行動を選択）
 - ▼ UCB方策 (upper-confidence bound policy)
 - 期待値の高い選択を選ぶのを基本戦略としつつ、これまで試行回数が少ない行動は優先的に選択する

- ▼ マルコフ決定過程モデル (Markov)
 - ▼ マルコフ性 (Markov Property)
 - 強化学習ではエージェントの行動 a_t によって、状態が S_t から S_{t+1} に遷移すると述べたが、ここに環境に対して暗黙的にある仮定をおいている（現在の状態 S_t から将来の状態 S_{t+1} へ遷移する確率は、現在の状態 S_t にのみに依存し、それより過去の状態には一切依存しない）の性質
 - 一般に状態遷移にマルコフ性を仮定したモデルのことを、マルコフ決定過程と言う
 - ▼ 価値関数
 - 状態価値関数 (state-value function)
 - 行動価値関数 (action-value function)
 - ▼ TD学習 (Temporal-Difference)
 - ▼ 強化学習における 価値関数を推定する手法
 - モンテカルロ法 (MC) : 実際の経験（エピソード全体の報酬）を使って価値関数を更新
 - 動的計画法 (DP) : 既存の価値の推定を利用して更新
 - 逐次更新: 各ステップで価値関数を更新可能、エピソード終了を待たない
 - ブートストラップ: 次の状態の価値推定を使って現在の価値を更新
 - MCとDPの利点を統合: 実際の経験から学習でき、環境モデルがなくてもよい
 - ▼ 方策勾配 (Policy Gradient)
 - ▼ 方策勾配法: 直接最適な方策を見つけ出そうのアプローチ
 - ロボット制御など、特に行動の選択肢が大量にあるような課題で用いられる。
 - ▼ 方策をあるパラメータで表させる関数として、（累積報酬の期待値が最大となるように）そのパラメータを学習することで、直接方策を学習していくアプローチ
 - ▼ REINFORCE

- QやV値を学習ではなく、直接方策を学習
 1. モンテカルロ法：軌跡全体が終了してから累積報酬を計算
 2. モデルフリー：環境の遷移モデルは不要、サンプルのみで学習
 3. 直接方策最適化：Q値を使わず、方策の確率分布を直接更新
 4. 高分散問題：累積報酬のばらつきが大きいため、通常 baseline（基準値）を使って分散を減らす

▼ Actor-Critic

- 行動器と方策を評価する評価器で構成、完治関数ベースおよび方策勾配ベースの考え方を組み合わせる

▼ モデルの選択・評価

▼ データの扱い

- ▼ 未知のデータに対しての予測能力を見る（準備できないが、かわりに擬似的に未知のデータを作り出す）

- ▼ 手元の全データを、学習用データ（訓練データ）、評価用のデータ（テストデータ）にランダム分割評価：交差検証も言う

▼ ホールドアウト検証

- 事前にデータを訓練データとテストデータを分割、（特に全体データ数が少ない場合）たまたまテストデータに対する評価が不正に良くなってしまう

▼ k-分割交差検証

- 訓練データ・テストデータの分割を複数回行う、それぞれで学習・評価を行うアプローチ
- 訓練データをさらに、訓練データと検証データに分割する場合もある、検証データで評価&モデル調整でモデルを決定+テストデータで最終効果評価

▼ 評価指標

- ▼ 予測誤差（損失）：主に回帰問題に対しての

- 分類問題は明確に評価できるが、回帰問題は数値そのものを予測するので、単純分けるの評価はできないため導入する

▼ 平均二乗誤（mean squared error, MSE）

- 対象となる各データの予測値と実際の値の誤差（差分）をそれぞれ2乗し（正負の誤差が打ち消し合うを防止）、総和を求めたもの

- ▼ 二乗平均平方根誤差（root mean squared error, RMSE）

- 平均二乗誤差のルートを取る
- ▼ 平均絶対値誤差 (mean absolute error, MAE)
 - 二乗の代わりに絶対値を取る
- ▼ 正解率・適合率・再現率・F値：主に分類問題に対しての
 - ▼ 混同行列 (confusion matrix)
 - ▼ 予測値と実際の値それぞれの組み合わせ
 - 真陽性： True Positive： TP
 - 偽陽性： False Positive： FP
 - 真陰性： True Negative： TN
 - 偽陰性： False Negative： FN
 - ▼ 正解率 (accuracy)： $(TP + TN) / \text{全データ}$
 - 全データ中、どれだけ予測が当たったかの割合
 - ▼ 適合率 (precision)： $TP / (TP + FP)$
 - 予測が正しいの中で、実際に正であったものの割合
 - ▼ 再現率 (recall)： $TP / (TP + FN)$
 - 実際に正であるものの中で、正だと予測できた割合
 - ▼ F値 (F measure)： $(2 \times \text{precision} \times \text{recall}) / (\text{precision} + \text{recall})$
 - 適合率と再現率の調和平均
- ▼ 過学習 / 過剰適合 (overfitting、オーバーフィッティング)
 - 訓練データにのみ最適化されすぎ
- ▼ ROC曲線とAUC
 - ▼ ROC曲線 (receiver operating characteristic curve)
 - ▼ TPR (True Positive Rate = Recall) を縦軸、FPR (False Positive Rate) を横軸、閾値を0~1に変換させた際の曲線
 - モデルの性能によって大きく変化するもの、モデルが全く予測ができない (ランダム予測) と同じなら、ROC曲線は斜めの直線になり
 - ▼ AUC (area under the curve)
 - ROC曲線より下部の面積、1に近いほどモデル性能が高いことを表す
- ▼ モデルの選択と情報量

- ▼ モデルを複雑にすればするほど複雑な表現ができる、逆に、表現しなくても良いノイズ部分まで表現してしまう（過学習）可能性もある
 - モデルが複雑になればなるほど、学習に必要な計算コストも増えてしまうので、「ある事柄を説明するためには、必要以上に多くを仮定すべきでない」という指針を表すオッカムの剃刀（occam's razor / Ockham's razor）
- ▼ モデルとタスクの相性：情報量基準の指標を利用
 - ▼ 赤池情報量基準（Akaike's Information Criterion, AIC）
 - 予測性能を重視 → データにうまくフィットするなら少し複雑でもOK
 - 回帰モデル、多項式フィッティング、時系列予測などのモデル選択
 - ▼ ベイズ情報量基準（Bayesian Information Criterion, BIC）
 - モデルの正当性・単純さを重視 → サンプルが多いと複雑モデルに強いペナルティ
 - 統計モデル、因子分析、混合モデル、クラスタリングのモデル選択

▼ ディープラーニングの概要

- ▼ ニューラルネットワーク
 - ニューロン（神経細胞）をお互い結びつくことを神経回路、ニューロンを再現する。
- ▼ 単純パーセプトロン（Perseption）
 - 1958年にフランク・ローゼンブラット（Frank Rosenblatt）が提案した線形二値分類モデルで、最も基本的なニューラルネットワーク
- ▼ 複数の特徴量（入力）を受け取り、一つの値を出力するモデル、単純すぎでほぼ実用されない（線形分類しか解くことができない）
 - 入力層
 - 重み
 - 出力層
- ▼ ロジスティック回帰と数式上の表現は全く同じ
 - 層の間をどのように伝播させるかを調整する関数を活性化関数（シグモイド関数関数もその一つ）
- ▼ 多層化パーセプトロン（MLP: Multi-Layer Perseption）
 - 入力層→隠れ層（中間層）→出力層

- ▼ パラメータ：モデルが学習する数値
 - 予測誤差を誤算関数、値最小化するの数学問題となる
 - ハイパーパラメータ：モデルの構造や振る舞いを決めるものの、最適化計算で求めない値のこと
- ▼ ディープラーニング
 - 隠れ層を増やしたニューラルネットワーク
 - 実用上、ニューラルネットワークモデル自体をディープニューラルネットワークと呼ぶは大半
- ▼ ハードウェアの制約と進歩
 - ▼ モーラ定理
 - 半導体の性能と集積は、18ヶ月ごとに2倍になる
 - ▼ CPU (Central Processing Unit)
 - さまざまな種類のタスクを順番に処理しておく（ま〜誤解しやすい説明）
 - ▼ GPU (Graphics Processing Unit)
 - 大規模な並列演算処理が得意
 - ▼ GPGPU (General-Purpose computing on GPU)
 - 元々画像処理に最適化されたものを、画像以外の計算にも効率良く使えるように改良
 - ▼ TPU (Tensor Processing Unit)
 - テンソル計算処理に最適化、機械学習受に特化した演算処理装置
- ▼ ディープラーニングのデータ量
 - ▼ 経験則
 - バーニーおじさんのルール：モデルのパラメータ数の10倍のデータ数が必要
 - 現実性ではないもあるので、いろんなテクニックで対処している
- ▼ 様々なアプローチ
 - ▼ 誤差関数（損失関数）
 - ▼ 平均二乗誤差関数
 - 訓練データを用いてこの関を最小化する。（微分＝導数（Derivative）を利用して最初値を導く）

- 分類問題は別の関数が用いられるが、回帰問題は大半誤差関数を利用している
- ▼ 交差エントロピー誤差関数 (cross entropy)
 - ▼ 2つの確率分布がどれくらい異なるかを定式化したもの、分類問題で最も用いられる誤差関数
 - モデルの各クラスの予測値は0~1の確率で表現、正確値と予測値をそれぞれ確立分布として捉えると、2つの分布が一致するときに最小値を取る関数
 - ▼ なぜ平均二乗誤差関数より人気なのは、微分計算に交差エントロピーの式がシグモイド関数やソフトマックス関数に含まれる指数計算と相性が良いこと
 - 特に以前自分で微分式を計算する時代は、計算が簡単にできるかどうかはかなり重要
- ▼ その他誤差関数
 - ▼ 距離学習における誤差
 - ▼ 距離学習 (metric learning) : ディープラーニング依存も存在、ディープラーニングを応用した手法を深層距離学習 (deep metric learning) と呼ぶ
 - データの類似度を推定、顔認識や類似データの検索など様々な分野で利用している
 - ▼ 深層距離学習
 - ▼ Siamese Network
 - 2つデータを用いる、誤差はContrastive Loss
 - ▼ Triplet Network
 - 3つデータを用いる、誤差はTriplet Loss
 - ▼ 生成モデルにおける誤差
 - ▼ 生成問題: 画像や文章を生成する (分類問題、回帰問題など問題...)
 - ▼ 与えられたデータをうまく分けることができる境界線を見つけるのではなく、与えられたデータがどのような確率分布に基づいているかを見つけること。
 - 「今観測できているデータは何らかの確率分布に基づいて生成されているはずだ」の考え
 - ▼ データ分布とモデル分布の「ズレ」を誤差関数として定義される

- カルバック・ライブラー情報量 (Kullback-Leibler divergence: KLダイバージェンス)
- イェンゼン・シャノン情報量 (Jensen-Shannon divergence: JSダイバージェンス)
- ▼ 生成モデルをディープラーニングを活用したものは深層生成モデルと呼ぶ
 - 例: 変分オートエンコーダ (variational autoencoder, VAE) では、KLダイバージェンスをベースとして誤差関数 (厳密は目的関数) が最適化計算に用いられる
- ▼ 正則化 (regularization)
 - ▼ 過学習に対しての色々考えられる対策のこと
 - 訓練データへの過剰な当てはまりを抑制しつつ、より単純なモデルが当てはまるようにすることを求め
 - ▼ 誤差関数にペナルティ項を課すが一般的
 - ▼ 誤差関数に制約条件を課すことによって、モデルのパラメータが取り得る範囲を制限するアプローチ
 - ▼ L0正則化
 - 0ではないパラメータの数で正則化、計算コストが多くて一般用されない
 - ▼ L1正則化
 - L1ノルムは重みなどモデルパラメータの各成分の絶対値の和
 - 一部のパラメータの値をゼロにすることで、不要なパラメータを削減することができる
 - ▼ L2正則化
 - L2ノルムは重みなどモデルパラメータの各成分の二乗和の平方根なので距離に相当
 - パラメータの大きさに応じてゼロにちかずけることで、汎化された滑らかなモデルを得ることができる
 - ▼ ラッソ回帰
 - 線形回帰に対してL1正則化を適用する手法
 - ▼ リッジ回帰
 - 線形回帰に対してL2正則化を適用する手法
 - ▼ ElasticNet

- ラッソ回帰とリッジ回帰を組み合わせ手法を利用した
- ▼ ドロップアウト (dropout)
 - ▼ ランダムにニューロンを「除外する」
 - ドロップアウトより、違うネットワークで学習させ、事実上内部的にアンサンブル学習となる
- ▼ 最適化手法
 - ▼ 勾配降下法 (gradient descent)
 - ▼ 実際のモデルの学習では、解析的に解を求めに行くのではなく、アルゴリズムを用いて最適解を探索する、というアプローチである。勾配（微分値＝導数）に沿って降りていくことで解を探索する手法。
 - ▼ 接線の傾き
 - 微分値が勾配をあらわっているの直感的な理解
 - ▼ イテレーション
 - k値を繰り返して計算した回数
 - ▼ 学習率
 - 勾配に沿って一度にどれだけ降りていく
 - ▼ バッチ勾配降下法
 - ▼ 全データの予測誤差の総和を用いて更新式の計算を行うこと、単なる勾配降下法を書く場合バッチ勾配を指すが一般
 - ▼ バッチ (batch)
 - データの固まりを表し、一回の更新にすべてのデータを用いるためのような名前付け
 - データ全量で回すので、最急降下法とも呼ぶ
 - ただし、全データ扱うので、各層にメモリが消費足りない可能
 - ▼ 確率的勾配降下法 (Stochastic Gradient Descent, SGD) / オンライン学習
 - ▼ 訓練データをシャッフルし、データを一つランダムに抽出、そのデータの予測誤差だけを用いて更新式を計算する
 - ニューラルネットワークの学習では、基本的に全データをシャッフルした後、一つ一つのデータを結局すべて更新計算に用いることが大半
 - エポック：全データを用いる回数

- イテレーション：誤差より更新計算の回数（オンライン学習の場合、1エポック＝データ数分のイテレーション）
- ▼ ミニバッチ勾配降下法
 - ▼ すべてのデータをいくつかのデータセットに分割する、各データセット内のデータ数のことをバッチサイズと言う
 - ▼ 一番多く使われる手法
 - データセット分のメモリのみ確保必要で、メモリ負担が相対的に低い
 - 確率的勾配降下法のようにデータによって探索方向がばらつくにも起こりにくい
 - 1エポック＝ミニバッチ数分のイテレーション
- ▼ 勾配降下法の問題と改善
 - ▼ 学習停滞：局所最適解になって、本当の最適解のことの全域最適解をうまく取れない可能
 - ▼ 学習率を大きくして、鞍点を超える手法がありが、適切なタイミングで学習率を小さくしていくが必要。
 - ▼ 鞍点
 - ある次元から見れば極小であるものの、別次元から見ると極大になる点
 - ▼ プラトー (plateau)
 - 一度鞍点付近に陥ちると、そこから抜け出すことが困難になる、その停留状態であること
 - ▼ ディープラーニングではパラメータの次元が大きい、鞍点が発生確率が高くなる。鞍点（そして局所最適解）に陥ちってしまう問題を回避するには、どの方向に沿って学習を進んでいるときに学習率を大きく（あるいは小さく）すべきかを考える必要
 - ▼ モーメンタム (momentum)
 - ディープラーニングより前、1990年代提唱されたモーメンタム (momentum)：物理の慣性の考え方を適用したもの、最適化の進行方向に学習を加速させ、学習の停滞を防ぐものもある
 - ▼ Adagrad (Adaptive Gradient Algorithm)
 - ▼ 過去の勾配の二乗和に基づきパラメータごとの学習率を調整。よく更新されるパラメータほど学習率を小さくする。
 - 疎な特徴に強いが学習率がどんどん小さくなる

- ▼ Adadelta (Adaptive Delta)
 - ▼ Adagrad の学習率減衰問題を解決。過去の勾配二乗の累積ではなく、指数移動平均 (EMA) を使う。
 - Adagradの減衰問題を改善、学習率不要
- ▼ RMSprop (Root Mean Square Propagation)
 - ▼ Adadeltaと似て、勾配の二乗の指数移動平均でスケールリングする。Hintonによる提案。
 - 非定常目的関数で安定 (RNNでよく使われる)
- ▼ Adam (Adaptive Moment Estimation)
 - ▼ RMSpropのスケールリングに加え、**一次モーメント (勾配の移動平均) と二次モーメント (勾配二乗の移動平均) **を組み合わせ、バイアス補正も行う。
 - デフォルト強力、収束速いが汎化性能に課題あり
- ▼ AMSGrad (Adaptive Moment Estimation with Long-Term Memory (AMSGrad))
 - ▼ Adamの二次モーメント推定を「過去最大値」に置き換え、単調性を保証し、非凸問題でも理論的収束性を強化。Adamの不安定性を改善。
 - Adamで学習が不安定/収束しない場合利用
- ▼ AdaBound (Adaptive Bound Optimizer (Adam with dynamic bounds))
 - ▼ Adamの変種。学習率に上下限 (動的境界) を設け、学習の初期はAdamのように自動調整、後半はSGDに近づく
 - Adamの速さ + SGDの汎化性能
- ▼ AMSBound (AMSGrad with dynamic bounds)
 - ▼ AdaBoundの拡張で、Adamの代わりに**AMSGrad (Adamの安定化版) **をベースにし、学習率に動的境界を適用。
 - より安定なAdaBound
- ▼ 早期終了 (early stopping)
 - ▼ 学習が進むにつれてテストデータに対する誤差関数の値が右肩上がりになる時点で止める
 - ジェフリー・ヒントンは Beautiful FREE LUNCH と表現している
- ▼ ノーフリーランチ定理

- あらゆる問題で性能の良い汎用最適化戦略は理論上不可能
- ▼ 二重降下現象
 - 一度テストデータに対する誤差が増えた後、再び誤差が減っていくの現象、それで、どのタイミングで学習をとめば良いかについては難しくなる
- ▼ ハイパーパラメータの探索
 - ▼ 例
 - ニューラルネットワークの層数
 - 各層のニューロン数
 - ドロップアウトの比率
 - L1、L2正則化はどれくらい有効か
 - ▼ ハイパーパラメータチューニング
 - ▼ グリッドサーチ
 - 調整したい（複数の）ハイパーパラメータの値の候補を明示的にいくつかを指定し、その候補のすべての組み合わせに対して学習・評価を行う
 - ▼ ランダムサーチ
 - ハイパーパラメータの値の候補を指定するではなく、代わりに取り得る範囲を指定。その範囲の中で何かしらの確率分布に基づいて乱数発生して実験を行う
 - ▼ ベイズ最適化（Bayesian Optimization）
 - 評価が非常に高コスト（例：ディープラーニングの学習、物理シミュレーション）
 - 低次元向き（10～50次元程度まで）
 - ▼ 遺伝的アルゴリズム（Genetic Algorithm）
 - 離散的なパラメータ・制約が多い・大域探索が必要
 - 高次元でも適用可能だが計算量増加
 - ▼ 誤差逆伝播法（backpropagation）
 - ▼ 複数のパラメータに対して微分を効率よく求めるために考えられた、ネットワークの各層は、その層に伝播してきた値は自分より前の層（入力層に近い層）のパラメータの値が含まれている（計算に使われている）ことに着目し、微分計算を再利用することを考えている

- 合成関数の微分、あるいは連鎖率と呼ばれる微分の公式を用いる、一つずつ計算より効率化された
- 勾配降下法を用いてニューラルネットワークの学習をする際に、微分計算を誤差伝播法を用いて効率よく行く
- ▼ 信用割当問題 (credit assignment problem) を解決できる
 - 信用割当問題: モデルのどの部分がその予測結果をもたらしているのかわからない問題
- ▼ 新しい挑戦
 - ▼ 勾配消失問題
 - 誤差の逆伝播する過程で勾配が小さくなりすぎ
 - ▼ 勾配爆発問題
 - 誤算の逆伝播する過程で勾配が大きくなりすぎ
 - ▼ バッチ正規化 (Batch Normalization, BN)
 - 各ミニバッチ内で層の入力 x を標準化することで、各層の入力分布を安定させ、活性が飽和領域 (シグモイド・ $\tanh$ 関数の飽和領域) に行きにくくすることで、勾配が0に近づくのを防ぎ、勾配消失を緩和する
- ▼ 活性化関数
 - 任意の実数を (非線形に) 変換することができる関数でさえあれば、どんな関数であろうと活性化関数として用いるのに特に問題ない
 - ▼ ステップ関数
 - 閾値より0か1を出力する関数。微分は0なのでディープラーニングはほぼ利用しない
 - ▼ シグモイド関数と勾配消失問題
 - シグモイドの微分した関数 (導関数) は0~0.25 (シグモイドの値区間は0~1)、隠れ層を遡るごとに、伝播していく誤差はどんどん小さくなっていく
 - ▼ $\tanh$ 関数 (hyperbolic tangent)
 - 値範囲は-1~1、微分した関数 (導関数) は0~1
 - それでシグモイド関数はほぼすべて $\tanh$ 関数に置き換えの方が良いになり
 - ▼ ReLU関数 (Rectified Linear Unit)
 - ▼ 値範囲は0~1、0以外の場合は0、0以上の場合は0~1。微分は0以下0、0以上1。

- ReLUを活性化関数に用いることによって、ディープニューラルネットワーク全体をそのまま効果的に学習できる場合が多くなり
- tanh関数よりも、誤差逆伝播の際に勾配が小さくなりにくい、但し0以下の場合、微分は0にあるので、学習がうまくいかない場合もある

▼ Leaky ReLU

- ▼ 値は0以下の場合、0ではなく、僅かな傾きを持っている
 - ただし、実際には精度が出る時もあれば、ReLUの方が良い場合もある

▼ Parametric ReLU

- Leaky ReLUの値が0以下の直線の傾きを学習によって最適化

▼ Randomized ReLU

- 複数の傾きをランダムに試す

▼ ディープラーニングの要素技術

▼ ネットワーク構成要素

▼ 畳み込み層 (Convolution Layer)

- ▼ フィルタ (カーネル) を用いて、特徴を特徴マップとして抽出する畳み込み処理

- フィルタと同じ位置のかけ合わせで総和処理で特徴マップ抽出

▼ パディング処理

- ▼ 入力の上下左右に要素を追加、0の値で埋め
 - 入力と同じサイズの特徴マップを抽出したい、辺の特徴も抽出したいなどで利用する

▼ ストライド (stride)

- フィルタを重ねる位置をずらす幅

▼ Atrous Convolution / dilated convolution (膨張畳み込み)

- カーネルの各要素の間に「dilation rate (膨張率)」だけ間隔をあけて適用、パラメータ数や計算コストを増やさずに受容野 (receptive field) を広げることができる。

▼ Depthwise Separable Convolution

- ▼ 空間方向とチャネル方向に対して独立に畳み込み処理を行う
 - 空間方向はDepthwise Convolution、特徴マップのチャネル毎に畳み込みを行う

- チャンネル方向はPointwise Convolution、 1×1 （チャンネル数の分を）の畳み込みを行う
 - 普通の畳み込みは空間 $\times$ チャンネル全体の中のブロックフィルタで畳み込み
- ▼ プーリング層（Pooling Layer）
 - ▼ 特徴マップをルールに従って小さくする処理、ダウンサンプリングあるいはサブサンプリングとも呼ばれる
 - ▼ 最大値プーリング（max pooling）
 - ある局所領域ごとの最大値を抽出する
 - ▼ 平均値プーリング（average pooling）
 - 平均値を抽出する
 - ▼ 特徴を集約して、特徴次元を削減する。プーリング処理も畳み込み処理と同様、画像のズレに対する頑健性を持ち、不変性を獲得
 - プーリング = 局所的特徴の要約 → 特徴マップの次元圧縮
 - 局所平行移動へのロバスト性 → 不変性の獲得（translation invariance）
- ▼ 全結合層（Fully Connected Layer / Dense Layer）
 - ▼ 層に入力された特徴に対して重みをかけて、総和した値をユニットの値とする、通常のニューラルネットワークと同じ線形関数です。
 - ▼ CNN（LeNet）
 - 畳み込み層・プーリング層を繰り返した後、全結合層を積層する。
 - 従来型CNN（VGG, AlexNetなど）の分類層でよく使用
- ▼ Global Average Pooling
 - ▼ 特徴マップの平均値を1つのユニット（ニューロン）の値にする
 - 出力ベクトルの長さはチャンネル数と同じ
 - 学習パラメータなし。モデルが軽量で過学習リスクが低い。
 - 空間方向の情報を平均化するため、位置依存性は失われる。
 - ResNetやMobileNetなど近年のモデルで広く採用され、軽量化・汎化性能向上に貢献
- ▼ 正規化層
 - ▼ 正規化処理
 - 特徴の分布のばらつきを抑制するために、各層の特徴の平均値が0、分散が1になるような処理

- ▼ バッチ正規化 (Batch Normalization (BN))
 - ▼ 各層で活性化関数をかける前の特徴的を正規化（データを変形する）する、どのように変形すれば良いかは学習によって決める
 - チャンネル数分正規化を行う
 - 学習時、ミニバッチで複数の入力データ用いて、各層において、データ間での特徴のバラツキをチャンネル毎に正規化するように学習
 - バッチサイズはハイパーパラメータとして事前に設定
- ▼ レイヤー正規化
 - ▼ データ毎に全チャンネルをまとめて正規化
 - バッチサイズ分正規化を行う
- ▼ インスタンス正規化
 - ▼ データ毎に書くチャンネルを正規化
 - チャンネル数 × バッチサイズ分の正規化を行う
- ▼ グループ正規化
 - ▼ データ毎に複数のチャンネルをまとめて正規化
 - 複数インスタンスをグループして正規化を行う
- ▼ メリット
 - 学習がうまくいきやすく、過学習し難くなる
- ▼ スキップ結合
 - ▼ 「超」深層にすると、学習時に誤差を入力層近くまで逆伝播しにくくなるため、層を飛び越えた結合をする
 - ▼ ResNetで導入され
 - 層が深くなっても、層を飛び越える部分は伝播しやすくなる
 - 様々な形なネットワークのアンサンブル学習になっている
- ▼ リカレンとニューラルネットワーク (Recurrent Neural Network, RNN)
 - ▼ 時系列を扱うため、ネットワークの中間状態を次の入力の処理に利用する回帰結合層を含むネットワーク
 - 入力層 + (過去の) 回帰結合層 → 回帰結合 → 出力層
 - ▼ エルマンネットワーク (Elman Network)
 - ▼ 回帰結合層の情報を伝播して、次の時刻の入力とともに利用するモデル
 - 自然言語処理などで利用

- ▼ ジョルダンネットワーク (Jordan Network)
 - ▼ 出力層の情報を伝播して、次の時刻の入力とともに利用するモデル
 - ロボットの運動制御などで利用
- ▼ 代表例
 - ▼ 言語モデル (Language Model, LM)
 - 音声処理でも自然言語処理でも利用できる、後継のPretrained Modelsの基礎ともなっている
- ▼ LSTM (LongShort-Term Memory)
 - ▼ RNNの課題
 - ▼ 勾配消失問題
 - RNNは時間軸を展開すると深いニューラルネットワークになるので、誤差を逆伝播する際に、過去に遡るにつれて勾配が消えていってしまう
 - ▼ 入力重み衝突
 - 通常のニューラルネットワーク：関係ある情報を入力された際は重みが大きくあるべきですし、関係のない情報が入力された際は、重みは小さくあるべき
 - 時系列では、「今の時点では関係ないけれど、将来の時点では関係ある」という入力を与えられた際に、重みは大きくすべきであり、同時に小さくすべきであるの矛盾を抱える
 - 出力重み衝突
 - ▼ 通常のニューラルネットワークの活性化関数を工夫するなどに対して、LSTMは回帰結合層の構造を変えることで、勾配消失、重み衝突を解決
 - ▼ LSTMブロック
 - 通常のニューラルネットワークにおけるユニットの一つがこのLSTMブロック
 - ▼ 誤差を内部に留め、勾配消失を防ぐためのセル
 - セルはCEC (Constant Error Carousel) とも言われ、
 - ▼ 必要な情報を必要なタイミングで保持・消却させるためのゲート
 - ▼ 入力ゲート
 - 入力重み衝突防ぐのため
 - ▼ 出力ゲート
 - 出力重み衝突防ぐのため

▼ 忘却ゲート

- 誤差が過剰にセルに停留するのを防ぐため、リセットの役割を果たす

- LSTMは時系列データを扱う上ではデファクトスタンダード（暗黙的な標準）になっているモデルとも言える

▼ LSTMはセルやゲートそれぞれを最適化が必要で、計算量が多く必要になる

▼ GRU (Gated Recurrent Unit)

- リセットゲート、更新ゲートが「入力ゲート、出力ゲート、忘却ゲート」の代わりを果たし

▼ Bidirectional RNN

- ▼ 課題例：時間情報の途中が欠けていてそれが何かを予測したい場合は、過去の情報だけでなく、過去と未来両方の情報を使って予測した方が効果的と言える

- 自然言語においては例えば単語の品詞を推定したい場合などは、過去の単語だけではなく未来の単語情報も用いる方が高精度に行える

- ▼ 通常のRNNは過去から未来への一方向でしか学習することができないに対して、RNNをふたつ組み合わせ流ことで、未来から過去方向も含めて学習できるようなモデル

- 2つのRNNを組み合わせと言っても、それぞれは過去用と未来用とで独立しているので、取り立てで複雑などところもない

▼ エンコーダ・デコーダ

- 入力が時系列、出力が一つではなく、入力が時系列なら、出力も時系列で予測したいものを、Seq2Seq (sequence-to-sequence)

▼ RNN エンコーダ-デコーダ

- 類似に2つのRNNをくみあわせて、入出力どちらもRNNで対応する

▼ エンコーダ

- 入力データを処理して符号化

▼ デコーダ

- ▼ 符号化された入力情報を使ってデコーダが復号化

- 出力も時系列のため、全出力を一気に行うことは不可能、デコーダは自身の出力が次のステップで入力として受け取って処理すること

▼ RNNの学習

- ▼ 通常のニューラルネットワークと同様に、入力層から回帰結合層に情報が伝播する経路がある
- ▼ RNNは過去の回帰結合層から（現在の）回帰結合層にも情報を伝播する経路を持つ
 - ▼ すなわく、これまでに与えられた過去の情報をどの程度現在の情報に反映することが学習する内容。誤差を過去に遡って逆伝播
 - ▼ BPTT (BackPropagation Through-Time)
 - 時間軸に沿って誤差を反映していく
 - ▼ 出力層をSoftmax関数で確率に変換し、正解との誤差を計算して誤差逆伝播によってパラメータの調整を行う
 - ▼ 教師強制 (Teacher Forcing)
 - 正解データを次の入力データとして利用すること
 - 機会翻訳でもデコーダへの入力として正解の翻訳文を利用するので、教師学習を利用している
 - RNNだけではなく、入力系列と出力系列が同じ場合には利用できる、トランスフォーマー学習などでも利用している
 - ▼ 露出バイアス (Exposure Bias)
 - テスト時は教師強制利用できないので、訓練時とテスト時で入力データの傾向に違いが出る、テスト時では訓練時ほどのパフォーマンスがでない問題
 - こちらは、言語生成AIにおける繰り返し (repetition)、矛盾 (incoherence)、ハルシネーション (hallucination) などのエラーの原因の一つ
- ▼ Attention
 - ▼ 誕生背景: RNNは (LSTMにしろ、GRUにしろ) 1つ前の状態と新たな入力から次の状態を計算するだけであり、過去の (BiRNNでは過去と未来) どの時刻の状態がどれだけ次の状態に影響するまでは直接まともていない
 - ▼ 「時間の重み」をネットワークに組み込んだのがAttentionと呼ばれる機構です
 - ▼ 過去の各時刻での回帰結合層の状態を保持しておき、それぞれの重みを求め、出力を計算する際に回帰結合層の状態を重み付き和を利用することで、時間の重みを考慮したモデルを実現
 - 入力と出力の対応関係「時間の重み」を可視化も可能

- Seq2Seqは長くなればなるほど全体の情報を適切に保持することができなくなり、Attention機構の導入で過去の情報を適切に重み付けして用いることが可能となり、長文であっても正確な翻訳が出力できるようになった

▼ トランスフォーマー (2017: Google)

▼ RNNの課題

- ▼ 機械翻訳モデルでは、それぞれRNNで構成されたエンコーダとデコーダをAttention機構により橋渡ししたような構造を持っている。

▼ Source-Target Attention / Encoder-Decoder Attention

- 入力文 (source) と出力文 (target) の橋渡しに使われるAttention機構

▼ 欠点

- 入力データを時間軸に沿って必ず1つずつ順番位読み込む逐次処理が必要→並列計算できず、処理速度が遅くなり
- 時系列の最初の時刻に入力した情報の影響が時間の経過とともに次第に薄れてしまう

- ▼ エンコーダとデコーダからRNNを排除し、代わりにSelf-Attention (自己注意機構) と呼ばれるネットワーク構造を採用

- ▼ ネットワーク全体をSelf-AttentionとSource-Target Attentionの2つ機構のみから構成され、並列計算がしやすく、RNNと比べる高速にモデルの学習が行える

- Self-Attentionでは遠い位置にある単語同士の関係もうまく捉えることができる

▼ Self-Attention (自己注意機構)

- ▼ Source-Target Attentionが入力文と出力文の単語間の関連度を計算したものに対し、Self-Attentionは入力文内の単語間または出力文内の単語間の関連度を計算したもの

- RNNで入力文内の単語間の関係計算にはその間にある単語数分のステップが必要に対し、Self-Attentionでは入力文内のすべての単語間の関係を1ステップで直接計算することが可能

- ▼ ある単語と他の単語との間の関係計算は、別のある単語とその他の単語との間位の関係計算とは独立するので、すべての計算が並列に行え、高速に処理できる

- 単語間の関係を直接計算できるが、語順の情報が失われる。それに対してトランスフォーマーは、位置エンコーディング（positional encoding）と呼ばれる単語の出現位置に固有の情報を入力に付加することで、ニューラルネットワークは間接的に単語の位置情報や単語間の位置情報を考慮することができる
- デコーダはSource-Target Attentionにより入力文の情報も利用
- ▼ エンコーダでは入力文のすべての単語を見ながら計算を行う、デコーダでは先頭から順に出力なので、未来の情報は使えない。
 - ▼ そのため、デコーダで翻訳文を生成するプロセスは並列化できない
 - ただし、訓練時には正解の翻訳を与えられるので並列計算はできる
- ▼ QKV（クエリ、キー、バリュー）
 - ▼ 2種類のAttentionとも、Q,K,Vより計算している。QKVそれぞれの値はベクトリもしくはベクトリをまとめた行列
 - ▼ 構造図
 - ▼ エンコーダの一層分
 - 入力+位置エンコーディングでのQKVをMulti-Head Attention（Self-Attention）に入力して、デコーダのKVを生成する
 - ▼ デコーダの一層分
 - 過去の出力+位置エンコーディングでのQKVをMulti-Head Attention（Self-Attention）に入力して、デコーダのQを生成する
 - 上記ふたつより生成されたKVQより、Multi-Head Attention（Source-Target Attention入力して、デコーダの一層分の出力を算出する
 - 詳細は論文： Attention Is All You Need
- ▼ Multi-Head Attention
 - ▼ Attentionの計算を複数並列行う、各Attentionの計算をHeadと呼ぶ、目的は多視点で異なるパターンでクエリとキーとの関係を見る
 - クエリ、キー、バリューの値が同じなら計算は無駄になるため、そこでこれらの3つの値をそれぞれ異なる全結合層に通じて変形する、さらにHeadの数だけ異なる全結合層を用意する
- ▼ オートエンコーダ
 - ▼ 基本的なオートエンコーダ
 - ▼ 可視層（入力層＝出力層）と隠れ層の二層からなるネットワーク

- 入力層の次元よりも、隠れ層の次元を小さくしておくことで、入力情報が圧縮されたもの
- ▼ エンコーダ
 - 入力層→隠れ層
- ▼ デコーダ
 - 隠れ層→出力層
- 教師なしの学習として、画像ノイズ削減など利用している
- ▼ 積層オートエンコーダ (stacked autoencoder)
 - ▼ ディープラーニングの黎明期考えられた手法、DPの祖であるジェフリー・ヒントン考えたもので、文字通りエンコーダを「積み重ねる」
 - ▼ A→B訓練後、続いてB→Cへ訓練のような順番的に学習していく。それぞれで隠れ層の重みが調整されるので、全体で見ても重みが調整されたネットワークができる、このオートエンコーダを順番に学習していく手順のことを事前学習 (pre-training) と呼ばれる
 - ただし、現在はこの「事前学習」は移転学習の文脈で用いられることが大半
- ▼ 変分オートエンコーダ (Variational Auto-Encoder, VAE)
 - 従来のオートエンコーダは、入力と出力が同じようにするような学習を行う、隠れ層は入力データ (の特徴) をうまく圧縮表現したもの
 - ▼ 変分オートエンコーダは入力データを圧縮するではなく、統計分布 (平均と分散) に変換する。
 - ▼ 入力データ (画像) に何かしらの分布に基づいて生成されているものだとしたら、その分布を表現するように学習すれば良いの考えです。
 - エンコーダは統計分布のある一つの点なる潜在変数に変換、デコーダは統計分布からランダムにサンプリングした1点を復元すること
- ▼ VQ-VAE
 - 潜在変数を連続値ではなく離散値にする
- ▼ infoVAE
 - 潜在変数とデータの相関を高めることで生成の精度をあげる
- ▼ β -VAE
 - VAEの目的関数において正則化を工夫することで画像の特徴を潜在空間上でうまく分離し、画像生成を行いやすくする

▼ ディープラーニングの応用例

▼ 画像認識

▼ 畳み込みニューラルネットワーク (Convolutional Neural Network, CNN)

- RGB画像は縦と横だけではなく、奥行き（チャンネル：色情報など）を持つ三次元ものに敵した構造として考えられたネットワーク

▼ 1980年福島邦浩

▼ ネオコグニトロン (Neocognitron)

- ▼ 人間が持つ視覚野の神経細胞の2つの働きを模してみようという発想から生まれた
 - 単純型細胞 (S細胞) : 画像の濃淡パターン (特徴) を検出する
 - 複雑型細胞 (C細胞) : 特徴の位置が変動しても同一の特徴であるとみなす。
- 入力層→コントラスト抽出→エッジ抽出→...→高次特徴抽出→...→認識細胞層

▼ 1998年ヤン・ルカン

▼ LeNet

- ▼ 畳み込み層とプーリング層（またサブサンプリング層）の2種類の層を複数組み合わせた構造
 - S細胞⇔畳み込み層
 - C細胞⇔プーリング層
- 微分（勾配計算）を用いないadd-if silentと呼ばれ学習法⇔誤差逆伝播法

▼ データ拡張 (data agumentation)

▼ 手元にあるデータから擬似的に別のデータを生成するアプローチ

- 上下左右にずらす
- 上下左右を反転する
- 拡大・縮小をする
- 回転をする
- 斜めに歪める
- 一部を切り取る
- ノイズを加える

▼ . . .

- 一方、闇雲にすべての処理を処理を施さないように注意が必要
(例: 親指をあげていいねのやつを上下回転すると。。。)

- ▼ Mixup
 - 二つデータを合成する
- ▼ Cutout
 - データの一部の値を 0 にする
- ▼ Random Erasing
 - データの一部の値をランダムにする
- ▼ RandAugment
 - どのようなデータ拡張の処理をどのぐらいの強さで行えば良いか自体により決める
- ▼ 物体認識タスク
 - ▼ 入力画像に対してその画像に映せる代表的な物体クラスの名称を出力するタスク。
 - 識別対象としている物体クラス全てに対して確信度を出力する、その確信度が最も高い物体クラスを識別結果として出力する
- ▼ ILSVRC: 画像認識の精度を競うコンペティション
 - ▼ 2012年優勝
 - ▼ AlexNet
 - 畳み込み層→プーリング層→畳み込み層→プーリング層→畳み込み層×3→プーリング層→全結合層×3
 - AlexNet以降、畳み込み層とプーリング層の繰り返しをさらに増やした、より深いネットワークのモデルが続々登場
 - ▼ 2013年優勝
 - ZFNet
 - ▼ 2014年準優勝
 - ▼ VGG (Visual Geometry Group, Oxford)
 - ▼ 畳み込み層→畳み込み層→プーリング層の塊を繰り返し、16層まで積層している。
各畳み込み層のフィルタサイズを 3×3 へ統一し、プーリングを行った次の畳み込み層からフィルタ数を 2 倍に増やすというシンプルな基本設計を採用していた
 - 深くなっても学習できるよう、一旦少ない層数で学習した後、途中に畳み込み層を追加して深くする学習手法
 - ▼ 2014年優勝

▼ GoogLeNet

- ▼ 層を深くするだけでなく、同時に異なるフィルタサイズの畳み込み処理を行うInceptionモジュール
 - 着目する範囲が異なる特徴を合わせて捉える
 - ネットワークの途中に認識結果を出力する層を追加し、学習時に誤差を逆伝播する補助的な機構を導入している

▼ 2015年優勝

▼ ResNet

- ▼ 152層の「超」深層でtop-5 error 約3.6%、人間の識別精度（エラー率大凡5%）を超えている。（但し、ILSVRCテストの1000クラス以外では人間のように識別できない）
 - ▼ 残差接続（skip connection）： $y=F(x)+x$
 - このアイデアだけで、深いネットでも誤差がスムーズに逆伝播でき、学習が安定

▼ WideResNet

- フィルタ数を増やす

▼ DenseNet

- スキップ結合を工夫

▼ 2017年優勝

▼ SENet (Squeeze-and-Excitation)

- 畳み込み層を出力した特徴マップに重みつけるAttention機構を導入（汎用的なアイデア）

▼ MobileNet

- ▼ 畳み込み層に深層分離畳み込み（Depthwise Separable Convolution）をしている
 - ▼ Depthwise Convolution
 - 各チャネルごとに空間方向の特徴抽出
 - ▼ Pointwise Convolution
 - チャネル方向に情報を融合（線形結合）

▼ Neural Architecture Search (NAS)

- ▼ リカレンとニューラルネットワークと深層強化学習を用いてネットワーク構造を探索する。

- RNN出力した各層のフィルタサイズやフィルタ数などを元にネットワークを作成し、学習および評価する。それで、認識精度が高くなるように深層強化学習によりネットワークを生成する部分を学習する
- ▼ NASNet (2017)
 - 生成する単位をResNetのResidual Blockのような塊にする工夫を導入
- ▼ MnasNet (2018)
 - 認識制度だけでなくモバイル端末での計算量を考慮する工夫を導入
- ▼ EfficientNet (2019)
 - ネットワークの「深さ」「幅」「解像度」をバランスよくスケールリングする方法
- ▼ 物体検出タスク
 - ▼ 入力画像に映せる物体クラスの識別とその物体の位置を特定するタスク
 - ▼ 位置特定とクラス識別 2 段階で処理
 - ▼ R-CNN (2014, Region-based CNN)
 - 画像から物体候補領域Selective Search (セグメンテーションの方法) で抽出, 大凡2000区域抽出
 - ▼ 物体候補領域を一体のサイズにリサイズして、CNNに入れて、判定は最上位層の一つ前の層 (FC層) を特徴ベクトルとし、サポートベクターマシン (SVM (one-vs-all)) によりクラス識別を行う
 - 物体候補領域ごとにこのような識別処理を行うため、処理時間がかかる
 - ▼ Fast R-CNN (2015)
 - 画像全体を入力して特徴マップを獲得することで高速化する、特徴マップ上で物体候補領域に相当する部分を切り出し、識別処理を行う
 - ▼ Faster R-CNN (2015)
 - ▼ Fast R-CNNまで利用していたSelective SearchをRegion Proposal Network (RPN) というCNNモデルに置き換えてさらに高速化するモデル
 - RPNで並行できるようにGPUより一気に加速された、Fast R-CNNの2秒/図より、0.2秒/図まで改善
 - ▼ Mask R-CNN (2017)
 - インスタンス分割のマスク枝を追加、FPN によりマルチスケール検出が向上

- ▼ 位置特定とクラス識別を 1 段階で処理
 - ▼ FPN (2017) (Feature Pyramid Network、特徴ピラミッドネットワーク)
 - ▼ R-CNN 系列の性能を強化するモジュール、Mask R-CNNと同じ年の2017FaceBookから提出、よく一緒に利用してインスタンス分類を利用している
 - 異なる層の特徴を上下に融合して、小さい物体には高解像度、大きい物体には意味情報豊富な特徴を提供する
 - ▼ YOLO (You Only Look Once)
 - 出力層を工夫して入力画像の各位置における物体領域らしさと矩形領域を直接出力する仕組み、各位置は入力画像の画像単位ではなく、グリッドに分割した領域単位にとって、らしさを判別する
 - ▼ SSD (Single Shot MultiBox Detector)
 - ▼ CNNの途中の特徴マップからYOLOのように領域単位で物体らしさと矩形領域を出力する
 - なぜ、特徴マップは段々小さくなるので、途中のも利用することで、小さいな物体も検出しやすくなり、かつデフォルトボックスのパターンを複数用意しておくことで、縦長や横長の物体を検出しやすくなる
- ▼ セグメンテーションタスク
 - ▼ 画像の画素ごとに識別を行うタスク
 - ▼ セマンティックセグメンテーション (semantic segmentation)
 - ▼ 画像全体を対象とする識別
 - ▼ 同一クラスの物体を一まとめする
 - 集団の歩行者などを一人一人分離できない
 - ▼ インスタンスセグメンテーション (instance segmentation)
 - ▼ 物体検出した領域を対象とする識別
 - ▼ 物体検出した領域に対してセグメンテーションを行う
 - 一人一人分離できる
 - ▼ パノプティックセグメンテーション (panoptic segmentation)
 - 個々の物体をそれぞれ分離しつつ、道路や建物などはひとまとめる
 - ▼ FCN (Fully Convolutional Network)

- 全結合層を用いず、畳み込み層だけで構成するモデルを採用、最後の特徴マップの1つの画素は入力画面の広い範囲の情報集約しているので、1画素ごとにクラス識別ができるようになり

▼ SegNet (Segmentation Network)

- ▼ 畳み込み層とプーリング層を繰り返し積層することで小さく（エンコーダ）なった特徴を徐々に拡大する（デコーダ）構造を採用する方法
 - エンコーダ側の最大値プーリングした位置を記憶して、デコーダ側の拡大時に記録していた位置に特徴マップの値を配置して、それ以外は0にする。境界付近のセグメンテーション結果をぼやけさせない工夫している
- VGGスタイルの畳み込み+プーリング

▼ U-Net

- ▼ データ側で特徴マップを拡大して畳み込み処理する際にエンコーダ側の特徴マップを同じサイズになるように切り出して利用
 - X線画像（CT、MRIなど）の医療画像診断に用いられている。SegNetに比べると精度が高い
- 通常は3x3畳み込み+ReLU（Rectified Linear Unit）+プーリング

▼ PSPNet (Pyramid Scene Parsing Network)

- ▼ エンコーダとデコーダの間にPyramid Pooling Moduleという複数の解像度で特徴を捉えるモジュールを追加
 - 特徴を異なるサイズでプーリングし、それぞれの大きさを畳み込み処理を行い

▼ DeepLab (2014-2015)

- 広い範囲の情報を集約するため、畳み込み層には、Atrous convolution (Dilated Convolution) を利用導入したモデルをDeepLab

▼ DeepLab V3+ (2018)

- SegNetやU-Netのようなエンコーダとデコーダの構造、PSPNetのような複数解像度の特徴を捉える機構（ASPP: Atrous Spatial Pyramid Pooling）を採用したモデル

▼ 姿勢推定タスク

▼ 人の頭や足、手などの関節位置を推定するタスク

▼ Convolutional Pose Machines

- CNNを多段に組み合わせて徐々に各骨格の信頼度マップを高精度化、多段組み合わせで着目範囲も広げて行き、人の全体の構造を考慮して各骨格の位置を推定する
- ▼ OpenPose
 - ▼ 複数の人の骨格を同時に推定できるようにした手法
 - ▼ Parts Affinity Fields
 - 骨格間間の位置関係を考慮した処理を導入
- ▼ マルチタスク学習
 - ▼ 複数のタスクを一つのモデルで対応できること
 - YOLO、Faster R-CNN、Mast R-CNNなど
- ▼ 音声処理
 - ▼ 音声データのコンピュータでの扱い
 - ▼ A-D変換（Analog to Digital Conversion）
 - ▼ パルス符号変調（Pulse Code Modulation, PCM）
 - 連続的な音波を一定時間ごとに観測する標本化（サンプリング）
 - ▼ 量子化
 - 観測された波の強さをあらかじめ決められた値に近似する量子化
 - ▼ 符号化
 - 量子化された値をビット列で表現する符号化
 - ▼ 高速フーリエ変換（Fast Fourier Transform, FFT）
 - 非常に短い時間ごとに周波数解析を行う必要での変換アルゴリズム、FFTにより音声信号は周波数スペクトル（spectrum）に変換
 - ▼ メル尺度（mel scale）
 - ▼ 人間が感じる音の高低に合わせた尺度、メル尺度の差が同じであれば、人間が感じる音の差も同じであるように定義している
 - 人間の聴覚は低周波領域の周波数の違いには敏感であるのに対して、高周波領域では鈍感であると言われる。
 - メル尺度は大量な心理学試験で取得された統計的な尺度
 - ▼ 音色
 - ▼ 同じHzの音の違いを認識する
 - 楽器の音色は高調波成分（こうちょうはせいぶん）できまる

- ▼ 高さ (Hz) 、長さ (横長) 、強さ (縦長)
 - 全く同じ音 (音色) であっても、異なるところを識別するもの
- ▼ スペクトル包絡 (スペクトル上の緩やかな変動)
 - 音色の違いの周波数スペクトル
- ▼ デファクトスタンダード
 - ▼ メル周波数ケプストラム係数 (Mel-Frequency Cepstrum Coefficients, MFCC)
 - 入力された音のスペクトル包絡に相当する係数列を得られる、これは音色の特徴量となるもの
- ▼ フォルマント周波数
 - ▼ スペクトル崩落を求めるといくつかの周波数でピックを迎えることがわかる、そのピックをフォルマントと呼ぶ、
 - 入力された音色の音韻 (言語によらず人間が発声する区別可能な音) が同じであれば、フォルマント周波数は近い値となる。個人差により多少ズレが発生する
- ▼ 音声認識
 - ▼ Speech-to-Text (STT)
 - ▼ 音声データをテキストに変換して出力する技術
 - ▼ 一般的な音声認識器は音響モデルと言語モデルの二つ、および単語と単語を発現した時の音素 (言語ごとに区別される音の最小単位) 列をペアにした辞書で構成される
 - ▼ 音響モデル
 - ▼ ある単語列を発声した時に、それに対応する音素列がどれぐらいの確率で観測されるかを表す確立モデル
 - 音素, 耳で音を聞き分ける部分
 - ▼ 隠れマルコフモデル (Hidden Markov Model , HMM)
 - 音素ごとに学習しておく、さまざまな単語の認識に対応できる
 - 単語を認識する際にはあらかじめ定義された単語と音素列の対応辞書により音素列に変化し、音素列に従ってHMMを連結することでモデル化する
 - 音響モデルとしてはHMM以外にも混合正規分布モデル (Gaussian Mixture Modle , GMM) や、CNNやRNNなどのニューラルネットワークも用いられる

- ▼ RNNを用いて音声データを時系列音素出力には、発音しない間に対応が必要

- ▼ Connectionist Temporal Classification (CTC)

- 出力候補として音素に加えて空文字を追加し、さらに連続して同じ音素を出力した場合は一度だけ出力したものと縮約する処理を行い、これにより、出力の長さで正解の長さが違う場合でも処理できる

- ▼ 言語モデル

- ▼ ある単語列はどのくらいの確率で出現するかを表す確率モデルで、単語列の文章としての自然さを表している

- 言葉の流れ、脳で自然な文章に直す部分

- ▼ n-gram言語モデル

- ある単語が出現する確率を、それより前のN-1個の単語が出現したという条件のもとでの条件付き確率の積として計算される
 - 最近RNNやトランスフォーマーなどのニューラルネットワークを用いた言語モデルも広く利用される

- ▼ End-to-End

- 音声データから直接単語列を生成する音声認識モデル

- ▼ 感情分析

- 機械がより適切な応答を返すために、人間の音声の感情分析を行う

- ▼ 話者識別

- 自動議事録作成では誰の発話かを推定する

- ▼ 音声認識器に音声データが入力されると、辞書に格納された情報から考える数多くの音素列および単語列が生成される、それぞれが音響モデルおよび言語モデルによってスコア付けされる

- この二つのスコアを統合して最も良いものが最終的な音声認識結果として出力される

- ▼ 音声合成

- ▼ Text-to-Speech (TTS)

- ▼ テキストを音声に変換して出力する技術

- ▼ 従来

- ▼ テキストの形態素解析、読み推定、読みから音素列への変換、音素列から音声は波形の生成などのいくつかのステップを経て実現
 - 音声波形は、ある話者のさまざまな音素の波形をあらかじめデータベース化しておき、これらを組み合わせて音声合成を行う波形接続方式と、音の高さや音色などに関するパラメータをHMMなどによって推定し、これを元に音声を合成するパラメトリック方式の2つがある（前者より合成の質が低い）
- ▼ 2016年：WaveNet By DeepMind
 - ▼ ディープラーニングを用いたパラメトリック方式の音声合成モデル
 - 周波数スペクトルなどの変換はせず、量子化された状態のままニューラルネットワークで処理することで、音声合成の質を劇的に向上させた

▼ 自然言語処理

▼ テキストデータの扱い方

▼ テキストデータの表現

▼ 単語n-gram

- 文字列を複数個の単語を並べたものとして表現できる
- n=1: ユニグラム (uni-gram)
- n=2: バイグラム (bi-gram)
- n=3: トライグラム (tri-gram)

▼ Bag-of-Words (BoW)

- 単語の集合として表現する、BoWでは単語がバラバラに保存され、出現順序の情報は失われる

▼ Bag-of-n-grams

- 局所的な出現順序が重要な意味を持つ場合もある

▼ ID化

- ニューラルネットワークは数値列（ベクトル）しか扱えない、各単語に異なる整数値を順に割り当て

▼ ワンホットベクトル (one-hot vector)

- IDに相当するベクトルの次元の値だけが1で他が全て0となっている

▼ TF-IDF (Term Frequency-Inverse Document Frequency)

- TF: 1つの文章内での単語の出現割合（単語の頻度を文章内の全単語数で割ったもの）であり
- IDF: ある単語が出現する文章の割合（ある単語が出現する文章の数を全文章数で割ったもの）の逆数を取り、さらに大数をとったもの

▼ 単語埋め込み (word embedding)

▼ 局所表現 (local representation)

- ▼ ワンホットベクトルは値が0か1しかなく離散的で、1を取る次元が1つしかないため情報が疎であり、次元数が単語の種類数と等しい、非常に高次元となっている

- 局所表現では単語同士の意味の近さを考慮されなく、局所表現を連続的（実数値全体を取る）で、情報が密であり（値が0である次元が少ない）、次元数の低いベクトルに変換することをかんがえる。このような単語の表現を分散表現 (distributed representation) や単語埋め込み (word embedding) と呼ぶ

▼ word2vec

- ▼ 単語を分散表現で表すことで、ベクトル間の距離や位置関係から単語の意味を表現する代表的な手法

- 単語の意味は、その周辺の単語によって決まるという分布仮説と呼ばれる言語学の主張をニューラルネットワークとして実現
- 例の 王様 - 男性 + 女性 = 女王

▼ 手法

▼ スキップグラム (skip-gram)

- ある単語を与えて周辺の単語を予測するモデル

▼ CBOW (Continuous Bag-of-Words)

- 周辺の単語を与えてある単語を予測するモデル

▼ fastText

- ▼ 単語埋め込みを学習する際に単語を構成する部分文字列の情報も含めること。部分文字列の情報を併用することで訓練データには存在しない単語 (Out Of Vocabulary, OOV) 出会っても単語埋め込みを計算したり、活用する単語の語幹と語尾を分けて考慮したりすること

- 学習に要する時間が短い特徴を持っている、ウィキペディアとコモンクロールを用いて訓練した世界中の157言語によるそれぞれの訓練済みデータを提供している

▼ ELMo (Embeddings from Language Models)

- 文脈を考慮した分散表現を得る手法
- ▼ 事前学習モデル (Pre-trained Models)
 - ▼ 事前学習 + 移転学習
 - 画像認識分野では以前から、VGG16などのように大規模なデータで事前学習したモデルを基に、特定のカテゴリの小規模なデータを使って移転学習で、小規模でも高精度に行うが可能
 - ▼ GPT (Generative Pre-Training) : 2018
 - OpenAI開発、事前学習として行うのは大規模なコーパスを用いた言語モデルの学習、トランスフォーマーのデコーダと似た構造を持つ
 - パラメータ数は約 1 億
 - ▼ BERT (Bidirectional Encoder Representation from Transformers) : 2018
 - ▼ Google社開発した、トランスフォーマーエンコーダを利用、エンコーダは入力された全体が見えている状態ので、通常学習の言語モデルにより学習は行えない
 - ▼ Masked Language Model (MLM)
 - 文内の単語のうちの一部をマスクして見えないようにした状態で入力し、このマスクされた単語を予測させる学習タスク
 - ▼ Next Sentence Prediction (NSP)
 - 2つの文を繋げて入力し、2つの文が連続する文かどうかを判定する学習タスク
 - 移転学習さまざまな応用タスクを解くことができる。さらに各単語の最終状態を使って品詞タグ付けや固有表現解析を行ったり、SQuAD (Stanford Question Answering Dataset) のような回答の範囲を予測するタイプの質問応答タスクも解ける
 - パラメータ数は約 3 億
 - ▼ ALBERT、DistilBERT
 - タスクの精度を落とさずにパラメータ数を削減する
 - ▼ 大規模言語モデル (LLM)
 - ▼ GPT-2 (2019年2月)
 - ▼ 15億
 - GPTでは行えなかった機械翻訳などの言語生成タスクも行えるようになった
 - ▼ Megatron-LM (2019年9月)

- ▼ 80億
 - NAVIA
- ▼ Turing -NLG（2020年2月）
 - ▼ 170億
 - Microsoft
- ▼ GPT-3（2020年5月）
 - ▼ 1750億
 - 様々な言語生成タスクが非常に高精度に行える
 - ▼ 別話題
 - CNNを使わない新たな慈善がクシュモデルであるVision Transformer (ViT) も2020年登場
- ▼ ChatGPT（2022年11月）
 - これまでのテキストデータからの言語モデルの学習だけでなく、生成された応答が適切かどうかを人間が判断し、その判断結果から強化学習を用いることで、より高精度な応答を生成することができる（RLHF、Reinforcement Learning from Human Feedback）と呼ぶ
- ▼ その後
 - ▼ Google
 - PaLM→PaLM2→Gemini
 - ▼ DeepMind
 - Chinchilla
 - ▼ メタ
 - LLaMA
 - 1兆パラメータを超えるPanGu -Σも出ている
- ▼ 自然言語処理のタスク
 - ▼ 評判分析（sentiment analysis）
 - 与えられた文をGPTに入力し、入力し終わった最後の状態を使って、入力された文の極性（positive, negative, neutral）を判定する
 - ▼ 自然言語推論（Natural Language Inference, NLI）
 - 与えられた2つの文書の内容に矛盾があるか、一方が他方を含意するかなどを判定するタスク。含意関係認識（Recognizing Textual Entailment, RTE）とも呼ばれる

- ▼ 質問応答 (question answering)
 - 文章とこれに関する質問文が与えられ、適切な回答を選択肢の中から選ぶタスク。しばしば常識推論 (commonsense reasoning) が必要
 - 意味の類似度 (semantic similarity) 判定
- ▼ 文書分類 (document classification)
 - 与えられた文書がどのクラスに属するかを予測するタスク。評判分析タスクも文書分類の一種
- ▼ GLUE (General Language Understanding Evaluation)
 - ▼ 様々な言語理解タスクをまとめたベンチマーク、世界中の研究者がこのデータセットでの精度を競っている
 - 文法が正しいかどうかの判定
 - 感情分析 (ポジティブかネガティブか)
 - 2つの文が同じ意味かどうかの判定
 - 含意関係認識
 - 質問応答
 - ▼ SuperGLUE
 - さらに複雑なタスクを扱う
 - ▼ JGLUE
 - 日本語に特化した
- ▼ 深層強化学習 (deep reinforcement learning)
 - ▼ ディープラーニングと強化学習を組み合わせ手法
 - ▼ 2013 基本手法であるDQN (Deep Q-Network) がDeepMind社から発表され
 - ▼ DQNは、Atari社が開いた家庭用ゲーム機Attari2600の多種多様なゲームを人間並や超える
 - 2020年前半、DeepMind社から発表されたAgent57と呼ばれる手法で、57ゲーム全てで人間のスコアを超えるようになった
 - ▼ Q学習 (1992年) では、ある特定の状態に対して1つの行動価値 (Q値) を割り当てて、その行動価値に対する学習を行う。実世界には非現実的なところが多く
 - DQNは、ゲームや実世界の画像をそのままディープニューラルネットワーク (畳み込みニューラルネットワーク) の入力として、行動候補の価値関数や方策を出力として学習するアプローチ
 - ▼ 経験再生 (experience replay)

- ▼ 環境を探索する過程で得た経験データをリプレイバッファと呼ばれる機構に保存し、あるタイミングで、これらの保存データをランダムに複数抜き出してディープニューラルネットワークの学習に使う手法
 - 学習に使うデータの時間的偏りをなくし学習の安定を図る
- ▼ ターゲットネットワーク
 - ▼ 現在学習しているネットワークと、学習の時間的差分がある過去のネットワークに教師のような役割をさせる手法
 - これにより価値推定を安定させる
- ▼ ダブルDQN (double deep q-network)
 - ▼ 経験再生やターゲットネットワークの使い方を工夫した
 - 「点数をつける人」と「実際にその行動を選ぶ人」を分けて、冷静に判断できるようにする。
- ▼ 優先度付き経験再生 (prioritized experience replay)
 - 凡ミスより、大失敗や大発見を強く記憶して、繰り返し復習する
- ▼ デュエリングネットワーク (dueling network)
 - ある状態では「どの行動をしても結果がほとんど同じ」ことがある。
 - Q値を「その状態の価値 (V)」 + 「各行動の相対的な優位性 (A)」に分解して学習。
- ▼ カテゴリカルDQN (categorical deep q-network)
 - Q値を「分布 (確率分布)」として学習。例えば「この行動で +10点になる確率50%、-5点になる確率30%...」みたいに扱う。
- ▼ ノイジーネットワーク (noisy network)
 - ϵ -greedy (ランダムに行動する手法) は単純すぎて探索効率が悪い。
 - ニューラルネットのパラメータ自体に「ノイズ」を注入して、自然に探索を促す。
- ▼ N-step Return
 - 報酬の伝播を速める
- ▼ 深層強化学習とゲームAI
 - ▼ DP登場後、評価関数の部分をディープニューラルネットワークで置き換え、加えて、深層強化学習と従来のゲーム木の探索、またその他のディープラーニングを使った画像認識や系列処理の手法を取り入れることでゲームAIは飛躍的な性能向上できた

- ▼ 代表的な手法やゲームAI
 - ▼ ボードゲームにおけるゲームAI
 - ▼ 2人完全情報確定ゼロ和ゲーム
 - 行動を選択する時点で、盤面の状態や相手の持ち駒などのゲームに関する情報が全てプレイヤー側で把握できる、かつ、一方が勝てば他方が負けるゼロ和性、偶然の要素がないゲーム
 - ▼ モンテカルロキー探索（2000年代前半考案）
 - 複数回のゲーム木の展開によるランダムシミュレーション（プレイアウト）をもとに近似的に良い打ち手を決定する手法
 - ▼ AlphaGo
 - ▼ 2016年、DeepMind開発したゲームAI、技術的には、モンテカルロ木探索に深層強化学習の手法を組み合わせることで圧倒的な強さを到達
 - 人間の棋譜のデータを使って教師あり学習や、複製したAlphaGoとの自己対戦（self-play）で獲得された経験を使って深層強化学習を行う
 - ▼ AlphaGo Zero
 - 教師なしで最初から自己対戦でAlphaGoよりも上まった
 - ▼ Alpha Zero
 - 囲碁のみならず、将棋やチェスなどの分野で人間のトッププレイヤーを超えて圧倒的な性能を持つ
 - ▼ その他ゲームにおけるゲームAI
 - ▼ リアルタイムにゲームが進行、不完全情報ゲームである
 - ▼ マルチエージェント強化学習（Multi-Agent Reinforcement Learning, MARL）
 - 今まで単一エージェントによる強化学習と区別してする概念、エージェントの協調的や競争的な関係を考慮して強化学習
 - ▼ OpenAI Five（2018年OpenAI）
 - ▼ MOBA（Multiplayer Online Battle Arena）型のDota2で人間トップチームに優勝
 - LSTM、PPOなどの強化学習アルゴリズムを利用

- 特長は手法やアルゴリズムではなく、膨大な計算資源と学習時間です。（5万以上のCPUと1000個以上のGPUを使用して10ヶ月に及ぶ強化学習を行った）

▼ AlphaStar（2019年DeepMind）

- RTS（Real-Time Strategy）型のスタークラフト2で人間トップに優勝
- ▼ ResNet、LSTM、ポインターネットワーク、トランスフォーマーなど、画像処理や自然言語処理の手法も多く取り入れたネットワークを使って学習、ゲームプレイを行い
 - 強化学習時にはゲーム理論や、自己大戦の発展系の手法を使うなど、様々な人工知能技術が巧みに組み合わせられて構成、いわば人工知能技術の集大成的なアルゴリズムである

▼ 実システム制御への応用

▼ ロボット制御への応用での実世界の課題

▼ 状態や行動を適切に設定する必要

▼ 次元の呪い（curse of dimensionality）

- ▼ 強化学習では、最も基本的な設定として、低次元で離散値の状態や行動を扱う
 - 連続値を離散値にはどの幅でやるか、様々な状態・行動の高次元から低次元への転換に、状態や行動の数が指数的に増大するため学習が困難になる
 - 価値関数や方策を関数近似することで高次元の連続値のセンサデータや制御信号を状態や行動として扱う、特に、関数近似器としてディープニューラルネットワークを用いることで、データの特徴表現を表現できるを期待

▼ 状態表現学習（state representation learning）

- 不変な特徴量を学習するCNNでは連続可変状態で適切でない可能。問題に対して適切な方策を学習できるように、エージェントは入力となるセンサデータから、「状態」に関する良い特徴表現を学習する必要。深層強化学習の文脈では、しばしば「状態」に関する特徴表現学習をさす

▼ 連続表現学習（continuous control）問題

- DQNを利用することで、状態として画像という高次元なデータを入力に利用することができるようになったが、出力である行動には低次元な離散値が仮定されてしまい、ロボットが行動として関節角や台車の速度といった連続値の行動に直接出力する問題設定

- ▼ 報酬設計が難しい
 - 報酬関数の設計（どのような状態・行動の組にどのぐらいの大きさの報酬を与えるかの設定）によって、得られる方策の挙動は大きく異なる
- ▼ 報酬成形（reward shaping）
 - 報酬関数の設計と学習された方策の挙動の確認を繰り返して、適切に学習が行われるように報酬関数を作り込む
- ▼ サンプル効率が低い割にデータ収集コストが高い
 - データの時効性、汎用性、本物の収集の難しさ
- ▼ 方策安全性の担保が難しい
 - 実世界には無限試行できない（ロボット故障などなど）、実行動の安全性を担保する仕組みを導入が必要
- ▼ 解決策
 - ▼ 人間が環境やロボットに行わせたタスクに関する事前知識（ドメイン知識、domain knowledge）を学習に組み込むための工夫を提案している
 - ▼ オフラインデータの利用
 - 事前（本物適用より）に何らかの方法で集めたデータから方策を学習する
 - ▼ オフライン強化学習（offline reinforcement learning）
 - 実際環境ではなく、そのデータセットを学習する
 - ▼ 模倣学習（imitation learning）
 - 人間が期待する動作をロボットに対して教示すること、ロボットが方策設定を学習する。これを教示データはデモンストレーションと呼ばれ、ロボットを直接手で動かしたり、リモコンやVRインタフェースにより遠隔操作したりすることで作成され
 - ▼ シミュレータの利用
 - ▼ sim2real
 - シミュレータで学習した方策を現実世界に移転して利用する設定
 - ▼ リアリティギャップ（reality gap）
 - 現実世界とシミュレータで再現された世界の間の差異
 - ▼ ドメインランダムマイゼーション（domain randomization）

- シミュレータの各種パラメータをランダムに設定した複数のシミュレータを用いて生成したデータから学習する。
- 例：2019年OpenAI、5本指のロボットハンドの中でルービックキューブを解く

▼ 残差強化学習 (residual reinforcement learning)

- ▼ 従来のロボット制御で用いられてきたような基本的な制御モジュールの出力と、実際にロボットがタスクを行う環境における最適な方策との差分を強化学習によって学習すること
 - 既存の枠を立てるので、サンプル効率や安全性の面で有効な手法である
- 例：2019年プリンストン大学やGoogleなどのチームが、ロボットアームを利用して様々な物体を把持し、指定された箱に投げ入れるTossingBotの研究が発表された

▼ 環境のモデルの学習

- 今まではほぼモデルフリー (model-free)：環境状態がどのように遷移するかに関する知識を明示的に学習しない
- ▼ モデルベース (model-base)
 - 環境に関する予測モデルを明示的に活用しながら方策の学習を行う学習アルゴリズム
 - 実際環境→状態・行動・報酬など様々な情報→環境モデル⇄方策
- ▼ 世界モデル (world model)
 - エージェントが、得られる情報をもとに自身の周りの世界に関する予測モデルを学習して、方策の学習に活用する枠組みは、世界モデルと総称される

▼ データ生成

▼ 生成タスク

▼ 画像生成

- データセット (訓練データセット) から画像が持つ潜在空間を学習し、それをベクトルとして表現。潜在空間より画像を生成する

- 音声生成
- 文章生成

▼ 変分オートエンコーダ (Variational AutoEncoder, VAE)：2014年

- 数学的に堅実、潜在空間の理解が得意、でも画像がぼんやりしがち

- ▼ 敵対的生成ネットワーク (Generative Adversarial Network, GAN) : 2014年
 - ▼ ジェネレータ (generator)
 - ランダムなベクトルを入力し、画像を生成して出力する
 - ▼ ディスクリミネータ (discriminator)
 - 画像を入力とし、その画像が本物か (ジェネレータによって生成された) 偽物かを予測して出力する
 - ▼ DCGAN (Deep Convolutional GAN) : 2015年
 - ディープニューラルネットワークで用いて、畳み込みニューラルネットワークを採用したもの、高解像度の画像の生成が可能になっていた
 - ▼ Pix2Pix
 - ▼ GANのようなベクトルの代わりに、画像データを入力して別の画像に変換する処理
 - あらかじめペアの画像を学習のために用意が必要です。
 - ▼ Cycle GAN
 - ある画像を変換して、その変換した画像を元の画像に再度変換する仕組みで、ペアなデータ準備が不要になった
- ▼ Diffusion Model: 2015年研究開始、2020年から実用までできた
 - ▼ データを生成する過程を時間的な連続的な拡散のプロセス
 - ▼ 拡散過程
 - 学習時に、画像データにノイズを加えていき、ガウス分布にする
 - ▼ 逆拡散過程
 - データ生成時に、ノイズから徐々にノイズを除去して画像データを生成する
- ▼ NeRF (Neural Radiance Fields) : 2020年
 - ▼ 数枚の写真を与えると、そのシーンを 3D 的に再構築し、見たことのない角度からの画像をレンダリングできる
 - 複数の画像データとそれらの視点や照明条件などの情報を用意し、画像データとそれらの情報を元に、3次元区間の各点での色や透明度を予測するネットワークを学習する
 - 生成品質が高い、計算リソースが必要、シートごとに学習が必要、品質は入力データの質と量に強く依存され
- ▼ 移転学習・ファインチューニング
 - 学習済みモデル

▼ 移転学習

- ▼ 学習する時、出力層だけ初期化して学習。
出力手前に複数の全結合層などを追加する場合などもある
 - ImageNetのデータセットで事前学習済みモデルは1000クラス分類のやつ、最後の出力層は適用したい問題のクラス数になるように、新たな出力層に変更して学習する。

▼ ファインチューニング

- 追加層だけではなく、モデルのすべての重みを更新するよう学習する

▼ 少量データでの学習

▼ Few-shot学習

- 極端に少ないデータ数、数枚程度で学習する手法
- ▼ MAML (Model-Agnostic Meta-Learning)
 - モデルの重み自体を更新するのではなく、モデルの重みをどのように更新すれば良いかという学習方法自体を学習するメタ学習
- One-shot学習
- Zero-shot (ゼロショット) 学習

▼ 半教師あり学習

▼ 擬似ラベリング (Pseudo-Labeling)

- 正解のついていないデータを利用して学習を行い、正解のついていないデータを評価する。その結果をもとに擬似的な正解をつけ

▼ 一貫性正則化 (Consistency regularization)

- データに対してノイズを加えた変換後のデータと変換前のデータをそれぞれモデルに入力した際に、同じように出力になるべき、この変化前後の差を最小化する考え方

▼ FixMatch

- 擬似的な正解ラベルと一貫性正則化を組み合わせると高い精度を達成

▼ 自己教師あり学習

▼ プレテキストタスクという人があらかじめ設定した問題を学習

- ▼ 例: 画像認識分野で、入力データに異なるデータ拡張を施して、モデルに入力、モデルが出力する特徴が類似するように学習
 - 一貫性正則化と同じ原理

▼ 継続学習

- ▼ 認識したいクラスを増えていく、認識したい環境（ドメイン）が変わっていく、適用範囲が広がるにいく
 - 但し、過去に学習したクラスを正しく認識できない破滅的忘却が起きる可能
- ▼ マルチモーダル
 - ▼ 画像、言語、音声など様々なデータを入力しても同時に扱う手法
 - ▼ マルチモーダルタスク
 - ▼ 例：Image Captioning
 - 画像データを入力すると、その内容を要約したテキストを出力
 - ▼ Text-To-Image
 - テキストから画像を生成する
 - ▼ 基盤モデル
 - ▼ CLIP（Contrastive Language-Image Pretraining, 2021, OpenAI）
 - ▼ 画像から抽出する特徴とテキストから抽出する特徴が同じようになるよう非常に大量のデータで学習して、特徴を学習する。
 - 物体認識と物体検出、Visual Question Answeringなど、様々なタスクで利用され
 - ▼ DALL-E
 - CLIPとDiffusion Modelを用いて、テキストで指定した画像を高品質で生成
 - ▼ Flamingo（2022, DeepMind）
 - その場で例を見せればすぐ学ぶ賢いマルチモーダルLLM
 - ▼ Unified-IO（2022, AllenAI）
 - 何でも I/O 形式で統一して処理する万能マルチモーダルAI
- ▼ モデルの解釈性
 - ▼ 説明可能AI（Explainable AI）
 - ▼ 判断根拠を解釈し、説明にすること
 - ▼ LIME（Local Interpretable Model-agnostic Explanations）
 - ▼ 入力データの特徴の一部だけを与え、その、その時の振る舞いを線形モデルに近似する
 - 局所的説明（1つの予測に対して理由を説明）

- ▼ Permutation Importance
 - ▼ 入力データの特徴をランダムに入れて、振る舞いの変化をもとに特徴の寄与度を測り
 - 全体的説明（グローバル） → モデル全体でどの特徴が重要かがわかる
 - 計算コストがかかる、特徴量同士が強く相関すると誤解を生む可能性
- ▼ SHAP (SHapley Additive exPlanations)
 - ▼ ゲーム理論の Shapley 値 に基づく、予測を「すべての特徴が協力して出した成果」と考え、各特徴の 貢献度（限界寄与） を公平に分配
 - 局所（1つの予測の説明） と 全体（全体的特徴重要度） の両方を扱える
 - 計算コストが非常に高い（TreeSHAP など高速近似が実用化されている）
- ▼ CAM (Class Activation Mapping) (2016年)
 - ▼ 画像認識タスクに用いるモデルの予測判断根拠をしますために「画像のどこを見ているか」を可視化する
 - ▼ GAPの最終層の手前に用いたネットワークの構造
 - 可視化したいクラスに対応する重みをGAP前の特徴マップに乗算し、すべての特徴マップを足して1つのヒートマップにする。
- ▼ Grad-CAM (2017年)
 - ▼ 出力クラスに対する勾配情報を用いて、「最後の畳み込み層の特徴マップにどれだけ貢献したか」を重み付け、任意の CNN アーキテクチャに適用可能
 - 但し、その過程で画像が低解像度になってしまう
- ▼ Guided Grad-CAM (2017年)
 - 入力値の勾配情報も用いて、CAM過程の低解像度問題解消
- ▼ モデルの軽量化
 - ▼ 蒸留
 - ▼ 層が深く高精度なネットワークを学習した知識を、層が浅く軽量のニューラルネットワークへ伝える方法
 - ▼ 教師ネットワーク
 - 層が深く複雑な学習済みのネットワーク

- ▼ 生徒ネットワーク
 - 教師の学んだ知識を伝える未学習のネットワーク
- ▼ hard target
 - ▼ 通常の学習時に用いるone-shotな正解ラベル
 - 「答えはA」
- ▼ soft target
 - ▼ 教師ネットワークの事後確率
 - 「答えはA (90%)、B (10%)」
- hard targetとsoft targetそれぞれを用いて、クロスエントロピー誤差関数で計算して、誤差逆伝播法で生徒ネットワークを更新
- ▼ 枝刈り
 - ▼ ニューラルネットワークの接続の一部を切断する、すなわち重みの値を 0 にする
 - ▼ マグニチュードベース
 - 絶対値の小さいものから順番に削除
 - ▼ 勾配ベース
 - モデルにデータを入力して各クラス的确信度を出力、正解クラス的确信どから誤差を逆伝播して、勾配情報から各重みの評価値を算出、この評価値（感度とも言う）が小さいものから順番に削除
 - ▼ 一般的に、モデル全体の学習と枝狩を繰り返して、少し済みモデルサイズを圧縮することが多い
 - いきなり多くの重みを削除すると精度に悪影響可能
 - ▼ 宝くじ仮説 (Frankle & Carbin, 2019)
 - モデルを学習する際に、より良い初期値（当たりくじ）を持つサブネットワークがモデル全体の中に含まれている
 - 従来のは枝刈り後、モデルの重みは初期化せず、繰り返し更新。対して、宝くじ仮説には重みを初期値に巻き戻して、元の訓練データより高い精度のモデルを作成
- ▼ 量子化
 - ▼ 重みなどのパラメータを少ないビット数で表現して、モデルを圧縮する方法。
 - ネットワークの構造を変えずにメモリ使用量を減らす

- 最初精度は誤差や勾配のため一般的に、32ビット浮動小数点数を使用する。推論時にはそこまで高精度が必要なく、8や4ビット整数などにもすることも性能をほぼ維持しながらメモリと計算量を減らす

▼ AIのビジネス利活用

▼ 意義

▼ 経営課題を解決し、利益を創出

- 5分が1分になることではなく、5日が1分になることに焦点、要は部分最適してもビジネスインパクトを生み出すが困難、全体的を最適化することで連鎖的に改善され、圧倒するバリューチェーン・サプライチェーンを手に入れる

▼ AIプロジェクトの進め方

▼ そもそもAIを適用する必要があるのか

- AIは手段の一つでなく目的ではない、AIの特性を理解した上で判断が必要、かつ短期的、中期的、長期的で時間軸、および実施内容でのルールベース、データ蓄積の流利的な考案が必要

▼ BPR (Business Process Re-engineering)

- AIの適用箇所と技術の連携範囲を再検討

▼ 提供方法

▼ クラウド

- モデルの更新が楽、装置の故障管理不要、計算機の保守・運用が不要
- 通信遅延の影響を受ける、ダウンした時の影響が大きい、量よりのコストは意外に大きい場合もある

▼ エッジ

- リアルタイム性が高い、通信量が少ない、故障の影響範囲が小さい
- モデルの更新が難しい、機器を長期間保守運用する必要がある

▼ 開発計画を策定

- データを確認する段階、モデルを試作する段階 (PoC)、運用に向けた開発をする段階にフェーズを細かく区切り、収集されたデータの中身や学習して得られたモデルの精度に応じて、柔軟に方針を修正できるような体制が望ましい

▼ プロジェクト体制を構築

- ▼ 多岐にわたるスキルを保有する様々なステークホルダーを巻き込んだ体制づくりが必要
 - システム構築技術者

- ビジネス的な観点も踏まえて全体を把握・意思決定するマネージャ
- UX / UXに関するデザイナー
- データサイエンティスト
- ...
- ▼ プロジェクト計画の各フェーズの進め方
 - ▼ CRISP-DM (CRoss-Industry Standard Process for Data Mining) : データマイニングのための産業横断型プロセス: 1990年代末に策定
 - ▼ プロセス
 - ビジネス理解 (Business Understanding)
 - データ理解 (Data Understanding) → データの収集・探索
 - データ準備 (Data Preparation) → 前処理・特徴量作成
 - モデル構築 (Modeling) → 学習・モデル作成
 - 評価 (Evaluation) → モデルがビジネス目標を満たしているか確認
 - 展開 (Deployment) → 実運用や意思決定に活用
 - ▼ CRISP-ML (Cross-Industry Standard Process for Machine Learning)
 - CRISP-DMの上、Business UnderstandingとData Understandingが統合され、Monitoring and Maintenance (監視・保守) が追加され6つのステップ
 - ▼ MLOps
 - ▼ NIPS2015論文
 - AIモデル構築部分は全体のAIプロジェクトの中で極めて小さく、その周辺領域が大きいこと
 - ▼ 概念図
 - Configuration→DataCollection→Feature Extraction・DataVerification・ML Code→Machine Resource Management・Analysis Tools・Process Management Tools→Serving Infrastructure→Monitoring
 - サービス化
 - ▼ 各フェーズの進め方 (実装・運用・評価)
 - ▼ 例
 - ▼ 産業連携をこなうことで、プロジェクト構成メンバーを分散させる
 - 大学からデータサイエンティストを出し、事業会社がデータが提供し、ベンチャー企業が環境を提供など

- ▼ オープンイノベーション
 - ▼ 外部のアイデアや技術と結合しイノベーションを生み出すスピードを向上させ、コストやリスクを低減させる
 - 例: Ciscoは有望なスタートアップへの出資やM&A、協業関係を築くなど外部資源を積極的に活用する
- ▼ Triple Helix model
 - 欧州では、これまで大学・産業界・政府の産業連携ネットワークを中心とし、研究開発領域に留まらず技術の商用化やビジネスモデルの領域まで及ぶ
- ▼ プロジェクトの計画に反映する
 - このAIシステムの恩恵や影響を受けたのは誰か
 - 想定外のユーザはいないか
 - 判断や最適化を行う時の基準はなんか
 - 判断や最適化などを機械で行うことの正当性はどんな根拠に基づいているか
 - AIシステムやサービスを、現在の文脈以外に悪用される危険性はあるか。それを防ぐ対策は取られているか
- ▼ データの収集・加工・分析・学習
 - ▼ データの収集方法および利用条件
 - ▼ オープンデータセット
 - ▼ 企業や研究者が公開しているデータセット
 - ▼ コンピュータビジョン分野
 - ImageNet
 - PascalVOC
 - MS COCO
 - ▼ 自然言語分野
 - WordNet
 - SQuAD
 - DBPedia
 - ▼ 音声分野
 - LibriSpeech

- 利用する際にライセンス要注意
- ▼ 自身で作成
 - ▼ 計測データ
 - センサを利用環境の情報計測などのアプローチ
 - テキストデータ解析
 - 時系列データ
 - アンケートやインタビュー
 - ログデータ
 - ソーシャルメディアの投稿データ
- ▼ 学習可能なデータを集める
 - ▼ AIのモデルを訓練できるデータが必要
 - 認識すべき対象の情報が十分に含まれているか
 - データの偏るを無くす
 - データの網羅性を重視
- ▼ データを加工
 - 収集されたデータに、不要な情報や、データ間で形式の近いがありなど、前処理必要
 - ▼ 教師あり学習の場合は、正解データを作成も必要：アノテーション
 - ▼ ばらつき要注意
 - アノテーション定義の曖昧さ
 - アノテーション実施者の感性
 - 作業の専門性
 - 認知容量を超える規模
 - ケアレスミスなど
 - ▼ 対策
 - 要件を決める際に、マニュアル作成、作業者が要件を理解できるようにする
 - アノテーションの判断軸とそのサンプルの提示、作業せいの明確化（言語のルール+事例）
 - ルール明確の上で、どの程度の誤差を許容するかも明確

▼ 個人情報の配慮

▼ 匿名加工

- ▼ 個人を特定できないように情報を加工する、プライバシー保護を図り
 - 氏名等の個人識別に繋がる情報の削除やマスキング、データの集約化など
 - 画像や音声データは、元データに復元できないような特徴量のデータをしつつ、生データは削除する対策など

▼ 開発・学習環境を準備

▼ Python

- バージョン管理で、環境を切り替えられるツール（`pyenv`, `virtualenv`, `pipenv`, `poetry`など様々ある）

▼ AIモデルを学習

- ▼ 初期段階ではパラメータの設計が甘くモデルの精度が低いところから始まるため、モデルの調整によってい大きな精度向上を見込め
 - ビジネスの目標に基づく、精度とコストの折り合いをつけて進む
 - 学習済みモデルを用いて移転学習するなどもある
- ▼ 検証には、学習に用いたデータ以外のテストデータを用いて検証を行う
 - 過学習を避けるために、バリデーションデータを用意して、最終性能評価を行う
- ▼ データリーク要注意
 - ▼ モデルが学習時に本来知るべきでない情報にアクセスしてしまう現象
 - 未来の事象を予測するモデルに未来の情報がモデルの学習に漏れ込んでしまうと、評価が過度に高くなる可能。それで実際の運用時に予期しない誤差を生じる可能性がある

▼ 推論を行う

- 運用時にコストやデプロイ環境制限などによって、モデルの最適化や軽量化が必要の場合もある
- ▼ 時間の経過や環境の変換より、当時の学習データとは異なるデータが増えていくことで、モデルの精度が徐々に低下するリスクがある
 - 定期的にデータを再収集し、モデルを再学習あるいは微調整をすることが推奨

▼ AIの法律と論理

- 「AI活用推進法（AI新法）」が2025年6月に成立・公布され、2025年夏頃にAI戦略本部が設置され基本計画が策定され

▼ AIの法律

▼ 著作権法

▼ 著作物

▼ 思想または感情を創造的に表現したもの

- 事実自体は著作物ではないです、それに対しての創造的な考え記事は著作物
- アルゴリズムや数学的な手法も対象外
- ソースコードのコピーやかなり類似では著作権侵害ですが、予め自己実現なら問題なし

▼ データに関しても通常、単なる事実でしかないため、保護の対象でもない

- ただし、情報の選択や体系的な構成に創造性が認められる場合は特別な規定により著作権が認められる

▼ 著作者財産権

- 複製権、公衆送信権、譲渡権など

▼ 著作者人格権

- 著作者の精神がきつけれられないように保護、公表権、氏名表示権、同一性保持権などがある、譲渡はできない

▼ 職務著作

▼ 従業員等が職務上行う著作

▼ 法人等の発意に基づいて、法人等が自己の名義で公開するものなどの要件を満たすれば、会社等の法人に著作権が原則として帰属する

- プログラムについては外部に公表を予定していないことも多いため、法人等が自己の名義で公表するものであることは不要と定められている

- 従業員ではなく、業務委託先が行なった著作の著作権は発注者ではなく業務委託先に帰属することを要注意

▼ 独占権利の例外

- 著作権法30条の4、コンピュータによる情報解析に利用するような場合には、複製等を認める
- 著作者の死亡年の翌年1月1日から起算して70年まで保護されます。

- ▼ 無名・変名・団体の場合は、公表後70年まで（または死亡後・創作後70年まで）
 - ベルヌ条約の「短期優先の原則（rule of the shorter term）」
- ▼ データと著作権
 - ▼ テーブルデータ
 - 内容は客観的な事実、やアノテーションの内容も客観的な事実の場合、著作権は発生しない
 - ▼ 画像データ
 - ▼ 人間がカメラを使って撮影した場合は原則著作権が発生
 - ただし、工場における設置カメラによる自動撮影のような場合は発生しない、また、画像に対するアノテーションは、通常客観事実の記述しかないので、アノテーションにより別途著作権の発生もない
 - ▼ テキストデータ
 - 人間が当該テキストを執筆した時点で著作権が発生、アノテーションは他と同じ
- ▼ プログラムと著作権
 - プラグラムも著作物として認める
 - パラメーターは計算の結果得られた数字の羅列なので、著作物とは言えず著作権発生しない
- ▼ 生成AIと著作権
 - ▼ 学習用データへの利用
 - 30条の4により原則的に適法
 - ▼ AI生成物の著作権
 - 単なるAI生成するものは創作性を認められず著作権は成立しない
 - 人間がAIを道具として創作したような場合やAI生成画像を作ったような人間に創作的寄与が認められる場合には著作権成立
 - ▼ AI生成物による著作権侵害
 - ▼ 既存著作物に類似していることを理由に著作権侵害が成立するためには、既存著作物に似拠している必要がある
 - ただし、AIはどう判定するはは大議論になる
- ▼ 特許法
 - ▼ 特許権

- ▼ アイデアを保護する法制度、排他的・独占的な権利、特許権者からライセンスを受けないと第三者がそのアイデアを使うことができない
 - ▼ 通常実施権
 - 他の第三者にも実施権を付与を行う
 - ▼ 専用実施権
 - 公表登記が必要、独占的排他的な権利を付与し特許権者自身も実施できない権利
- ▼ 基本
 - ▼ 特性
 - 産業上の利用可能性
 - 新規性
 - 進歩性
 - ▼ 登録制
 - ▼ 特許庁に出願をし、特許庁の審査と登録を受けて初めて権利として成立
 - 同一の発明を行なった者がいる場合に、日本の特許法は先願主義なので、先のやつに特許を与える
 - 特許は基本20年、医薬品などは最長25年
 - ▼ 従業員が職務に関して行なった発明について、一定の場合には特許権が使用者である企業等に帰属するための特許法で定めている
 - 契約や従業規則で使用者があらかじめ特許を取得するためを含めていれば、ただし、適切な対価を従業員に支払うが必要
- ▼ データの保護と不正競争防止法
 - ▼ 不正競争行為と呼ばれる情報の窃取などを処罰する
 - ▼ 営業秘密
 - ▼ 要件
 - ▼ 秘密管理性
 - 主観的ではなく、秘密管理の意思が秘密管理措置として他の一般情報特別必要、マル密などの表記付与、営業秘密のリスト化、閲覧のためのパスワード設定などで
 - 有用性
 - 非公知性

- ▼ 限定提供データ（2023年改正で導入）
 - 電磁的方法により相当量蓄積された情報であって、特定の者との間で、電磁的方法により有償で提供されるものをいう。
- ▼ 個人情報保護法
 - ▼ 個人情報の定義
 - ▼ 生存する個人に関する情報であって、いずれがに該当するもの
 - ▼ 当該情報に含まれる氏名、生年月日その他の記述等により特定の個人を識別することができるもの（他の情報と容易に照合することができ、それにより特定の個人を識別することができることとなるものを含む。）
 - 氏名や顔写真はもちろん、メールアドレスも該当する。電話番号や位置情報は単品であれば特定できないので個人情報ではないです。ただし、単品ではなく氏名と一緒にしている場合は個人情報になり
 - ▼ 個人識別番号が含まれるもの
 - 法令で定めた番号や記号などに該当し、指紋やDNAなどの生体情報や、運転免許証番号やパスポート番号などの公的機関より与えられた番号が含まれる。
顔認識に用いられる特徴ベクトルも前者の生体情報に該当し個人情報に該当する
 - ▼ 個人データベース等
 - ▼ 個人情報を含む情報の複合体であって、特定の個人情報を検索できるようにしたもの。
 - 注意が必要なのは、紙媒体によるデータベースも含まれるということです。名刺を五十音順に検索できるように並べたものも個人データベースに該当する
 - ▼ 個人データ
 - 個人データベース等を構成する個人情報
 - ▼ 保有個人データ
 - ▼ 開示、訂正、削除等の権限を有する個人データを指す。
 - 委託により預かっている個人データは保有個人データではないです
 - 事業者が自ら利用目的を決定して保有している個人データ のこと。
ただし、6か月以内に消去する短期データなどは除く
 - ▼ 類型ごとの規制概要
 - ▼ 個人情報

▼ 利用目的の特定等

- ▼ 原則として、あらかじめ本人の同意を得ることなくこの利用目的を超えて個人情報を取り扱うはできない
 - 利用目的はあらかじめ公表するか、速やかに通知または公表する必要
 - 通常の個人情報は取得する際に同意までは不要で、利用目的の通知または公表でOKが、要配慮個人情報は取得でも同意が必要

▼ 不適正な利用の禁止等

- 偽りその他不正の手段により取得は禁止、違法または不当な行為を助長し、または誘発する恐れがある方法により個人情報を利用も禁止

▼ 個人データ

▼ 取得利用に関する規制

- 個人データを正確・最新の内容を保ち、利用する必要がなくなった場合に、遅滞なく消去する努力が課せられる

▼ 安全管理義務

- 個人データの漏洩、滅失または毀損の防止その他の個人データの安全管理のために必要かつ適切な装置を講じなければならない
- 従業員もしくは委託を受けた者に対して必要かつ適切な監督を行うが必要

▼ 第三者提供規制

▼ 原則本人の同意が必要（オプトイン：opt-in）

▼ 例外

- ▼ 利用目的の達成に必要な範囲内において個人データの取り扱いを委託することに伴って個人データが提供される場合は同意不要
 - AI開発を第三者に委託する場合に、開発会社に学習用データとして個人情報を提供する。委託元の利用目的の達成に必要な範囲でのみ個人情報の利用が可能です

▼ 保有個人データに対する規制

▼ 開示請求

- 本人は、自己に関する保有個人データの開示を請求することはでき、企業は原則として応じなければならない

- ▼ 訂正等の請求権
 - 内容の訂正、追加または削除
 - 利用の停止または消去
- ▼ 特別な個人情報や類似情報の規制
 - ▼ 要配慮個人情報
 - ▼ 本人の人種、信条、社会的身分、病歴、犯罪の経歴、犯罪により害を被った事実などの特にセンシティブな個人情報を指す
 - オプトアウト（opt-out）より本人同意せず第三者へ提供不可
 - ▼ 匿名加工情報
 - ▼ 第三者に提供するため氏名などを削除するが、削除前のデータと容易に照合性が認められ、相変わらず個人情報として取り扱う、自由な利活用はできないため、匿名加工情報制度を設けた
 - 匿名加工情報は、プライバシーに関する情報のため様々な義務があったが、一定の事項を公表した場合には、同意なく第三者提供が可能になる
 - ▼ 特定の個人を識別できないように加工が必要
 - ▼ 例
 - ▼ 氏名を削除するとともに、住所を市区町村レベルまで抽象化、照合用のIDも削除、116歳などの特異なデータを削除など
 - 対応表の破棄なども必要
 - 個人情報保護委員会が公開してる個人情報の保護に関する法律についてのガイドラインがあり、匿名加工情報・匿名加工情報編
 - ▼ 仮名加工情報
 - 第三者提供は原則禁止され、事業者内部での利活用を想定した制度
 - ▼ 氏名との削除、クレジットカード番号などの財産的損害が生じる恐れのある記述等の削除でたり、「116歳」など特異なデータの削除等まで必要ない
 - 個人情報では利用目的を変更する場合には原則本人同意が必要、仮名加工情報では変更本人の同意が不要で、事後的に利用目的を変更して利用することができるようになり
 - ▼ 個人関連情報

- ▼ 生存する個人に関する情報であって、個人情報、仮名加工情報及び匿名加工情報のいずれにも該当しないもの
 - IPアドレス、閲覧履歴などこれらだけでは個人情報等該当するものではない
- ▼ 第三者へ提供する際に、提供先には当該個人関連情報を個人データとして取得が予測する場合、原則は本人同意が必要
 - 例、提供先の第三者が（氏名、住所、IPアドレス）の個人データを持っており、IPアドレスを用いて照合すると個人関連情報を個人データとすることができる場合がある
- ▼ GDPR（General Data Protection Regulation（一般データ保護原則））
 - ▼ EU領域内の個人情報を保護する目的の法
 - ▼ EUに事務所を設置している企業だけではなく、様々なものを保護対象としている
 - EUの個人に商品・サービスの提供を行っている
 - データポータビリティ権など日本居ない権限が定めている
 - データ保護責任者の配置等の日本の個人情報保護法にはない義務が定めている
 - データ移転に関して厳しい制限がある
 - 高額な制裁金がある
- ▼ 独占禁止法
 - ▼ 自由競争を阻害する行為を禁止することで公正かつ自由な競争を促進し、ひいては一般消費者の利益を保護するための法律
 - 事業者同士が話し合って価格を決定するカルテルなどを阻止する
 - ▼ 議論
 - ▼ データの囲い込み
 - 市場支配力のある巨大な事業者が、当該市場における事業活動に不可欠で、代替的な取得が困難なデータを独占すること ← ただし、まだ明確に禁止する法律がない
 - ▼ AIとカルテル
 - カルテルの合意が守られているかを監視するAIで、その合意に従って価格をつけるように設定されたアルゴリズムをカルテルに参加している事業間で用いていること

▼ デジタルプラットフォーム規制

- 一定のプラットフォーム事業者を対象に、取引条件等の開示や運営状況の報告・評価等を義務つける（特定デジタルプラットフォームの透明性及び高平成の向上に関する法律）

▼ AI開発契約

▼ 請負契約

- 仕事の完成を約束し、その結果に対して報酬が支払われる契約

▼ 準委任契約

▼ 履行割合型

- ▼ 事務の履行に対して報酬が支払われる
 - 医師による治療契約は完治の約束がない

▼ 成果完成型

- ▼ 事務により得られる成果に対して報酬を支払うもの
 - 請負と違って、成果の実現を条件に報酬を支払う、仕事完成業務がない、（努力義務＋成果確認）がある。

▼ AI開発契約に関するガイドラインと特徴

▼ 例

- 経済産業省が「AI・データの利用に関する契約ガイドライン」（AI契約書ガイドライン）
- 特許庁・経済産業省「研究開発型スタートアップと事業会社のオープンイノベーション促進のためのモデル契約書」（特許庁モデル契約書）
- 日本ディープラーニング協会「ディープラーニング開発標準契約書」

▼ 特徴

- モデルの内容や性能がデータの品質に依存する
- 性能保証が難しい
- ▼ ノウハウの重要性が高い
 - 加工方法、ハイパーパラメータ設定、データ分析などなど、委託者側のドメイン特有のノウハウも重要

▼ 開発の流れ

▼ アセスメント

- ▼ 解決すべき課題の特定等を行う、成果物は報告書であることが多い
 - AI契約ガイドラインでは秘密保持契約（NDA）だけを締結するが、想定は簡易なもので、実にはそれなりの工数が必要なので、一般的に準委任契約を利用
- ▼ PoC（Proof of Concept：概念実証）
 - ▼ 実運用可能なモデルが作成できるか、モデルを実運用できるかを調査するが目的
 - 準委任契約を締結、成果物は調査結果をまとめた報告書
- ▼ 実装
 - ▼ 結果予測できないため、準委任契約で行う事が多い。
 - 成果物としてはモデル（推論用コードとパラメータ）であり、成果完成型準委任契約を利用することもある
- ▼ 追加学習
 - 保守・運用契約中で実施か、ある程度規模大きな追加学習もあり、一般的に準委任契約です
 - ▼ 一般的にAIモデル以外、ユーザインタフェースも合わせて開発
 - アジャイル形式の場合は準委任契約が一般
 - ウォーターフォール型契約の場合は要件定義フェーズは準委任が、実装フェーズでは主に請負契約を用いている
- ▼ 知的財産権の帰属
 - ▼ AI開発契約で定めておく必要
 - 実用主義で、利用権を重視し、必要に応じて著作権者側に制限を加える
- ▼ 秘密保持契約（Non-Disclosure Agreement：NDA）
 - ▼ AI開発契約の締結検討段階や簡易なアセスメントを行う段階で締結される契約
 - 第三者へ開示・漏洩以外、目的以外禁止、他社からの委託や自社営業目的での使用なども禁止した方がよい
- ▼ AI利用契約
 - ▼ 特定の会社のために専用のAIを開発する場合の契約
 - ▼ 注意点
 - ▼ 追加学習に関する手当

- サービス提供者側の判断で追加され、ユーザ側は知らないもので
- ▼ 同じデータに対して昨日とは異なる出力になされるや、ユーザ環境における精度低下も可能
 - あらかじめ契約書で説明しておく、サービス提供者側が責任を負わないため定めていく
- 複数のユーザのデータを用いて1つのパラメータを更新する場合も、その旨をAI利用契約に明記すべき

▼ AIの論理

- 信頼できるAI (Trustworthy AI) 、責任あるAI (Responsible AI)

▼ 国内外のルールと取込み

▼ ハード・ロー

- ▼ 法律など公的機関が定める順守義務が生じるルール、法的強制力がある一方、成立や変更には議会などの承認が必要で遅くなる

▼ AI法案が代表的なEUを除けば基本はソフト・ロー

▼ EU: AI法案等

- AIを直接規制する法であるAI法案を発表し、制定を目指している、AIのリスクに応じた規制を行うリスクベースアプローチが採用され、法案以外、AIに関する賠償ルールを定めるハード・ローであるAI責任指令案を公開し、制定を目指している

▼ ソフト・ロー

- ▼ 公的機関だけではなく業界団体や学会も定める自主規制、ガイドラインなど、強制力がないが、裁判時に善管注意義務違反の参考になる

▼ 日本政府よりルール

▼ 内閣府

- 「人間中心のAI社会原則」のAIの社会実測を進めるため関係者が注意すべき基本原則を述べるガイドライン

▼ 総務省

- 「AI利活用ガイドライン」、AIをビジネスに利活用する者が留意すべき原則を述べる
- 「国際的な議論のためのAI開発ガイドライン案」、AI開発者が留意すべき原則についての説明

▼ 経済産業省

- 「AI原則実践のためのガバナンス・ガイドライン」、原則の実践を支援すべく、実施すべき行動目標を指示し、実践例や事務的な対応例を示している
- ▼ 外国政府によるルール
 - ▼ アメリカ
 - ▼ Blueprint for an AI Bill of Rights
 - アメリカのホワイトハウスが出したガイドラインであり、AIの開発や利活用等をガイドする原則を説明する
 - ▼ Executive Order on Safe, Secure, and Trustworthy Artificial Intelligence
 - バイデンは、AIの安全性に関して政府機関に対して研究を行うことなどの指示を大統領令
 - ▼ AI RISK MANEGEMENT FRAMEWORK
 - アメリカ商務省配下のNISTが定めたAIに関するリスク・前ネジメントのためのフレームワーク
 - ▼ EU
 - ▼ Ethics guidelines for trustworthy AI
 - AI法案より前に信頼できるAIのための必要事項を解説するもの
- ▼ 国際機関によるルールや国際連携
 - ▼ Recommendation of the Council on Artificial Intelligence
 - ▼ OECD（経済協力開発機構）
 - 2019年世界で初めて政府間で合意されたAIに関する原則。
AIは人権や民主主義の価値に沿うべき
透明性と説明責任
セキュリティとプライバシー保護
公平性と包摂性
 - ▼ G7（広島AIプロセス, 2023）
 - G7各国が生成AI（特に基盤モデル）に関して、透明性・リスク管理・国際協調を進める合意
 - ▼ Global Partnership on AI（GPAI, 2020設立）
 - 日本、米国、EU、インドなどが参加
 - AI倫理、ガバナンス、社会応用について国際協調
 - ▼ ISO

- ISO/IEC 42001（2023年）：AIマネジメントシステムの国際標準

▼ 公平性

▼ バイアス

▼ データバイアス

- ▼ 学習データに偏りがあることでモデルも偏る。
例：顔認識モデルが白人男性には強いが、女性や有色人種には弱い。
 - データ収集時に多様性を確保
 - サンプリング手法の工夫（例：層化抽出）
 - データオーグメンテーションで不足クラスを補う

▼ 選択バイアス（Selection Bias）

- ▼ 分析対象が偏っている。母集団を正しく反映しない。
例：健康調査を「病院に来た人」だけで行うと偏る。
 - 無作為抽出を徹底
 - 欠損データ処理を適切に実施
 - 重み付けで母集団に近づける

▼ 測定バイアス（Measurement Bias）

- ▼ データの測定方法が偏りを生む。
例：古い機器での計測誤差、質問票の誘導的な文言。
 - 測定機器・方法を標準化
 - クロスチェックや複数測定を導入

▼ アルゴリズムバイアス

- ▼ モデル構造や学習方法自体に偏りが入る。
例：誤差を最小化するだけだとマイノリティの精度が落ちる。
 - 公平性制約を組み込む（Fair ML）
 - ロス関数を工夫してマイノリティの重みを上げる

▼ 人間自体がバイアス

- 認知バイアス
- 無意識バイアス

▼ 安全性

▼ 安全性

- ▼ AIによって利用者や第三者の生命・身体・財産に危害が及ばないように配慮すること
 - 安全性基準
- ▼ 有効性
 - AIがタスクに対して適切に判断ができること
- ▼ プライバシー
 - ▼ プライバシー・バイ・デザイン
 - ▼ AIの開発の仕様設計段階からプライバシー保護の取組みを行う考え方
 - ▼ 経済産業省
 - カメラ画像を用いる場合に「カメラ画像利活用ガイドブック」を参考に、推論の内容、利用目的、データの保存方法、周知方法など
- ▼ 透明性とアカウントビリティ
 - ▼ 情報の開示に関する事項を透明性として扱う
 - どのような理由で、誰に対して、どのような情報を開示するのか検討するが必要
 - ▼ AIに関して責任を負うことを意味するものをアカウントビリティ
 - AIの出力がもたらされた入力やパラメータ等が追跡できる追跡可能性、出力の原因を探ることのできる検証可能性、必要なドキュメントの文書化、AI論理に関する事項を実施する責任者や担当組織の明確化など
- ▼ セキュリティ
 - 学習用データを汚染攻撃、敵対的事例（Adversarial example）を用いた推論結果の操作、推論結果を集めることによる学習用データやモデルの推測、細工をしたモデルの配布というモデル汚染攻撃など様々あり
- ▼ 悪用の防止
 - ディープフェイクなどポルノや偽情報や、生成AIを利用した詐欺や危険物の製造方法の調査などが問題、サイバー攻撃へのAI利用なども懸念された
- ▼ 仕事の保護
 - AI自動化により引き起こされる仕事の喪失から労働者を保護、最小化するや他の仕事に移行など
- ▼ 民主主義とその他の価値
 - 誤情報の拡散、ソーシャルメディアの操作、死者のデジタル復活などなど
- 生成AIにおける価値

▼ AIガバナンス

▼ 経営層の関与

- 経営層が組織として行うことを意思決定し、関与する

▼ AIポリシー

- AIの価値や原則などの目的に対して、どのように取り込んでいくのかなどを述べるドキュメント

▼ 責任者の特定

- AIガバナンスに関する業務を実施する責任者や実施担当者・担当組織を任命する必要

▼ AIリスク・アセスメント

- 開発・導入しようとしている、または現在利用しているAIが自組織や利用者、社会にどのようなリスクを生じさせるかの検討
- 目標や手続きの設定
- 社内教育

▼ 文書化

- 必要な文書を文書化して保存しておき、必要な者がいつでもアクセスできるようにしておく

▼ モニタリング

- どの指標で、どのような頻度やタイミングでモニタリングを行うのかを検討
- 内部監査、振り返りと改善

▼ リスク低減のための措置の例

▼ 人間の関与

- AIの判断は参考とし人間が最終判断を下す
- フィードバック
- ステークホルダー関与
- 多様性の確保
- データの品質確保